西南科技大学
Southwest University of Science and Technology

专业学位硕士研究生学位论文

（电子信息硕士）

基于深度学习的类风湿关节炎骨损伤诊断研究

作者姓名 凌德玉

学　　号 7220210689

导　　师 张广兵

专业（领域）名称 计算机技术

答辩委员会成员 黄晓芳　刘涌　陈永辉　李理　刘金

评　阅　人 王飞　张杏莉

2024 年 6 月

中国知网 https://www.cnki.net

分类号：　　学校代码：10619

UDC：　　密级：

西南科技大学硕士学位论文

（电子信息硕士）

基于深度学习的类风湿关节炎骨损伤诊断研究

凌德玉

学科（专业）或领域名称：计算机技术

指导教师姓名、职称：张广兵、副教授

校外指导教师姓名、职称：李斌、工程师

学生所属学院名称：计算机科学与技术学院

论文答辩日期：　2024 年 5 月 22 日

中国知网　https://www.cnki.net

A Thesis of Southwest University of Science and Technology for the Degree of Master

（Master of Electronic and Information Engineering）

Deep Learning-based Diagnostic Study of Bone Damage in Rheumatoid Arthritis

Candidate：Deyu Ling

Supervisor：Guangbin Zhang, Bin Li

June 2024

中国知网 https://www.cnki.net

摘　要

类风湿关节炎是一种病因未明的慢性系统性疾病，主要表现为炎性滑膜炎。其特征包括手、足小关节的多关节、对称性、侵袭性关节炎症，常伴有关节外器官受累及血清类风湿因子阳性，导致疼痛和功能受损，甚至可能出现关节畸形及功能丧失。对于类风湿关节炎患者而言，早期干预至关重要，因为早期干预可以有效防止不可逆的骨质破坏，减轻疼痛并保护关节功能。

在临床实践中，夏普/范德海登法被广泛用于评估类风湿关节炎的进展和关节损伤程度。然而，传统的人工夏普/范德海登评估方法存在一些问题，例如操作繁琐且主观性强，可能导致测量结果的不一致。为了解决这些问题，本课题提出了一种基于夏普/范德海登评分标准的手部 X 光片骨损伤自动诊断深度学习方法，旨在辅助医生更精确地预测类风湿关节炎患者手部的夏普/范德海登评分。

本文方法的创新之处有：首先，设计了一种轻量级特征提取模块 LTransformer，它能够以线性复杂度计算自注意力机制，从而显著降低时间和内存开销，加快类风湿关节炎特征的识别速度；其次，利用一种轻量化的通道注意力机制，以弥补 Transformer 模块在各通道之间特征融合方面的不足，进一步提高诊断精度；最后，引入自监督学习，以缓解数据集稀缺的问题，通过辅助自监督任务，提取额外的图像位置信息，增强模型训练的鲁棒性，这对于应对数据不足的情况非常有帮助。本文提出的自动诊断模型在区分类风湿关节炎手部骨损伤任务中表现出较高的准确率，能够更好地捕捉患者手部的局部特征，更加关注与夏普/范德海登评分相关的关节位置和间隙等重要细节。

为了验证所提出深度学习模型的有效性，本课题在一个公开可用的类风湿关节炎患者手部 X 光图像数据集上进行了大量实验。实验结果表明，所提出模型在预测夏普/范德海登评分方面表现出色，相较于该数据集上的最优模型，本文提出的模型平均绝对误差降低了 2%，均方根误差降低了 7.4%。

关键词：类风湿关节炎；深度学习；自动诊断

论文类型：应用研究

中国知网　https://www.cnki.net

ABSTRACT

Rheumatoid arthritis is a chronic systemic disease of undetermined etiology that is characterized by inflammatory synovitis. Its characteristics include polyarticular, symmetric, aggressive joint inflammation of the small joints of the hands and feet, often accompanied by extra-articular organ involvement and positive serum rheumatoid factor, leading to pain and functional impairment, and possibly even joint deformity and loss of function. Early intervention is critical for patients with rheumatoid arthritis, as it can effectively prevent irreversible bone destruction, reduce pain and protect joint function.

In clinical practice, the Sharp/van der Heijde method is widely used to assess the progression of rheumatoid arthritis and the degree of joint damage. However, the traditional manual Sharp/van der Heijde assessment method has some problems, such as cumbersome and subjective operation, which may lead to inconsistent measurement results. In order to solve these problems, this topic proposes a deep learning method for automatic diagnosis of bone damage on hand radiographs based on the Sharp/van der Heijde scoring criteria, aiming at assisting physicians to more accurately predict the Sharp/van der Heijde scores on the hands of rheumatoid arthritis patients.

The innovations of the method in this paper include: firstly, designing a lightweight feature extraction module LTransformer, which is able to compute the self-attention mechanism with linear complexity, thus significantly reducing the time and memory overhead and speeding up the recognition of rheumatoid arthritis features; secondly, utilizing a lightweight channel attention mechanism to make up for the Transformer module's inter-channel feature fusion to further improve the diagnostic accuracy; finally, self-supervised learning is introduced to alleviate the problem of dataset scarcity by assisting the self-supervised task to extract additional image location information and enhance the robustness of model training, which is very helpful to cope with the situation of insufficient data. The proposed automatic diagnostic model in this paper shows high accuracy in the task of distinguishing bone damage in rheumatoid arthritis hand, and is able to better capture the local features of the patient's hand, paying more attention to important details such as joint positions and gaps related to the Sharp/van der Heijde score.

In order to validate the effectiveness of the proposed deep learning model, extensive experiments were conducted on a publicly available dataset of X-ray images of the hands of rheumatoid arthritis patients. The experimental results show that the proposed model

中国知网 https://www.cnki.net

performs well in predicting the Sharp/van der Heijde scores, and the average absolute error of the model proposed in this paper is reduced by 2% and the root-mean-square error is reduced by 7.4% compared to the optimal model on this dataset.

KEY WORDS：Rheumatoid arthritis; Deep learning; Automated diagnosis

TYPE OF THESIS：Application Research

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景和意义.....1
1.2 国内外研究现状.....2
1.2.1 基于医学影像的诊断方法.....3
1.2.2 基于组学数据的诊断方法.....5
1.3 研究目标和内容.....6
1.4 论文内容安排.....7
2 类风湿关节炎医学影像诊断基础.....9
2.1 卷积神经网络.....9
2.2 深度学习网络.....12
2.2.1 LeNet.....12
2.2.2 AlexNet.....13
2.2.3 ResNet.....13
2.2.4 Transformer.....14
2.3 VIT 模型及其优化.....15
2.4 本章小结.....17
3 基于深度学习的 RA 图像诊断模型.....18
3.1 引言.....18
3.2 实验数据和评价指标.....20
3.2.1 Sv H 评分标准.....21
3.2.2 数据增强.....23
3.2.3 评价指标.....24
3.3 RAVIT 分类网络模型.....24
3.3.1 RAVi T 结构.....24
3.3.2 LTransformer 模块实现.....26
3.3.3 自监督学习方法.....30
3.4 实验结果的定量比较.....32
3.5 消融实验.....35
3.6 实验结果分析.....36
3.7 本章小结.....37
4 软件设计与实现.....38
4.1 引言.....38
4.2 软件架构设计.....38
4.3 软件各模块设计.....40

中国知网 https://www.cnki.net

4.4 软件界面设计及操作流程 42
4.4.1 界面设计.....43
4.4.2 主界面诊断流程.....45
4.5 软件测试.....47
5 总结与展望.....48
参考文献.....50

中国知网 https://www.cnki.net

1 绪论

1.1研究背景和意义

类风湿性关节炎（Rheumatoid arthritis,RA）是一种慢性炎症性疾病，2010 年全球发病率估计为 0.24%。女性发病率约为男性的 2 倍[1]。目前国内统计数据显示，RA 在成年人中的发病率约为十万分之八左右，与肿瘤、心脏病并列，成为导致劳动力下降的主要慢性疾病之一，给社会和个人都带来了沉重的医疗负担。RA 的特征是关节滑膜发炎，导致关节间隙变窄（JSN）和软骨下骨侵蚀、关节变形，并常常导致残疾[2]。并不是所有的 RA 患者都会出现关节损伤，这反映了该病的病因和发病机制存在差异。此外，一些症状轻微的患者会随着时间的推移慢慢出现进行性损害，这种损害只能通过影像学检查发现，由于其隐匿性，临床医生可能不易察觉。

确定患者是否出现关节损伤和评估病情进展速度是 RA 的主要挑战。通过放射成像对损伤进行实时、客观的定量评估，并与之前的图像进行比较，从而指导正在出现关节损伤的患者升级治疗。尽管先进的成像技术（如小线圈磁共振成像、超声波成像和其他成像技术）可以帮助患者直观地观察到关节的损伤情况，但这些技术在临床上并不适用。这些成像技术虽然可以帮助观察关节损伤，但这些技术要么价格昂贵，要么许多患者无法使用，要么依赖于操作者（如超声波成像）获取图像。在确诊为 RA 后，目前主流是通过评估手部、手腕和足部关节（RA 常受影响的关节）的 X 光片，对 RA 相关的骨和关节损伤进行量化，针对对这些关节部位的 JSN 和侵蚀程度进行评分。该研究 Sharp/van der Heijde（SvH）法[3]是目前公认的 RA 评分系统。然而，人工进行这种方法耗时、耗力，而且需要专业培训。研究 RA 临床疗效的研究人员将受益于一种自动化方法，该方法可快速、准确地评估关节损伤程度。这种方法可以在目前全球电子健康记录（EHR）中的成千上万张图像进行快速评分，并用于临床研究。经过临床验证后，这种方法可以集成到电子病历中，以便可靠、高效地监测类风湿关节炎患者关节损伤的进展，从而做出更好的治疗决定（例如，更换对通过放射成像检测到的损伤无效的改良抗风湿药物）。

基于深度学习（DL）的算法在图像分类方面已经达到了人类水平甚至更高的性能，这一点在 ImageNet 竞赛中已经有所体现[4,5]。例如，深度学习方法已被用于辅助诊断胸片上的肺结核或肺炎[6]。与 RA 相关的 JSN 和皮质骨侵蚀是一项独特的挑战，因为涉及的关节众多（如近端指间关节、掌指关节和腕部的许多关节），解剖结构复杂（如腕部关节由多块骨头组成）（图 1-1）。虽然许多研究在建立机器学习模型对 X 光片进行评分方面取得了进展[7-9]，但据调研考证，目前还没有独立的、可访问的、自动化的

中国知网 https://www.cnki.net

方法来量化 RA 相关关节损伤。

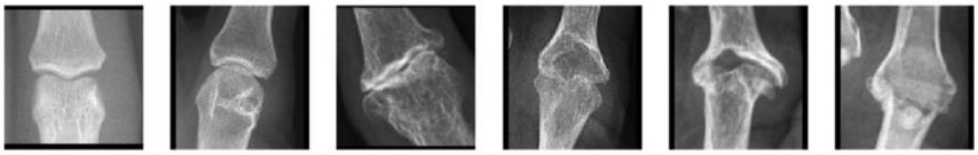


图 1-1 X 射线成像下骨关节的病变

目前国际上也有很多相关的基于神经网络的类风湿关节炎诊断模型的比赛，希望神经网络技术能在该领域中有突破性的进展。例如类风湿性关节炎挑战赛（RA2-DREAM）是一项全球性合作竞赛，吸引了生物学家、计算机科学家和医生等不同群体的参与。参加挑战赛的团队可以从美国国立卫生研究院资助的研究中获得已经有了标准的 SvH 评分的手部、腕部和足部的高分辨率 X 光照片。在每个子挑战赛中，根据参赛团队的算法性能对其进行排名。通过对最终评估数据集进行子采样和重新评分，对提交方法的可重复性进行了评估。然后，使用来自早期侵袭性类风湿性关节炎治疗（TEAR）试验的挑战后独立数据集对所有算法进行了验证[10]。每一届的获胜算法的表现都明显优于基线模型，并且非常接近专家评定的 SvH 分数。这支持了一种假设，即对类风湿关节炎放射影像进行自动评分是一种可行且有前景的方法。

总的来说，基于神经网络的类风湿关节炎放射影像自动评分方法开创了该领域的新篇章。虽然这些方法仍存在一些局限，如噪声的干扰和有效数据集不足等问题，但它们为类风湿关节炎自动诊断任务提供了全新的思路和技术手段。随着技术的不断进步和优秀的神经网络的出现，相信神经网络模型的诊断方法将为类风湿关节炎领域带来更加优异的表现和更加广阔的应用前景。

1.2 国内外研究现状

近年来，随着人工智能和机器学习技术的发展，卷积神经网络（CNN）在医学影像诊断领域展现出了巨大的潜力。在国内外，越来越多的研究致力于利用 CNN 技术对类风湿关节炎进行准确的诊断和预测，以提高诊疗效率和精准度，已然成为了备受关注的重要研究课题之一。在过去的几年中，大量的研究工作旨在开发具有鲁棒性强、预测精度高的算法。为了增强模型预测病情的准确性，人们在各种类风湿关节炎的临床上应用卷积神经网络技术来不断尝试提高诊断的精度。目前，主要的诊断算法可以分为基于医学影像和基于组学数据两个大类，如图 1-2 所示。基于医学影像的诊断方法又可以细分为基于 X 光图片、基于超声图像和基于核磁共振（MRI）图像三种方法；而基于组学数据的诊断方法所使用的临床数据种类繁多，例如血清或血浆中多种编码或非编码核糖核酸（RNA）[11]，血细胞的基因表达谱[12]，未修饰肽和 HN 修饰肽的自身抗体[13]，代谢组学[14]和糖组学[15]等。

中国知网 https://www.cnki.net

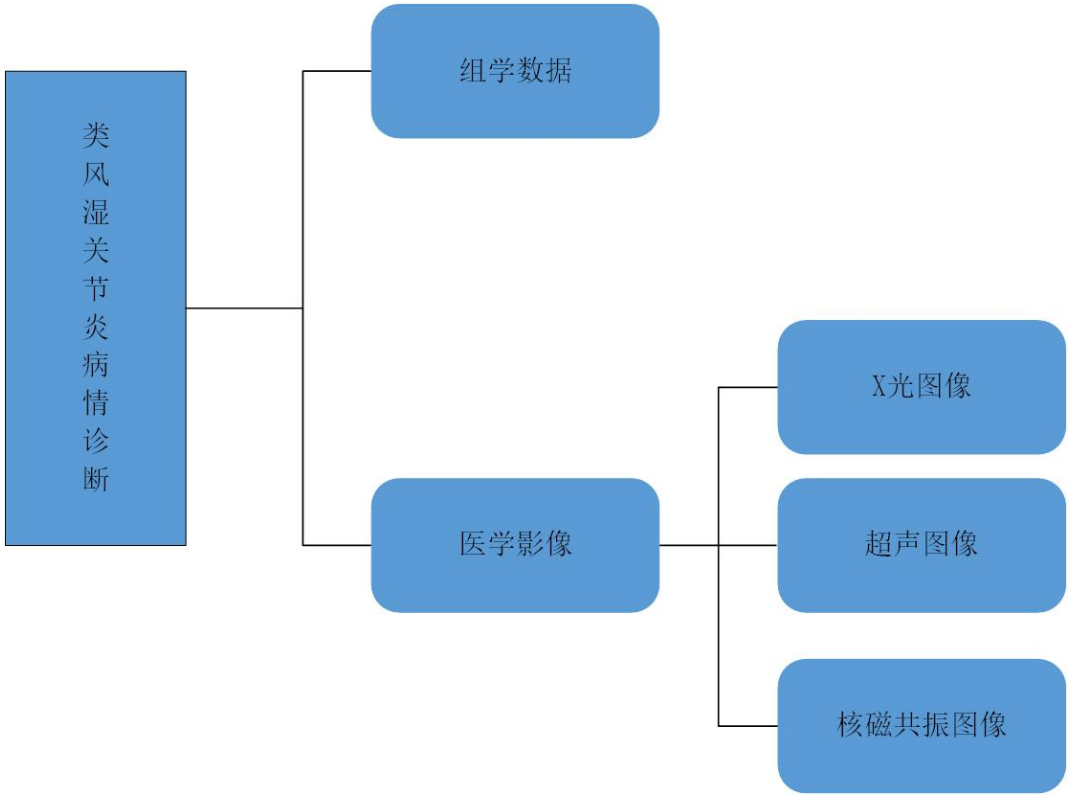


图 1-2 主要的类风湿关节炎病情诊断方法

1.2.1 基于医学影像的诊断方法

(1) X 光图像

大多数研究利用手部 X 光图像来识别侵蚀。最近的一项研究表明，通过基于深度学习（DL）的模型分析手部 X 光图像获得的严重程度评分可与人类评估者的评分相媲美。基于人工智能的模型在通过普通 X 光片检测 RA 关节间隙狭窄方面也表现良好。然而，由于侵蚀具有凸出的特点，传统的放射摄影可能会低估侵蚀的数量和大小。因此，利用 CT 图像自动检测和量化骨侵蚀有助于更准确地评估疾病的活动性。

2018 年，Murakami 等人利用深度卷积神经网络自动识别类风湿性关节炎患者手部 X 射线图像中的骨质侵蚀[16]。研究团队通过建立一个基于 CNN 的系统，对手部 X 射线图像进行分析和处理，以自动检测和识别 RA 患者手部骨质侵蚀的位置和程度。他们的研究结果显示，该系统在识别 RA 患者手部骨质侵蚀方面取得了良好的准确率和效果，为 RA 的影像诊断提供了一种新的自动化和精准化方法。

2019 年，Hirano 等人开发了一种基于深度学习的模型[17]，该模型使用密集连接卷积网络和全连接层来预测 RA 手指关节 X 光图像中的关节损伤评分，并与人工评分进行了对比验证。

2019 年，Rohrbachet 等人提出了一种基于 CNN 的模型[18]，该模型采用区域建议

中国知网 https://www.cnki.net

网络和回归网络来检测 RA 手部 X 光图像中的骨侵蚀区域并进行评分。该模型的创新之处在于它结合了区域建议网络和回归网络，实现了对 RA 手部 X 光图像中骨侵蚀区域的准确检测和评分。区域建议网络用于提取潜在的骨侵蚀区域，而回归网络则负责对这些区域进行评分。这种结合利用了深度学习的强大能力，能够高效地捕获图像中的复杂特征，并在大规模数据集上进行训练和优化。

2021 年，Chaturvedi 等人利用深度卷积神经网络与注意力机制来预测关节 X 光片中的关节损伤[19]。作者提出了名为 DEEPRA 的模型，该模型结合了 CNN 和注意力机制，以提高关节损伤预测的准确性和效率。通过在大量的关节 X 光片数据上进行训练，DEEPRA 模型能够自动学习并识别 X 光图像中的关键特征，从而实现对关节损伤的准确预测。其注意力机制可以帮助模型聚焦于图像中最相关的区域，进一步提高了预测的准确性。这一研究成果为类风湿性关节炎等疾病的诊断和治疗提供了新的可能性，有望帮助医生更及时地识别和干预关节损伤，提高患者的生活质量。

2022 年，Li 等人提出了一种多层次建模方法[20]，利用线性混合效应模型和广义估计方程模型分析 RA 手部 X 光片中关节损伤的发展趋势和影响因素。虽然这类方法能提供更细化的评分信息，但需要进行图像预处理、关节定位和更多标注数据。此外，这些方法还忽略了不同手指之间的相互作用和依赖关系。

(2) 超声图像

2018 年，Tang 等人提出了利用深度卷积神经网络对类风湿性关节炎在超声图像上进行分级的方法[21]。研究团队训练了一个深度 CNN 模型，通过学习超声图像中的特征来自动识别和分级类风湿性关节炎。他们的方法能够有效地实现对关节炎的定量评估，避免了传统手动评分的主观性和不一致性。

2019 年，Andersen 等人利用神经网络技术自动评分关节炎疾病活动程度的超声图像[22]。研究团队采用神经网络模型，通过学习超声图像中的特征来实现对关节炎疾病活动程度的自动评分。他们的方法不仅能够准确地识别和评估关节炎的活动程度，而且还节省了医生手动评分的时间和劳动成本。

2020 年，Christensen 等人利用级联卷积神经网络设计进一步增强了对类风湿性关节炎患者超声图像中关节炎疾病活动程度的自动评分[23]。研究团队采用了级联的 CNN 模型，通过多层级的特征提取和学习来增强评分的准确性和稳定性。他们的方法不仅在评分准确度上取得了显著提高，而且还提高了模型的鲁棒性和泛化能力。这项研究为类风湿性关节炎患者提供了一种更加精准和可靠的评估工具，有望在临床实践中帮助医生更准确地判断疾病活动程度，从而指导更有效的治疗方案。

2024 年，He 等人利用深度学习技术基于多模态超声图像开发了自动评分模型[24]，用于评估类风湿性关节炎的疾病活动程度。研究团队综合利用了多种超声图像模态，如 B 模式、彩色多普勒和组织彩色多普勒等，构建了深度学习模型。通过对大量的数据进行训练，模型能够准确地识别和评分类风湿性关节炎的疾病活动程度。

中国知网 https://www.cnki.net

(3) 核磁共振图像

2005 年，Sommer 等人介绍了类风湿性关节炎成像技术的最新进展、图像解读以及临床应用[25]。创新点包括系统地总结了多种影像学技术在 RA 诊断和评估中的应用，如 X 射线、超声、磁共振成像等。文章深入探讨了各种成像模态在 RA 早期诊断、疾病活动评估和治疗效果监测中的作用。此外，文章还讨论了图像解读的技术细节和临床意义，为临床医生提供了全面的指导，有助于提高 RA 患者的诊疗效果。

2007 年，Tripoliti 提出了一种基于磁共振成像数据的自动化手部炎症组织分割和定量方法[26]，用于类风湿性关节炎患者的研究。研究团队开发了一种自动化算法，能够准确地识别和量化 RA 患者手部磁共振图像中的炎症组织。

2012 年，Boesen 等人探索了计算机辅助动态钆增强磁共振成像评估与类风湿性关节炎患者手腕滑膜炎和骨髓水肿评分之间的相关性[27]。研究团队发现了动态 MRI 评估与传统评分方法之间的密切相关性，为了更好地评估 RA 患者的关节炎症程度提供了新的视角。通过这项研究，为临床医生提供了更准确和全面的影像学评估方法，有助于指导 RA 患者的治疗决策和监测疾病进展。

2015 年，Czaplicka 等人出了一种自动化评估类风湿性关节炎患者手腕滑膜炎的方法[28]，利用 0.2T 磁共振成像。研究团队开发了一种计算机辅助系统，能够自动识别和评估手腕滑膜炎在磁共振图像中的程度。他们的方法不仅提高了评估的速度和效率，而且还减少了人为误差。

1.2.2 基于组学数据的诊断方法

多项研究采用蛋白质组学方法，使用质谱法发现循环诊断生物标志物[29]。在这类研究中，样本量通常相对较小，而每个样本都包含大量的输入变量。这种非典型的数据模式使基于决策树的算法适合于数据分析，因为与样本数量相比，它们可以处理输入数据不成比例的高维度。在这种情况下，2005 年，Geurts 及其同事表明[30]，增强的决策树优于其他 ML 方法，包括 SVM 和 k 近邻（kNN）。使用这种方法，提出了几种蛋白质峰模式，以高灵敏度和特异性将 RA 患者与对照组和其他自身免疫性疾病患者区分开来。

使用来自血清的组学数据，特别是炎症和氧化应激标志物[31]，已经开发了其他几种诊断模型。使用人工神经网络（ANN）分析 38 种细胞因子的循环水平，得出了一个在区分 RA 患者、对照组和骨关节炎（OA）患者方面具有 100%敏感性和特异性的模型。然而，ANN 是一个黑盒，为进一步的临床推断提供了有限的信息。因此 2014 年，Heard[32]及其同事利用单一的决策树来识别导致该项目产出的细胞因子。这些细胞因子包括 CD40L、转化生长因子（TGF）-a、表皮生长因子（EGF）、干扰素（IFN）-c、嗜酸性粒细胞趋化因子、巨噬细胞炎症蛋白（MIP）-1b、肿瘤坏死因子（TNF）-a、IL-1a、粒细胞集落刺激因子（G-CSF）、fractalkine、生长调节癌基因（GRO）和血管内皮生

中国知网 https://www.cnki.net

长因子（VEGF）。这一发现强调了在传统统计方法之外应用 ML 算法开发最佳诊断面板的必要性。

使用代谢组学和糖组学的机器学习方法在 RA 的诊断中也显示出有希望的结果。2016 年，Ahmed 及其同事通过研究血浆、血清和滑膜样本[33]，评估了关节损伤蛋白的诊断价值，包括氧化蛋白、硝化蛋白和糖化蛋白，以及循环中释放的氧化、硝化和无糖化加合物。他们的算法以血浆中 10 种受损氨基酸的水平、羟脯氨酸和抗 CCP 抗体状态为特征，成功地将早期 RA 与对照组和其他关节炎患者区分开来。值得注意的是，晚期患者的受损氨基酸水平高于早期患者。2018 年，Chocholova 等人使用糖组学数据训练了基于 ML 的诊断模型[34]，在血清阳性患者中，ANN 和 LASSO 回归的诊断准确性相当。然而，在他们的研究中，ANN 在检测血清阴性患者方面优于 LASSO 回归。

2020 年，Ormseth 及其同事使用 LASSO 变量选择和逻辑回归开发了一组区分 RA 患者和对照组的微小 RNA（miRNA）[35]，这导致了 miR-22-3p、miR-24-3p、miR-96-5p、miR-134-5p、miR-140-3p 和 miR-627-5p 的选择，所有这些在 RA 患者中都上调。在区分 RA 患者（血清阳性或血清阴性）与对照组时，miRNA 组显示 AUC 约为 0.8。然而，该小组可能是自身免疫性疾病的非特异性特征，因为它不能区分 RA 和系统性红斑狼疮。

尽管利用卷积神经网络技术基于医学影像和组学数据的类风湿关节炎病情诊断方法已经表现得相当出色，但是当存在较大分辨率的图像时，可用的远距离信息可能会无效，卷积神经网络对远距离的信息捕获能力很弱，这可能会降低模型对图像语义的理解能力。因此，针对这个问题，需要研究更加高效的方式来提高模型的特征捕获能力。

1.3研究目标和内容

自基于医学影像的卷积神经网络被引入类风湿关节炎病情诊断任务后，诊断的效率和精度都得到了很大的提升。针对上述提到的该领域仍存在的问题，本文的研究目标是构建一种既能捕捉到类风湿关节炎细小的病理特征，又能利用图像中距离较远的信息的关联性，更好的对类风湿关节炎病情做出快速准确诊断的模型。本文提出的模型在均方根误差（RMSE）和平均绝对误差（MAE）等量化指标上表现出色，均实现了降低，超过国内外前沿的 RA 诊断模型。同时，并以课题的研究和试验为基础，发表基于深度学习的类风湿关节炎诊断模型的相关高水平国际会议论文或期刊论文。本文主要是从自动化 RA 诊断模型、轻量级特征提取模块、轻量化通道注意力机制、额外自监督任务的引入等方面，对基于深度学习的 RA 诊断新方法进行研究。本文的主要研究内容为以下几点：

（1）结合不同领域的知识：本课题研究将医学、影像学和计算机深度学习方法相

中国知网 https://www.cnki.net

结合，设计了一种自动化诊断模型，用于检测手部 CT 图像中的类风湿关节炎病情情况。这种跨学科方法可以减轻医生的工作负担，提高诊断的准确性和效率，对于早期诊断和监测 RA 在医疗实践中具有重要意义。

（2）引入 Vision Transformer (ViT)模型[36]：这是该领域首次尝试将 Vision Transformer 模型应用于 RA 的骨损伤诊断，而不是传统的卷积神经网络。这一创新意味着更好地捕捉图像的全局信息，从而提高了特征提取的能力。

（3）轻量级特征提取模块 LTransformer：设计了一种轻量级特征提取模块 LTransformer，它能够以线性复杂度计算自注意力机制，从而显著降低了时间和内存的开销，加快了 RA 特征的识别速度。

（4）轻量化的通道注意力机制：引入了一种轻量化的通道注意力机制，以弥补 Transformer 模型在各通道之间特征融合方面的不足，进一步提高了诊断的精度。

（5）自监督学习的引入：本研究首次在该领域引入了自监督学习，以解决数据集稀缺的问题。通过辅助自监督任务，可以提取额外的图像信息，并增强模型训练的鲁棒性，这对于应对数据不足的情况非常有帮助。

基于以上的研究内容，本文提出了基于深度学习 ViT 模型的类风湿关节炎手部 X 光片损伤诊断模型。通过优化 ViT 核心模块 Transformer 并引入轻量化的通道注意力机制和自监督学习，该模型能够更有效地提取图像特征并解决数据不足的问题，从而提高了诊断精度和效率。这一研究为早期诊断和监测类风湿关节炎在医疗实践中的应用提供了新的思路和方法。

1.4 论文内容安排

本文一共分为五个章节，结构安排如下：

第一章：绪论。本章介绍了类风湿关节炎病情诊断的背景和意义，探讨了该疾病对患者生活的影响以及早期诊断的重要性。同时，从医学、影像学和计算机深度学习的角度对目前类风湿关节炎诊断方法进行了概述，指出了现有方法存在的局限性和需要改进的地方。最后，简要介绍了本文的研究目标和主要内容，以及整体结构。

第二章：类风湿关节炎医学影像诊断基础。本章重点介绍了类风湿关节炎影像诊断中常用的技术和方法，包括卷积神经网络、深度学习 ViT 模型和基于 ViT 模型的一些优化网络。对每种技术进行了详细的介绍和分析，探讨了其在类风湿关节炎诊断中的优势和局限性。

第三章：基于深度学习的 RA 图像诊断模型。通过引入深度学习技术，本章设计了一种基于 ViT 模型和通道注意力机制的 RA 图像诊断模型 RAViT。该模型结合了医学影像学和计算机深度学习的方法，能够自动识别和评估 RA 患者手部影像中的关节炎病变。通过相关实验验证了模型的有效性和准确性。针对 RA 图像诊断中存在的数

中国知网 https://www.cnki.net

据集较少问题，引入了自监督学习，提出了改进的监督学习与自监督学习相结合的 RA 图像诊断模型。通过自监督学习任务的辅助训练和损失函数的调整，改善了类风湿关节炎图像数量较少带来的问题，提高了诊断的准确性。本章将详细介绍所提出模型 RAViT 的各个组件及其原理、实验结果与分析。

第四章：基于 RAViT 模型的类风湿关节炎辅助评分应用软件。主要介绍了该软件的流程结构、模块设计以及功能测试。

第五章：总结与展望。最后一章对本文的研究内容、方法和成果进行了总结，并分析了存在的不足之处。同时，提出了未来需要解决的问题和可行的研究方向，为进一步的 RA 图像诊断研究提供了有益的启示。

中国知网 https://www.cnki.net

2 类风湿关节炎医学影像诊断基础

医学影像诊断是计算机视觉领域中的一项重要研究课题，其目的是根据对医学临床上的图像数据按照一定的标准进行病人病情的评估和预测，以便更好得辅助医生给出合理有效的治疗方案。在过去的几十年中，研究者们已经提出了许多有效的医学影像诊断算法[37-39]。随着机器学习和人工智能的不断发展，卷积神经网络、深度学习算法等优秀的模型被广泛应用于医学影像领域。本章将重点介绍这些算法的原理和应用，并介绍类风湿关节炎病情诊断的评分标准，以便读者更好地了解该领域的应用。

2.1 卷积神经网络

卷积神经网络是一种流行的机器学习（ML）模型，已被广泛用于各种任务，包括图像识别、语音识别和 自然语言处理（NLP）等。CNN 在图像识别任务中尤其成功，在多个基准测试中取得了最先进的结果。它们的成功归功于其捕捉图像中空间特征和模式的能力，这种能力是通过使用分层架构来执行卷积运算并提取不同抽象层次的特征。本节全面概述了 CNN 的基本原理、架构和最新发展。

CNN 是一种功能强大的神经网络，广泛应用于图像识别任务。它们由一系列卷积层和池化层组成，这些层从输入图像中提取相关特征，然后由一个或多个全连接层利用这些特征进行预测。要使用 CNN 进行图像识别，首先必须在包含相关对象的大型标注图像数据集上对其进行训练。在训练过程中，CNN 通过反向传播和优化过程学会将提取的特征与正确的标签联系起来[40]。一旦 CNN 经过训练，就可以通过网络传输图像并选择预测概率最高的标签，从而对未见过的新图像进行预测。图 2-1 显示了用于图像分类的 CNN 的简化图示。

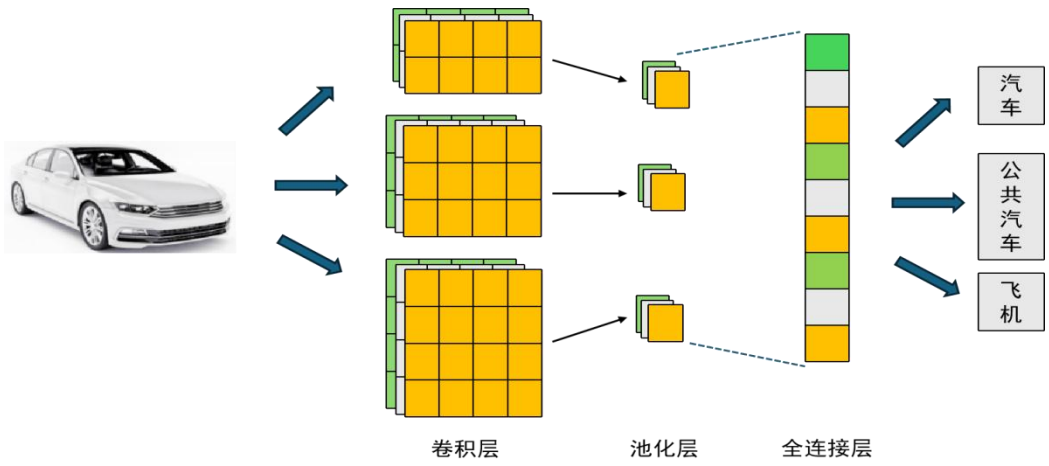


图 2-1 简单的 CNN 网络例子

中国知网 https://www.cnki.net

网络的输入是一幅汽车图片，输入到输入层。输入层将图像传送到卷积层，该层对图像应用一组滤波器。每个滤波器从图像中提取特定的特征，如边缘或纹理。然后，卷积层的输出被传递到下一个隐藏层，在那里应用更多的滤波器来提取更高级别的特征。这一过程在多个隐藏层中重复进行，直到最后一个隐藏层，该层产生的一组特征被传递到池化层和全连接层，最后到达输出层。输出层产生汽车、公共汽车和飞机三个类别的概率分布。然后，网络根据概率最高的类别做出决策。每一层过滤器的权重都是通过反向传播学习的，反向传播可以调整权重，使预测输出与实际输出之间的误差最小化。

CNN 的核心组件是卷积层、池化层和全连接层。以下是卷积神经网络的基本结构及其公式：

（1）卷积层。卷积层是 CNN 中最核心的单元。它使用一组可学习的滤波器对输入图像进行卷积运算，从而生成一组特征图。滤波器是在输入图像上滑动的小阵列，每一步都要计算滤波器与输入图像一小块区域之间的点积。卷积层的输出是一组代表输入图像中不同特征的特征图。卷积是信号处理、图像处理和计算机视觉中常用的一种数学运算。它用于将两个信号或函数结合起来，产生第三个信号，该信号代表一个信号对另一个信号的影响，并根据另一个信号的形状进行加权。在计算机视觉中，卷积是利用 CNN 从图像中提取特征。卷积的数学定义如下：

$$(f * g)[\mathrm{t}] = \sum_{\sigma=-\infty}^{\infty} f\,[\sigma] g[\mathrm{t}-\sigma] \tag{2-1}$$

式中 f 被称为输入函数或输入信号，在 CNN 中，通常是表示输入图像的像素值；g 被称为卷积核或滤波器，在 CNN 中，卷积核是由网络学习到的参数。f 和 g 可以是离散的，也可以是连续的；卷积运算用符号∗表示；t 是输出信号的位置或时间索引；σ表示卷积核 g 在当输入信号 f 上滑动的位置。离散时，上式可写成：

$$(\mathrm{f} * \mathrm{g})[\mathrm{t}] = \sum_{\sigma=-\infty}^{\infty} \mathrm{f}\,[\sigma] \mathrm{g}[\mathrm{t}-\sigma] \Delta\sigma \tag{2-2}$$

式中$\Delta\sigma$为采样间隔。当输入信号为连续信号时，卷积运算可定义为：

$$(f * g)(t) = \int_{-\infty}^{\infty} f\,(\tau) g(t-\tau) d\tau \tag{2-3}$$

式中τ表示卷积核在输入函数 f 上进行积分操作时所处的位置。

（2）池化层。池化层用于降低卷积层生成的特征图的空间维度[41]。它在每个特征图上独立运行，并通过减去非重叠区域的最大值或平均值来执行降采样。池化过程有助于降低网络的计算复杂度，还能使网络对输入图像的微小平移更加稳健。通过减去

中国知网 https://www.cnki.net

非重叠区域的最大值或平均值，可以降低卷积层生成的特征图的空间维度。最常见的池化操作为最大池化（Max Pooling）和平均池化(Average Pooling)。最大池化见图 2-2 最大池化操作。前向传播：选图像区域的最大值作为该区域池化后的值。反向传播：梯度通过最大值的位置传播，其它位置梯度为 0。

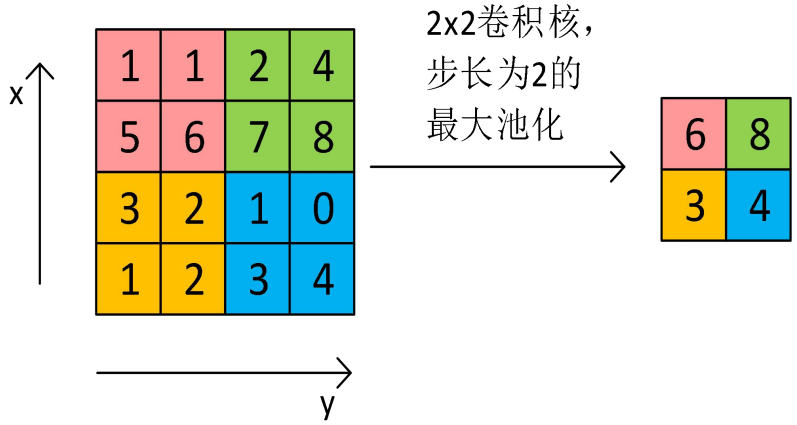


图 2-2 最大池化操作

平均池化见图 2-3 平均池化操作。前向传播：计算图像区域的平均值作为该区域池化后的值。反向传播：梯度取均值后分给每个位置。

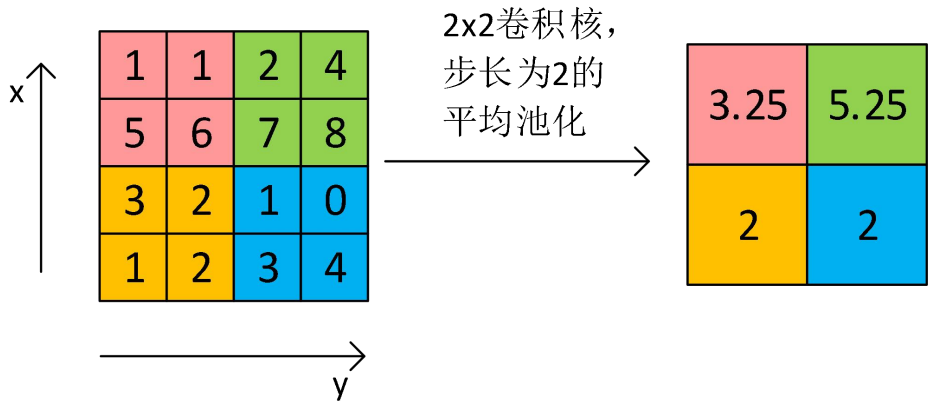


图 2-3 平均池化操作

（3）全连接。全连接层（Fully Connected Layers，FC）在卷积神经网络中的作用是充当“分类器”。相比于卷积层、池化层和激活函数层等操作将原始数据映射到隐层特征空间，全连接层则将学到的“分布式特征表示”映射到样本标记空间，见图 2-4 全连接层示意图。在实践中，全连接层可以通过卷积操作实现：对于前一层是全连接的全连接层，可以转化为卷积核为 1x1 的卷积操作；而对于前一层是卷积层的全连接层，可以转化为卷积核为高度（h）和宽度（w）的全局卷积，其中 h 和 w 分别为前一层卷积结果的高度和宽度。全连接层的核心操作是矩阵向量乘积，可以表示为：

中国知网 https://www.cnki.net

$$y = Wx + b \tag{2-4}$$

式中 y 是输出向量，W 是权重矩阵，x 是输入向量，b 是偏移量。这一操作本质上是将特征空间进行线性变换，从而将输入特征映射到输出特征空间。在 CNN 中，全连接层通常出现在网络的最后几层，用于对前面设计的特征进行加权和。换言之，前面的卷积和池化层相当于进行特征提取，而全连接层则相当于进行特征加权，最终得到样本的分类结果。

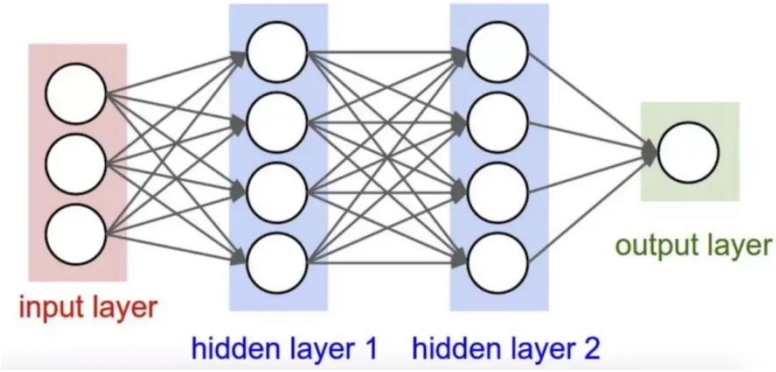


图 2-4 全连接层示意图

2.2 深度学习网络

2.2.1 LeNet

LeNet 是由深度学习领域的先驱之一 Yann LeCun 于 1998 年设计提出的[42]，被认为是最具代表性的早期 CNN 模型之一，特别用于手写字符的识别与分类。该模型在当时广泛应用于美国银行的字符识别任务中。LeNet 的设计奠定了 CNN 的基本结构，其中包括卷积层、池化层和 ReLU 激活函数等，见图 2-5。这些结构现在在许多神经网络中仍然被广泛采用。尽管 LeNet 在上世纪 90 年代就被提出，但由于当时训练数据规模有限，计算机硬件性能不足，因此其在处理复杂问题时的效果并不理想。

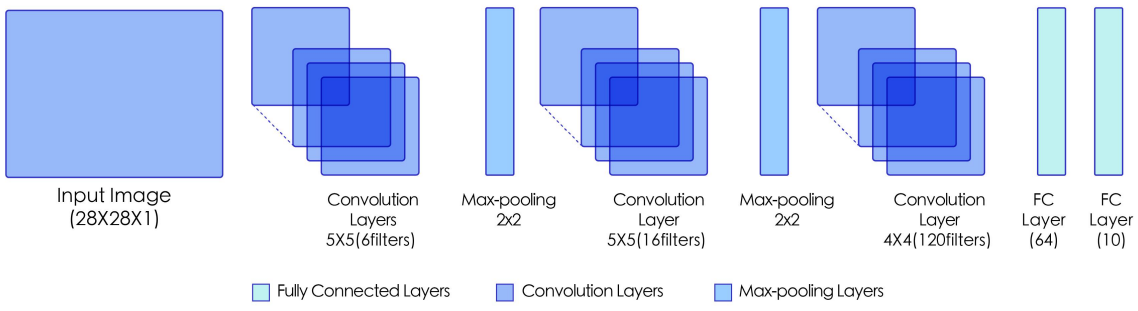


图 2-5 LeNet 网络结构

中国知网 https://www.cnki.net

LeNet5 这个网络虽然很小，但是它包含了 CNN 的基本模块：卷积层，池化层，全连接层，是后来其他 CNN 模型的基础。

2.2.2 AlexNet

ImageNet 挑战赛是一个旨在评估图像分类和对象识别架构在大规模数据集上表现的竞赛。自 2010 年开始举办以来，该竞赛已经引入了许多新颖、强大和有趣的视觉架构。在 2012 年，ImageNet 挑战赛发生了重大变化[43]，AlexNet 以仅 15.3%的 Top 5 错误率赢得了比赛，几乎是之前获胜者错误率的一半。AlexNet 的网络结构包括 5 个卷积层、随后的最大池化层、3 个全连接层和一个 Softmax 层，见图 2-6。这次胜利展示了深度卷积神经网络在处理视觉识别任务上的优越性。尽管当时这一观点尚未被广泛应用到其他领域，但它为深度学习的发展开辟了新的道路。

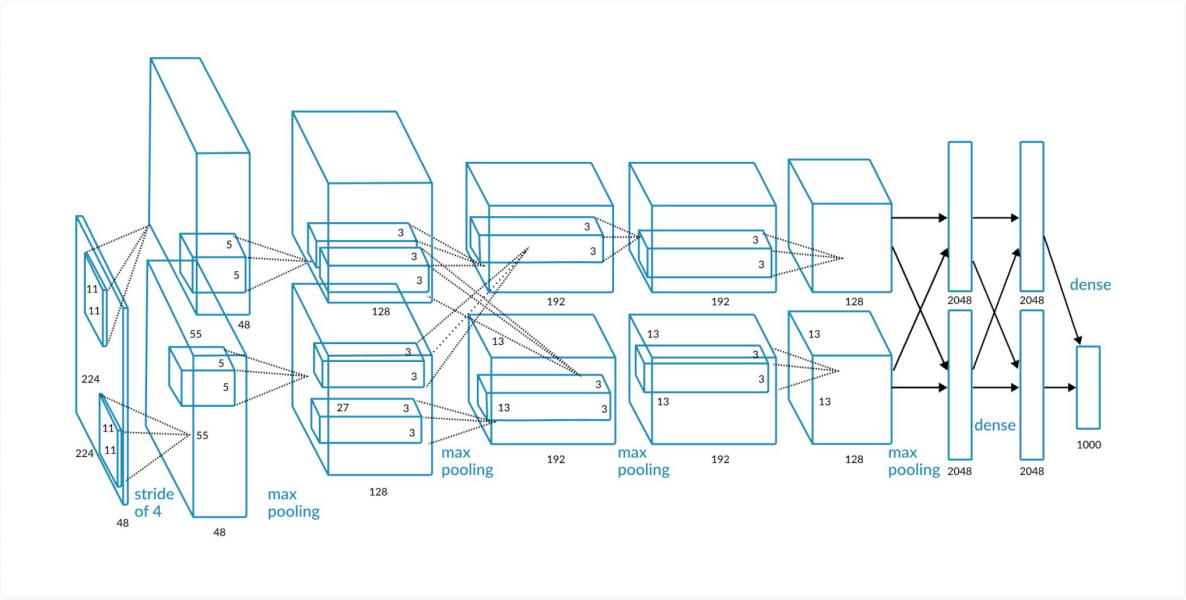


图 2-6 AlexNet 网络结构图

2.2.3 ResNet

ResNet 网络是由微软实验室的何凯明等人于 2015 年提出的[44]，在当年的 ImageNet 竞赛中取得了分类任务和目标检测任务的第一名，以及在 COCO 数据集上实现了目标检测和图像分割的第一名。ResNet 主要创新点包括超深的网络结构、引入了残差结构如图 2-7 以解决梯度消失和梯度爆炸的问题，以及使用 Batch Normalization 加速训练过程。

中国知网 https://www.cnki.net

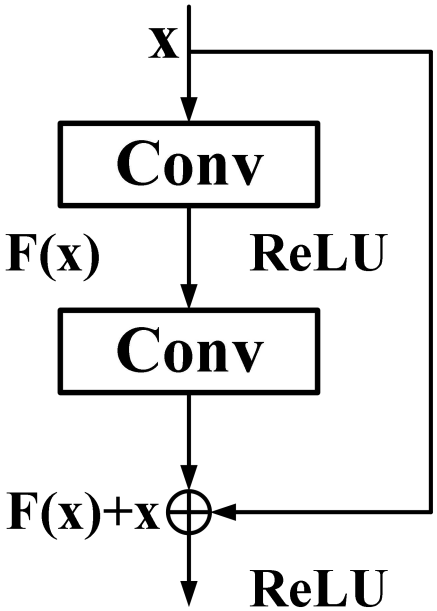


图 2-7 残差连接

在 ResNet 之前，普遍认为通过增加卷积层和池化层的层数可以提升网络性能，但实际实验发现随着层数增加，网络性能反而出现退化问题。为了解决这一问题，ResNet 引入了残差结构，允许某些层跳过下一层神经元的连接，从而减轻了退化问题的影响。通过这些创新，ResNet 取得了突出的性能表现，并为后续的深度学习研究奠定了重要基础。

2.2.4 Transformer

Transformer 模型是一种基于自注意力机制的神经网络，被广泛应用于处理序列数据，如文本、语音信号、图像或视频等。其核心思想是对序列中的每个元素进行全局建模，并建立元素之间的联系。该模型包括多层 encoder 和 decoder，每层由多个注意力机制模块和前馈神经网络模块组成，见图 2-8。通过残差连接和层归一化等技术，Transformer 模型加速了模型收敛并提高了性能。与传统的循环神经网络(RNN)相比，具有更好的并行性能和更短的训练时间，能够处理长序列并克服 RNN 的难题。在机器翻译等任务中，Transformer 模型通过自注意力机制并行处理输入序列的每个词，不受词序影响，展现出色彩。总的来说，Transformer 模型是一种高效的序列处理工具，在自然语言处理领域得到广泛应用，提供比传统 RNN 更好的性能和灵活性。

中国知网 https://www.cnki.net

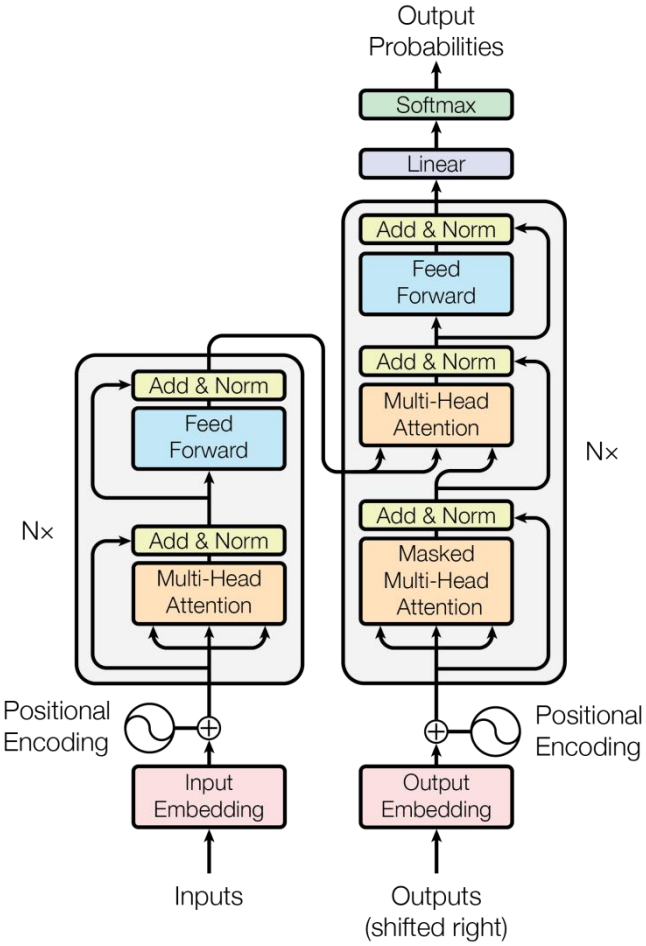


图 2-8 Transformer 网络结构[45]

2.3 ViT 模型及其优化

随着深度学习的迅速发展，传统的卷积神经网络在图像分类和目标检测等任务上取得了显著成果。然而，对于处理大尺寸图像和长序列数据，卷积神经网络存在一些局限性。为了解决这些问题，近年来出现了一种新型模型，即 Vision Transformer（ViT）模型[36]。

ViT 模型采用了基于自注意力机制的图像分类方法。与传统的卷积神经网络不同，ViT 模型将图像分割成小的图块，并将它们作为输入序列进行处理。每个图块经过一系列变换后被转换为一个向量，然后这些向量被送入 Transformer 模型进行分类。

ViT 模型最大的创新之处在于引入了自注意力机制。传统的卷积神经网络在提取图像特征时局限于捕捉局部信息，而自注意力机制能够考虑到全局信息，从而提高了模型的性能。这是通过在 Transformer 中引入多头自注意力机制来实现的。每个注意力头都可以学习不同的注意力模式，因此 ViT 模型可以捕捉到图像中不同尺度和重要性的特征。

除了自注意力机制，ViT 还引入了位置编码。位置编码是用来为序列中的每个图

中国知网 https://www.cnki.net

块提供位置信息的。通常使用正弦函数和余弦函数来编码位置信息，这样可以在序列中引入时间和空间上的结构。位置编码的引入有助于模型理解图像中的局部和全局上下文关系，结构如图 2-9。

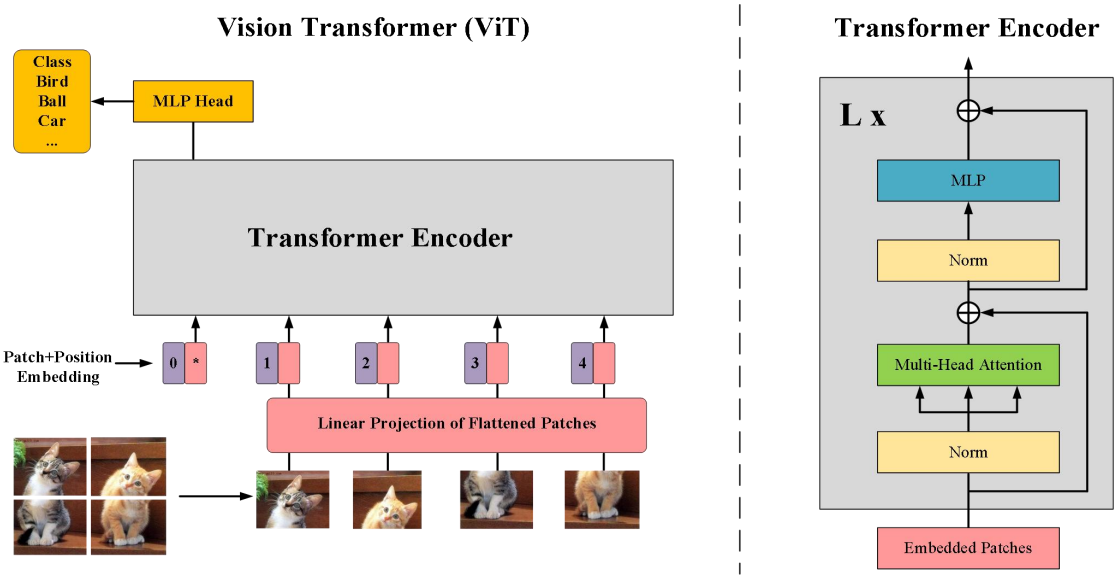


图 2-9 ViT 模型结构

相比于传统的卷积神经网络，ViT 模型具有几个显著的优势。首先，ViT 不需要手动设计的卷积结构，能够适应不同尺寸和分辨率的图像数据。其次，ViT 模型具有较强的泛化能力，可以在小数据集上表现出色。这得益于自注意力机制能够将全局信息纳入考虑，从而更好地理解图像的语义。除此之外，ViT 模型还具有较低的计算复杂性，可以并行处理不同图块。

然而，ViT 模型也存在一些挑战和限制。由于输入序列的长度通常比较大，ViT 模型在处理大尺寸图像时会面临显存限制和计算开销的问题。此外，ViT 模型对输入的位置信息较为敏感，对噪声和变形比较敏感。为了增强位置信息的鲁棒性，一些改进方法被提出，例如引入局部感知机制或者使用多尺度注意力机制。

尽管如此，ViT 模型代表了计算机视觉领域的最新进展，为研究人员理解和处理图像提供了新的视角。它超越了卷积神经网络的局限性，为处理大尺寸图像和长序列数据提供了一种新的方式。未来，随着 ViT 模型的进一步发展和改进，相信它将在更多领域展现出惊人的应用潜力。

总结起来，ViT 模型通过引入自注意力机制和位置编码，实现了图像分类任务中的突破。它能够克服传统卷积神经网络在处理大尺寸图像和长序列数据时的限制，并具有较强的泛化能力和较低的计算复杂性。

也有学者提出的一个新颖的解决方案指出，在之前的大多数研究中，传统 ViT 的计算太消耗内存，利用表征特征从教师回归到学生，作为一对一的空间匹配，可以降低开销，然而，由于架构的差异，研究人员需要更加关注这一点。空间位置可以根据

中国知网 https://www.cnki.net

其位置而具有不同的语义信息。因此，一对一蒸馏方法受到极大破坏。通过 Target aware Transformer（TaT）一种新颖的知识提取方法被提出，称为一对所有空间匹配[46]。该方法允许将教师特征的每个像素转换为学生特征的所有空间位置，考虑它们之间的相似性。在他们提出的方法中，使用参数相关性将教师的特征提取为所有学生特征，即，提取损失是所有学生特征的加权总和。使用 Transformer 结构，他们重建了每个学生特征组件，并将其与目标教师特征对齐。因此，提出的方法被命名为 TaT。所提出的方法面临的一个关键挑战是，由于它计算了特征空间位置之间的相关性，因此在大型特征地图的情况下，它很可能变得难以处理。为了克服这一问题，以分层两步的方式扩展了管道，如图 2-10 所示。

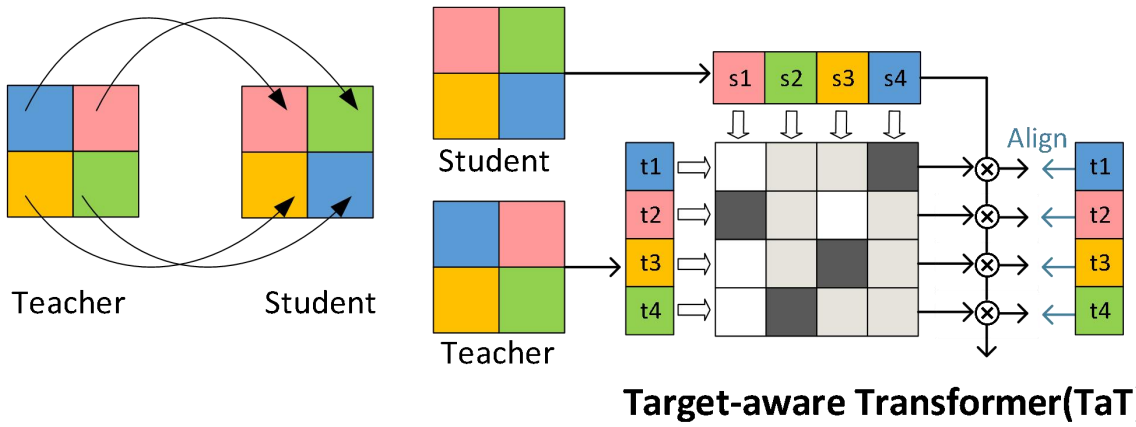


图 2-10 TaT 算法介绍

特征图被分成几个块，在每个块中，一对一地进行提取，而不是使用所有空间位置的相关性；他们将补丁中的特征平均为一个向量，以提取知识。对于特征对齐，使用 TaT 将教师和学生模型特征转换为相似的特征空间。

2.4本章小结

本章主要介绍了类风湿关节炎医学影像诊断的基础知识。深入探讨了常用的影像诊断技术和方法，包括卷积神经网络、深度学习 ViT 模型以及基于 ViT 模型的优化网络。通过对每种技术的详细介绍和分析，发现它们在类风湿关节炎诊断中各具优势和局限性。这一章的内容为后续章节提供了基础和参考，有助于读者深入理解类风湿关节炎医学影像诊断的现状与发展趋势。

中国知网 https://www.cnki.net

3 基于深度学习的 RA 图像诊断模型

3.1 引言

近年来，深度学习在医学影像领域的应用取得了重大进展，尤其是卷积神经网络（CNN）在图像分类、图像配准、图像分割和图像去噪等任务中表现出了优异的性能。还有一些相关工作使用基于 SvH 方法的 CNN 来诊断 RA 的损伤程度。

一种常用的基于关节水平的方法是使用两步策略检测手指关节损伤：第一步是关节检测任务，第二步是使用 CNN 对每个关节分别评分，然后将关节评分相加得到最终的 SvH 评分，如图 3-2。虽然这些模型在一些结果中表现出了令人印象深刻的性能，但在临床应用中仍有不足之处。主要原因是评分系统需要对特定位置进行评估，而准确检测这些位置具有挑战性。有些位置非常接近，即使检测到一个位置，也不容易消除其他位置的影响，尤其是在手腕部位。此外，严重红斑狼疮患者的手部关节可能是交错的，这也增加了正确检测的难度。为了避免这些问题。

另一种基于图像水平的方法是直接在整个手部或足部 X 光片上训练模型以预测整体 SvH 评分，这种方法相对简单，但在捕捉关节位置、骨间距离等关键局部信息方面具有挑战性，如图 3-1。然而，RA 的病理表现是滑膜组织疯狂生长，侵蚀关节位置的软组织，导致骨间距离不断缩小。因此，这些信息对 RA 的诊断至关重要。此外，缺乏公开可用的数据集也是该领域面临的最大挑战。直到 2022 年，Wang 等人才提供了唯一公开的以 SvH 标准评估的 RA 手部影像学数据集[47]。然而，这个数据集并不能直接使用，数据缺失严重，而且训练集和测试集的划分标准也没有明确定义。

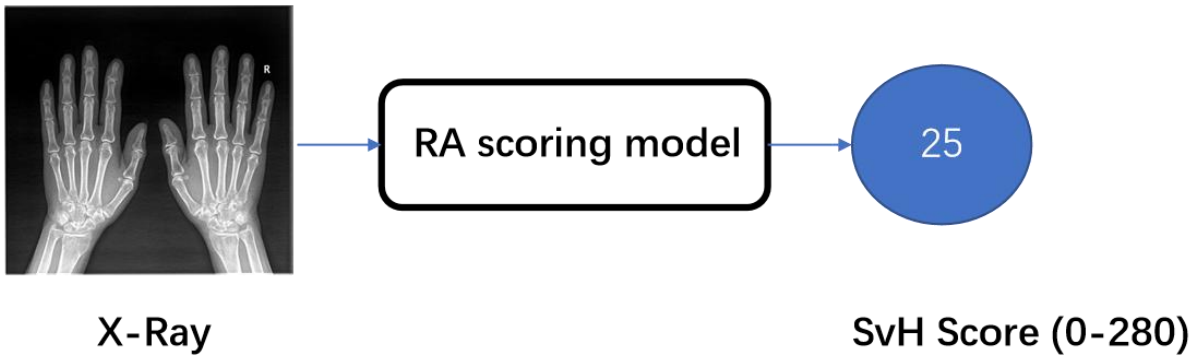


图 3-1 基于图像水平的损伤诊断

中国知网 https://www.cnki.net

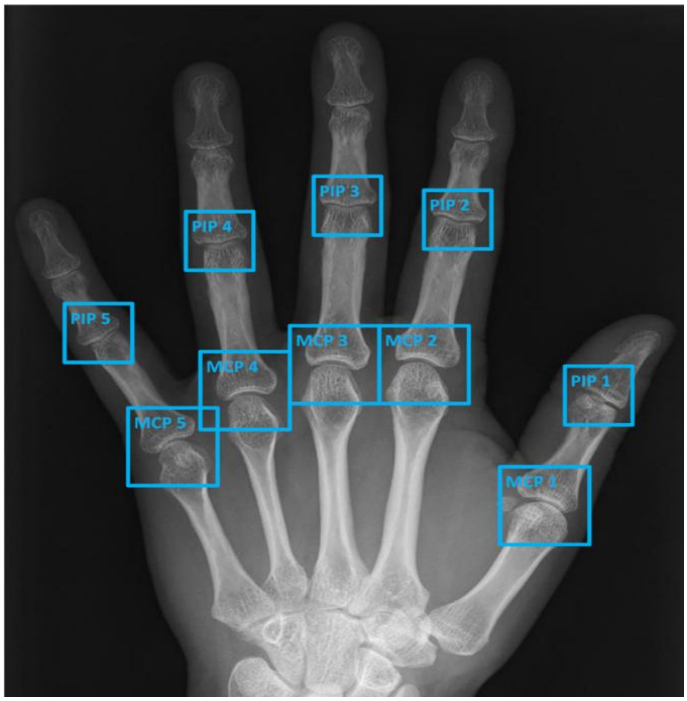


图 3-2 基于关节水平的损伤诊断

为了解决上述问题，本文提出了轻量级特征提取模块 LTransformer，它能捕捉 RA 手部图像的局部信息，从而让网络更加关注图像的关键特征，如关节位置和关节空间，并抑制无关区域的干扰。此外，还能凭借 Transformer 本身对远距离像素点之间关系的敏感度，获取更完整的特征信息。在此基础上，本文将 LTransformer 与 ViT 相结合，并引入密集相对定位（Drloc）自监督模块来增强模型的位置学习能力，构成了本文的模型 RAViT。这改善了直接通过整只手的 X 光片评估 RA 手部损伤时，不易学习到 RA 手部损伤中存在的局部关键信息和远距离像素点关系的问题，实现了更高效、更准确的预测结果。针对数据集存在的问题，Wang 等人指出，虽然提供了 3818 张 RA 图像，但只有 2849 张被公开。这使得其他研究人员无法与文章进行比较，这是很遗憾的。因此，本文对原始数据集进行了预处理，剔除了重复数据和缺失数据，并根据分层抽样原则划分了训练集、验证集和测试集。将处理后的数据集上传到 Git Hub，公开发表，供更多类风湿性关节炎学者交流和比较，这是一项非常有意义的开创性工作。本文的主要研究内容为以下几点：

（1）自动化 RA 诊断模型的设计

本课题的首要目标是设计和实现一种自动化 RA 诊断模型，以便为医生提供更快速和准确的诊断工具。RA 是一种慢性疾病，对关节和周围组织造成损害，早期诊断对于及时干预和治疗至关重要。本文将整合医学领域的知识，以自动检测 RA 骨损伤的迹象，从而提供早期诊断的机会，有助于改善患者的生活质量。

引入 Vision Transformer（ViT）模型作为深度学习架构的一部分，以提高对 RA 骨损伤的准确性和可解释性。传统的卷积神经网络在图像分类和特征提取中表现出色，

中国知网 https://www.cnki.net

但它们对全局信息的理解有限。通过引入 ViT 模型来设计一种更高效的 RA 骨关节损伤诊断模型，从而使模型可以学习到距离较远的图像之间的信息，进而提高 RA 损伤诊断的准确性。本研究将选择适当的 ViT 架构，将其应用于 RA 骨损伤检测任务，并使用收集的医学数据集对模型进行训练。模型的训练将包括监督学习和自监督学习任务，以提高模型的泛化能力。

（2）轻量级特征提取模块 LTransformer 的设计

由于传统的 Transformer 中计算的时间和内存复杂度随着输入图片分辨率的大小呈二次增长。对于 W×H 像素的图像，复杂度为 O（W^2H^2）。因此，使用传统的自注意机制来计算高分辨率（1024×1024）RA 图像任务是不现实的。本文需要设计新的模块 LTransformer，旨在提高特征提取的速度和效率，以便更快地对 RA 骨损伤进行识别。LTransformer 将具有线性复杂度的自注意力机制，这将显著降低系统的时间和内存开销，从而提高 RA 特征的识别速度。LTransformer 模块的设计需要精心的权衡，以确保在速度和准确性之间取得最佳的结果。本文将优化自注意力机制，以充分利用图像中的相关信息，同时减少计算成本。模块的实现将包括模型构建、参数调整和性能优化。

（3）引入轻量化的通道注意力机制

引入一种轻量化的通道注意力机制，以弥补 Transformer 模型在处理图像时缺乏的通道之间特征融合的能力。这一机制的设计旨在提高模型对图像中结构性信息的理解，以进一步提高 RA 骨损伤的诊断准确性。轻量化的通道注意力机制的设计将包括对图像特征的空间关系进行建模，并引入适当的注意力权重。这将有助于模型更好地理解图像中的关节结构和异常特征。本文将通过实验来验证该机制的有效性，以确保它能够在 RA 诊断中提供更全面和准确的信息。

（4）自监督学习的引入

引入自监督学习方法，以应对数据集不足的挑战。由于可获得的 RA 数据集十分稀少，会导致模型无法得到很好的训练，所以本文采用自监督学习技术设计出一个监督与自监督学习相结合的模型，来解决该领域数据集较少的问题。通过各种实验来验证自监督学习方法的有效性，以确保它能够提高模型的鲁棒性和性能。

3.2 实验数据和评价指标

该领域的数据很难获取，直到 2022 年 Wang 等人才提供了目前唯一公开的标有 SvH 评分的 RA 手部数据集。本文实验使用的就是他们提供的带有 SvH 评分的 RA 双手 X 光片数据集，如图 3-3。该数据集包含 RA 双手的 X 光图像，每张图像都标有表示关节炎严重程度的 SvH 分数。然而，该数据集既不完整也未分区，因此无法将其与原始论文进行直接比较。为了解决这个问题，本文对原始数据集进行了处理，删除了重复数据和缺失数据，选择了有标记的数据对，得到了 2849 个有效数据集。数据集的

中国知网 https://www.cnki.net

划分将直接影响最终的实验结果。如果每个研究人员对公开的未分割数据集的分割方式不同，实验结果就没有可比性。因此，本文按照分层抽样的原则将其分为 2179 个训练集、546 个验证集和 124 个测试集，以尽可能保持数据分布的一致性。数据集已经上传到 GitHub，以便学者们在相同的划分好的数据集上进行实验比较。



图 3-3 患者手部 X 光片

3.2.1 SvH 评分标准

在临床上，SvH 法是评估手部 X 光片 RA 的常用方法之一，也是经过验证的方法之一，该方法评估手部和腕部 15 个区域和足部 6 个区域的关节变窄情况 JSN（每个关节 0-4 分），以及手部和腕部 16 个关节区域（每个关节 0-5 分）和足部 6 个关节两侧（每个关节 0-10 分）的骨侵蚀情况，总分为 448 分。本文的实验只针对患者双手进行 SvH 方法评估手部 RA 损伤情况，因此总分范围为 0 至 280 分，0 分表示正常，分数越高表示该 RA 患者的手部损伤情况越严重。

本文的数据集存储在 RA 文件夹下，按照分层抽样的原则划分为 training，validation，testing 3 个文件夹，保证每一部分的样本分布情况大致相似，分别存储着用于训练，验证，测试的 X 光片数据集。数据集中所有图片统一命名为 DX3317.jpg 的形式，如图 3-4。

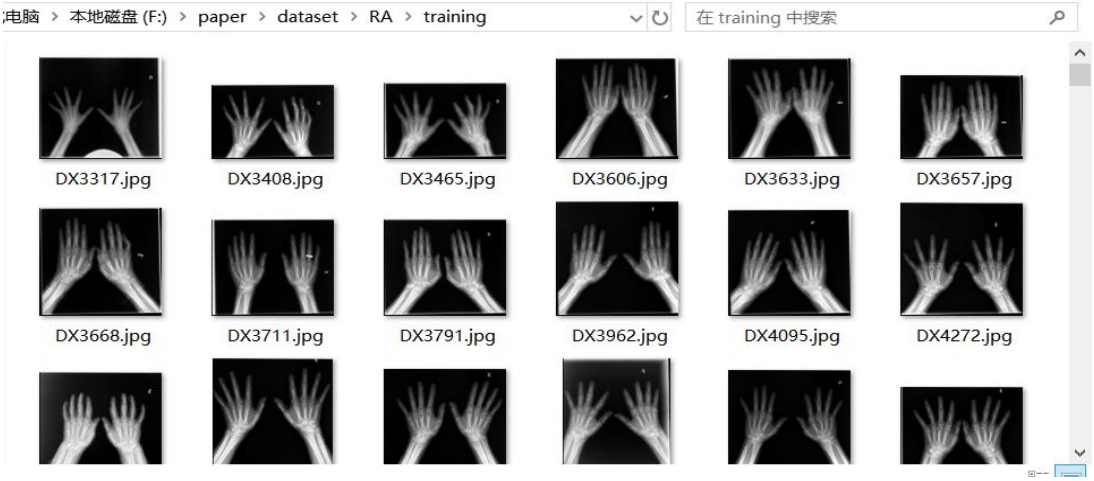


图 3-4 training 文件夹（训练集）中的 RA 手部 X 光片

中国知网 https://www.cnki.net

在 RA 文件夹下还有一个名为 data 的文件夹，里面存放着 data.csv 文件，是所有 X 光片对应的标签，即 SvH 分数的真值，如图 3-5。

	A	B	C	D
1	exam_numb	gender	age	score_avg
2	230259	F	73	264
3	42566	F	62	259.5
4	394385	F	45	253
5	416527	F	56	250.5
6	440941	F	65	250
7	46657	F	33	247.5
8	353773	F	64	243
9	237308	F	51	236
10	41363	F	51	235
11	353170	F	68	234.5
12	249317	F	66	231.5
13	317715	M	70	231.5
14	354359	F	77	229.5
15	37809	F	47	229.5
16	43858	F	66	227.5
17	435078	F	57	226.5
18	44922	F	42	226
19	42313	F	52	225.5
20	410376	F	50	223
21	251909	F	50	222.5
22	305680	F	45	222

图 3-5 data.csv 文件中存储的记录

其中，exam_numb 字段和 X 光片命名相对应。例如 230259，对应 DX230259.jpg 这张 X 光片。gender 字段表示患者性别，F 为女性，M 为男性。age 表示患者的年龄。Score_avg 表示的就是最为关键的 SvH 评分，范围为 0-280 之间。由于该数据集的 SvH 真值分数是由两位类风湿科的医生给出，然后取平均值的，所以会出现带有小数的情况。图 3-6 显示了整个数据集中不同 SvH 评分的频率分布情况，可以看出数据集中评分为 0，即没有类风湿关节炎和评分较低，即 RA 病情不严重的数据样本较多，而评分较高，即 RA 病情严重的样本比较稀缺。

中国知网 https://www.cnki.net

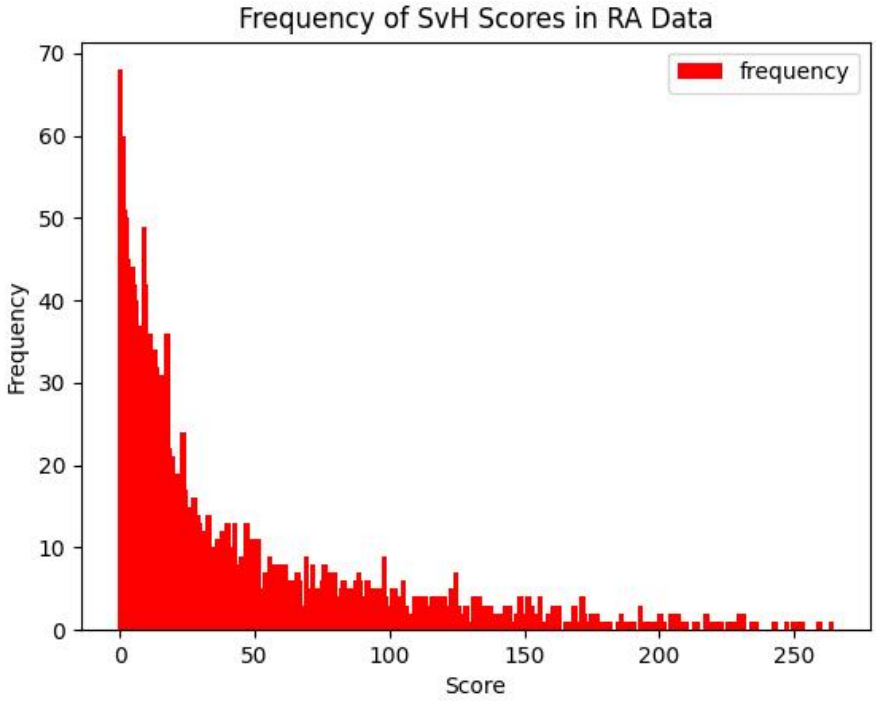


图 3-6 数据集 SvH 分数的频率分布情况

3.2.2 数据增强

为了提高模型在不同场景下的性能，本文对训练数据进行了一些变换，如旋转、缩放、裁剪等，以丰富训练数据。当医学图像数据稀疏且难以标记时，这种技术尤其有效。在数据预处理中使用数据增强以提高模型的鲁棒性，尤其是在标注的医学图像数据不足的情况下，可以使模型在训练集、验证集以及测试集中的表现相差不大。具体步骤如下：

（1）将所有图像大小统一调整为 1024 ×1024；

（2）从调整后的图像中随机取样将其水平翻转；

（3）随机改变裁剪图像的亮度、对比度和饱和度，并将其概率全部设置为 0.1；

（4）随机将图像旋转一个给定的角度：[0°, 90°, 180°, 270°]；

（5）用训练数据计算出的平均值和标准偏差对张量图像进行归一化处理，并使用 z-score 归一化处理标签值。

课题研究数据集的评分分布大致呈指数分布。一开始本文尝试直接使用这些分数进行训练，但是发现模型很难收敛。因此，在将分数输入到网络之前，对其进行了标准化处理。本文选择了 z-score 方法对分数进行标准化，取得了不错的效果，训练能够稳定收敛。

中国知网 https://www.cnki.net

3.2.3 评价指标

本课题使用了两个指标：平均绝对误差（Mean Absolute Error，MAE）和均方根误差（Root Mean Squared Error，RMSE）来评估模型性能。这两个指标是 RA 骨损伤评估任务中最常用的评估指标，能有效反映模型预测的 SvH 评分与标签真实值之间的误差大小。

(1) 平均绝对误差

平均绝对误差 MAE 是一种常见的回归模型评价指标，用于衡量模型预测结果与真实结果之间的平均绝对误差。MAE 的计算方法如下：

$$\mathrm{MAE} = \frac{1}{\mathrm{N}}\sum_{\mathrm{i}=1}^{\mathrm{N}} |\mathrm{y_i} - \hat{\mathrm{y}}_\mathrm{i}| \qquad (3-1)$$

式中 N 代表样本个数；y_i表示样本的标签，即真实值；$\hat{y}_i$为模型对样本的预测值。

(2) 均方根误差

均方根误差 RMSE 是一种常用的图像评价指标，用于比较数据之间的相似度。它代表了模型预测值与真实值之间的平均根误差。RMSE 的计算方法如下：

$$\mathrm{RMSE} = \sqrt{\frac{1}{\mathrm{N}}\sum_{\mathrm{i}=1}^{\mathrm{N}} (\mathrm{y_i} - \hat{\mathrm{y}}_\mathrm{i})^2} \qquad (3-2)$$

式中 N 代表样本个数；y_i表示样本的标签，即真实值；$\hat{y}_i$为模型对样本的预测值。

MAE 衡量预测误差的绝对值的平均，消除了正负误差的抵消；而 RMSE 则计算了预测误差的平方的平均再开平方，对大误差进行了放大并进行惩罚。在计算 MAE 和 RMSE 时，需要将真实值和预测值一一对应，然后计算误差并取平均。通过比较 MAE 和 RMSE 的大小，可以评估模型的准确性和可靠性，MAE 和 RMSE 的值越小，均代表模型预测结果与真实结果之间的误差越小，说明所提出的模型越准确可靠。

3.3RAViT 分类网络模型

3.3.1 RAViT 结构

本文所提出的 RA 手部骨损伤自动诊断模型 RAViT 的整体网络结构如图 3-7。该网络是基于 ViT 模型进行优化的，整体流程与 ViT 模型相似，主要优化的是其核心 Transformer 特征提取模块和自监督学习任务 Drloc 模块的引入。

中国知网 https://www.cnki.net

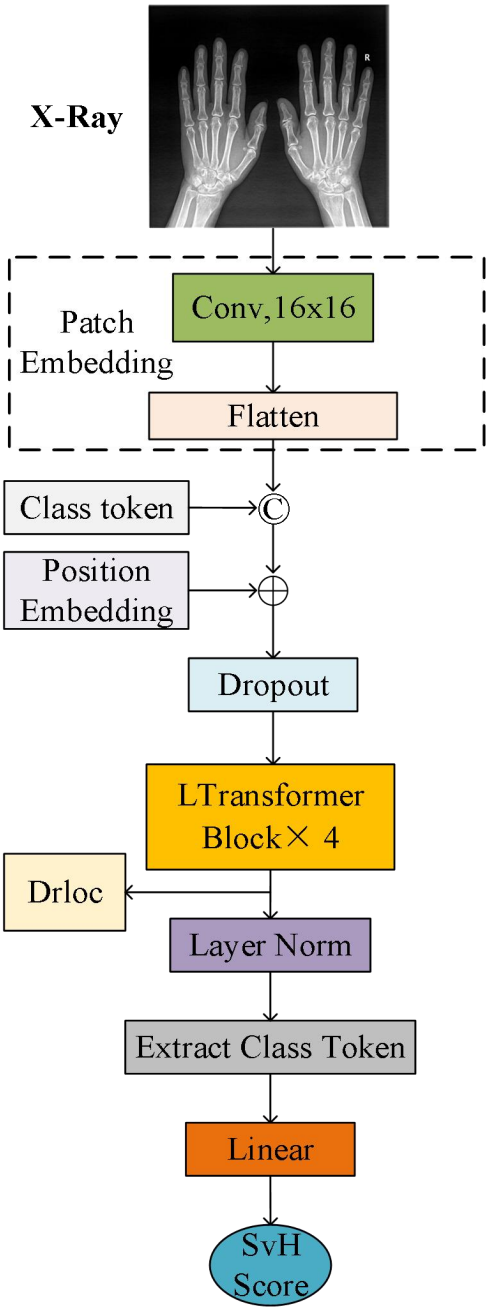


图 3-7 RAViT 网络结构

在本文的 RAViT 模型中，输入图像首先被 Patch Embedding 层分割成多个补丁。然后，每个补丁被映射成一个固定长度的向量。具体来说，RAViT 会将分辨率为 H×W×C 的图像转换为 N×(P^2× C)的序列，其中 H×W 是原始图像的分辨率，C 是通道数，P×P 是每个图像补丁的分辨率。N = HW/P^2是得到的补丁数，也是 LTransformer 的有效输入序列长度。然后，对每个 (P^2×C) 的图像块进行线性变换。在每个序列的开头添加一个特殊的类标记。该类标记与图像块一起通过 LTransformer 模块。在经过所有 LTransformer 模块后，得到的输出特征一边会经过 Drloc 模块进行自监督任务的学习来帮助模型的训练；另一边只关注类标记的输出，这一输出被输入 MLP 分类器，

中国知网 https://www.cnki.net

完成最终分类任务。所提出模型还加入了位置编码。位置编码可以理解为一个总共有 N 行的表格；N 的大小与输入序列的长度相同，每一行代表一个向量；向量的维度等于输入序列嵌入的维度。然后，经过 4 个用于特征学习的 LTransformer 模块后，与类标记相对应的输出将作为最终输出，经过特征提取后，模型将图像的特征向量传递给一个层归一化模块，该模块是一种神经网络正则化技术，旨在增强深度神经网络的训练和泛化能力。接着通过全连接模块，将学习到的各种特征进行整合，用于进一步分类，用均方根误差（RMSE）损失函数对 SvH 分数进行分类预测。这一分类层将根据从图像中学到的特征将输入图像映射到 0-280 之间的分数，来表示患者手部骨损伤程度。这一预测结果可以用于医生的决策支持，从而促进早期诊断和干预。

3.3.2 LTransformer 模块实现

在本文的 RAViT 模型里，最核心改动的是对 Transformer 模块进行的优化，即本文提出的 LTransformer 模块。该模块由多头深度卷积转置注意力（Multi-Dconv Head Transposed Attention,MDHTA）和倒残差前馈网络（Inverted Residual Feed-forward Network,IRFN）两部分组成。

（1）MDHTA。原始 Transformer 模块中使用的是传统的自注意机制，在计算中会涉及三个值分别为查询（Q），键（K）和值（V）。简单来说，它通过计算 Q 和 K 的相关性，再将结果与 V 进行加权求和得到最终的注意力值。而 Q 和 K 需要通过点积来计算该相关性，这一步花费的时间和内存复杂度随着输入图片分辨率的大小呈二次增长。对于 W×H 像素的图像，复杂度为 O（W^2H^2），自注意力机制是 Transformer 的主要计算开销。因此，使用传统的自注意机制来计算高分辨率（1024×1024）RA 图像任务是不现实的。而本文设计的 LTransformer 模块在计算自注意力机制时具有线性复杂度。它的关键在于 MDHTA 中使用了转置注意力机制，应用跨通道的自注意力而不是空间维度的自注意力，通过计算跨通道的互协方差以生成隐式编码全局上下文的注意力图，大大降低了时间和内存的开销，实现了 RA 特征的快速提取。

然而，尽管自注意力机制有很大的感受野，可以处理全局特征，但它在局部特征处理方面存在着不足。因此，本文还引入了深度卷积来丰富局部特征信息，并在计算特征协方差生成全局注意力图之前强调局部上下文。与普通卷积相比，它还可以显著降低计算成本。在此之前，添加了一个 1×1 的卷积来扩展通道。这确保了后续计算可以获得通道上的更多特征。MDHTA 模块具体过程如图 3-8 所示：

中国知网 https://www.cnki.net

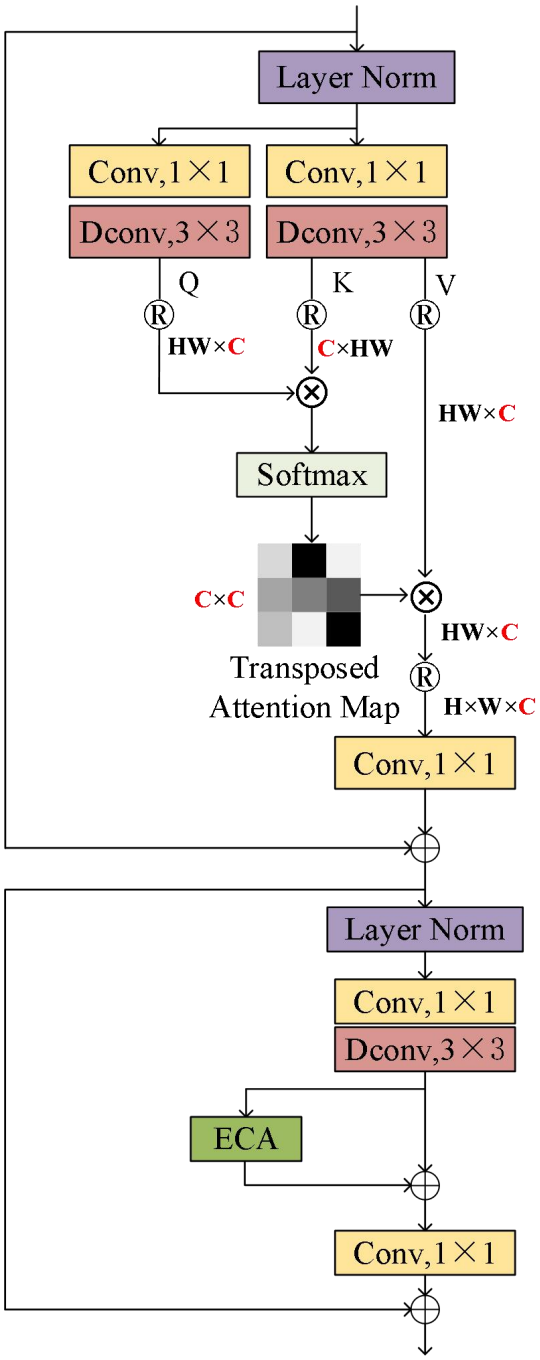


图 3-8 LTransformer 结构

① 输入进来的图像特征 $Y \in R^{H \times W \times C}$,首先经过层归一化模块（Layer Norm,LN），该正则化技术可以增强深度神经网络的训练和泛化能力。

② 利用转置注意力机制替代原始的自注意力机制。通过应用 1×1 卷积来汇聚像素级的跨通道上下文，然后通过 3×3 深度卷积来编码通道级的空间上下文，生成查询（Q）、键（K）和值（V）的投影，得到 $Q=W_d^Q W_p^Q Y$, $K=W_d^K W_p^K Y$ 和 $V=W_d^V W_p^V Y$。其中 $W_p^{(\cdot)}$ 是 1×1 卷积，$W_d^{(\cdot)}$ 是 3×3 深度卷积。

中国知网 https://www.cnki.net

③ 接下来，通过®模块重新整形 Q,K,V 的投影，得到新的$\widehat{Q}\in R^{HW\times C}$，$\widehat{K}\in R^{C\times HW}$，$\widehat{V}\in R^{HW\times C}$，方便接下来生成转置注意力图。

④ 对$\widehat{K}$和$\widehat{Q}$进行点积计算操作，经过 softmax 归一化指数函数，交互生成一个大小为 $R^{C\times C}$ 的转置注意力图（Transposed Attention Map），而不是巨大的常规注意力图 $R^{HW\times HW}$。接着将生成的转置注意力图与$\widehat{V}$进行点积计算，得到注意力特征 Attention($\widehat{Q}$,$\widehat{K}$,$\widehat{V}$)，该过程定义如下：

$$\text{Attention}(\widehat{Q},\widehat{K},\widehat{V}) = \widehat{V} \cdot \text{Softmax}(\widehat{K} \cdot \widehat{Q} / \alpha) \qquad (3-3)$$

式中 α 是一个可学习的缩放参数，用于在应用 softmax 归一化指数函数之前控制 $\widehat{K}$ 和 $\widehat{Q}$ 的点积的大小。

⑤ 注意力特征 Attention($\widehat{Q}$,$\widehat{K}$,$\widehat{V}$) 通过®模块重新整形为 $H\times W\times C$。

⑥ 再经过 1×1 卷积W_p，最后使用了残差连接，加上了输入特征 Y，这种连接能够解决梯度消失问题、加速训练、提高网络性能和允许更深的网络来改进深度学习模型的训练和性能。该过程定义如下：

$$\hat{Y} = W_p\text{Attention}(\widehat{Q},\widehat{K},\widehat{V}) + Y \qquad (3-4)$$

式中 Y 是输入 LTransformer 模块之前的特征，$\hat{Y}$ 则是经过 LTransformer 模块处理后的输出特征。

（2）IRFN。倒残差前馈网络 IRFN 是本文设计的 LTransformer 模块中另外一个重要部分。原始 ViT 模型中的前馈网络（Feed-forward Network,FFN）是由两个线性层组成，中间有一个 GELU 激活函数。初始层将维度扩大了四倍，而后续层则将维度缩小了相同的倍数：

$$\text{FFN}(F) = W_\beta\text{GELU}(W_\alpha F + b_\alpha) + b_\beta \qquad (3-5)$$

式中W_α和W_β表示两个线性层的权重；GELU 为激活函数；F 为经过 MDHTA 模块后的特征；b_α和b_β表示偏置项。

本文在原始的 FFN 基础上提出了一种倒残差前馈网络（IRFN），它类似于倒残差块[48]。该块由一个扩展层、一个深度卷积层和一个投影层组成。本文修改了跳跃连接的位置以提高性能并且引入了高效的通道注意力机制（Efficient Channel Attention,ECA）

中国知网 https://www.cnki.net

来弥补 Transformer 在通道维度上缺少特征信息交互的缺点，进一步提高 RA 骨损伤诊断的准确性。其结构如下图 3-9。

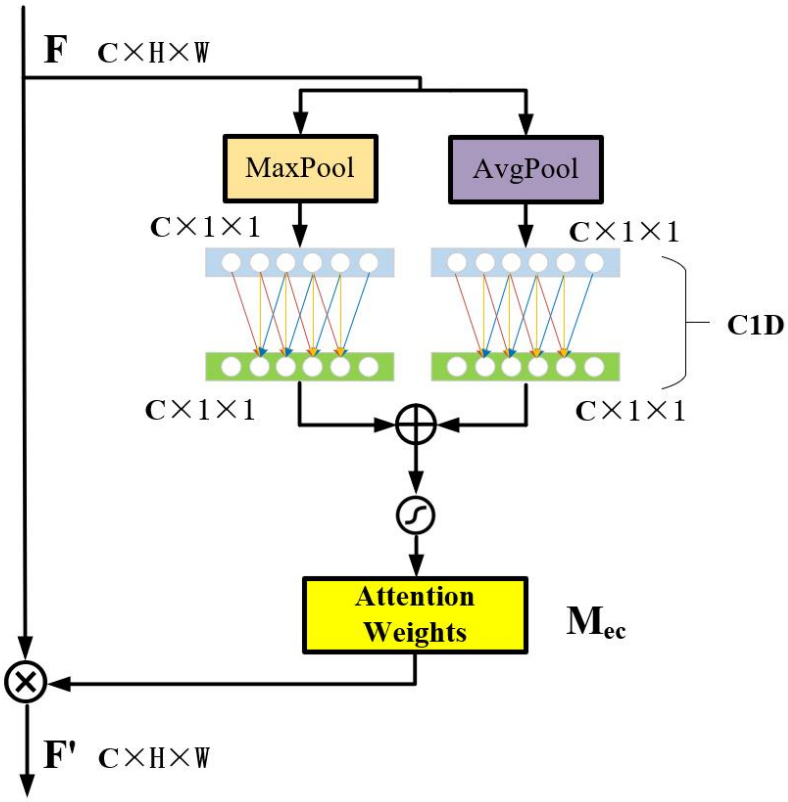


图 3-9 ECA 结构

本文的高效通道注意力 ECA 模块压缩了输入特征图的空间维度以聚合空间信息，同时使用平均池化和最大池化特征，大大提高了网络的表示能力。大多数通道注意力则通过多层感知器（MLP）的隐层来减少参数开销，其中隐激活大小设置为$R^{C/r\times1\times1}$，其中 r 为缩放率，通常设置为 16。虽然这降低了模型的复杂度，但却破坏了通道与其权重之间的直接对应关系，而且先降维后增维的做法会使对应关系变得间接，从而导致信息丢失。为了解决这个问题，本文使用一维卷积方法代替共享 MLP，以减少降维对数据的影响。下面将介绍具体的操作：

首先通过平均池化和最大池化操作来聚合特征图的空间信息，生成两种不同的特征： F^{ec}_{avg} 和 F^{ec}_{max}，分别代表平均池化特征和最大池化特征。然后分别对这两个特征进行自适应一维卷积 C1D 处理，从而在不损失维度的情况下生成高效的通道注意力映射。最后，使用对应元素求和的方法将两者结合起来，并使用 Sigmoid 激活函数在（0-1）之间映射权重，从而得到注意力权重 $M_{ec}\in R^{c\times1\times1}$。ECA 通道注意力的计算方法如下：

中国知网 https://www.cnki.net

$$\begin{aligned} M_{ec}(F) &= \sigma\left(C1D_a\left(AvgPool(F)\right) + C1D_b\left(MaxPool(F)\right)\right) \\ &= \sigma\left(C1D_a\left(F_{avg}^{ec}\right) + C1D_b\left(F_{max}^{ec}\right)\right) \end{aligned} \quad (3-6)$$

式中，σ 表示 sigmoid 激活函数。$C1D_a$ 和 $C1D_b$是两个相互独立的自适应一维卷积，输入通道为 1，输出通道为 1，内核大小为 k，填充为 k/2 向下取整。高效通道关注模块通过自适应卷积核大小计算通道权重，它只根据输入通道数 C 计算 k，无需额外参数。假定输入通道维数为 C，内核大小 k 可以通过以下公式自适应确定：

$$k = \varphi(C) = \left|\frac{\log_2(C)}{\alpha} + \frac{\beta}{\alpha}\right|_{odd} \quad (3-7)$$

式中的 α 和 β 在本文的实验中分别设置为 2 和 1。利用非线性映射，映射 φ 允许高维信道有较长的交互范围，而低维信道有较短的交互范围。这样，所提出的高效通道注意力 ECA 模块就能根据输入通道的维度自适应地调整卷积核大小，从而实现通道间的有效交互。

3.3.3 自监督学习方法

自监督学习是一种机器学习范式，它利用数据本身的结构或属性来进行训练，而无需人工标注的标签。在自监督学习中，模型被要求预测数据的某些属性，这些属性可以是数据本身的一部分，也可以是与数据相关的其他信息。自监督学习的目标是通过最大化模型的预测准确性来学习数据的表示，从而使得模型能够学习到数据中的有用特征。

在医学影像领域，自监督学习方法已经得到了广泛的应用。其中一种常见的应用是利用医学影像数据中的空间和时间信息来预测图像中的结构、病变或疾病状态。例如，可以使用自监督学习方法来训练模型，使其能够根据患者的医学影像数据来预测其患病的风险或诊断结果。

另一个常见的自监督学习应用是利用医学影像数据中的局部特征和全局结构来学习影像的表示。通过设计适当的自监督任务，可以使模型学习到影像中不同区域之间的关联性和语义信息，从而更好地捕获影像中的有用特征。

最近引入的一种自监督学习任务是密集相对定位（Dense Relative Localization，Drloc）。在这个任务中，模型被要求预测医学影像中的不同区域之间的相对位置关系。通过训练模型来预测这些相对位置关系，可以使模型学习到医学影像中不同结构之间的准确空间位置，从而提高影像分析和诊断的准确性，另一方面也缓解了医学数据较少的问题。

总的来说，自监督学习方法为医学影像分析提供了一种有效的方式，可以利用数据本身的特征来训练模型，从而减少对大量训练数据集的依赖，提高医学影像分析的

中国知网 https://www.cnki.net

效果和性能。密集相对定位作为一种新兴的自监督学习任务，为医学影像中的结构定位和分析提供了新的思路和方法。

在本文设计的 RAViT 中也引入了该自监督学习任务 Drloc，有效地增强了模型的鲁棒性，特别是在面对数据稀缺的情况下。这一方法将在后续研究中得到更详细的验证和优化。本文将进一步探索不同自监督学习方法的潜力，以提高模型的性能。其结构如图 3-10:

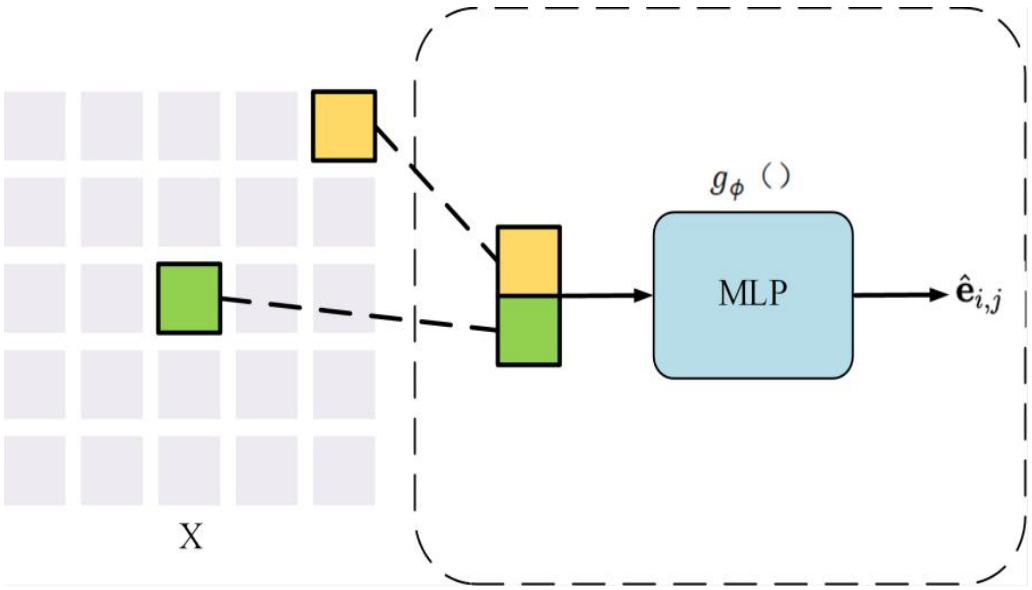


图 3-10 Drloc 结构

Drloc 模块通过对每幅图像的多个嵌入对进行密集采样，并要求网络猜测它们之间的相对距离，从而实现额外的位置信息自监督学习。该定位任务由两个主要部分组成：位置编码和位置预测。

位置编码的过程是：首先，将图像划分为 H×W 的均匀块，并将每个块的中心坐标归一化为 [-1, 1] 的范围，得到 $P_{i,j}$；然后，使用正弦函数对每个块的相对位置进行编码，得到 H×W×2 的张量 $e_{i,j}$：

$$P_{i,j} = (\frac{2i}{H} - 1, \frac{2j}{W} - 1) \quad (3-8)$$

$$e_{i,j} = (\sin(\frac{\pi}{2}P_{i,j}), \cos(\frac{\pi}{2}P_{i,j})) \quad (3-9)$$

式中 i，j 代表选取点的行列值；$P_{i,j}$为坐标归一化后的坐标；H×W 为输入特征的高度跟宽度；$e_{i,j}$为经过编码后的选取点的坐标。

中国知网 https://www.cnki.net

位置预测的过程是：首先，将图像输入模型并提取最后一层的特征向量；然后，使用 MLP 将特征向量映射到相对位置的预测值，得到一个 H×W×2 张量 $\hat{e}_{i,j}$；最后，使用 L1 损失函数优化模型参数：

$$\hat{e} = g_{\emptyset}(x) \tag{3-10}$$

$$L_{drloc} = \frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W}\left[\left|\hat{e}_{i,j} - e_{i,j}\right|\right] \tag{3-11}$$

式中$\hat{e}$是模型预测的选取点的坐标值；x 是最后一层的特征向量；$g_{\emptyset}$是 MLP 层；L_{drloc}为 Drloc 任务中定义的损失函数值。

本文模型的标记监督学习本身使用 RMSE 损失函数，它反映了预测值与真实值之间的误差程度，因此能更好地指导梯度下降后模型参数的更新。其定义如下:

$$L_{rmse} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2} \tag{3-12}$$

式中L_{rmse}为监督学习的训练损失函数，RMSE 损失函数越小，所提出的模型就越精确；N 为样本数；y_i 为样本的标签，即真实值；$\hat{y}_i$ 为模型对样本的预测值。最终，Drloc 中的 L_{drloc} 将被添加到标准监督下的网络原生损失L_{rmse}中。整个模型的最终联合损失为:

$$L_{all} = L_{rmse} + \lambda L_{drloc} \tag{3-13}$$

式中，λ 为调节 Drloc 任务比重的参数，在本文的实验中为 0.1，它们共同作为正则化项来调节模型训练。

3.4 实验结果的定量比较

本文在 Wang 等人提供的带有 SvH 评分的 RA 双手 X 光片数据集上验证了所提出的方法。使用 PyTorch 1.11.0 框架来开发本文的模型，并在单个英伟达 RTX 3090Ti GPU 上进行了训练。本文采用随机梯度下降作为优化器，初始学习率为 0.001，权重衰减为 0.001，动量为 0.9。为了更好地评估实验中图像的 SvH 分数，所有图像的大小都调整为 1024×1024 分辨率。训练模型时 LTransformer 块的数量设置为 4，批量大小为 16，最大迭代次数为 1000。

中国知网 https://www.cnki.net

表 3-1 列出了 Wang 等人在其公开原始数据集上的实验结果，模型带*的为原论文的实验结果。然而，该公开的数据集存在一些问题，该数据集既不完整也未给出训练集，验证集及测试集的划分，这些问题使得本文无法直接与该论文的实验结果进行比较。因此，本文的实验结果是在经过处理后的数据集上获得的，详情见 3.2 实验数据和评价指标这一小节的内容。在处理过的数据集上，本文的模型取得了 12.86 的 MAE 和 17.60 的 RMSE，这是目前最优的实验结果。2022 年 Wang 等人发表了唯一一篇关于该公共数据集的研究论文，他们 ResNet-Dwise50 模型的 MAE 和 RMSE 分别为 13.13 和 19.02，这些都是在处理后的数据集上的实验结果。可以看到，该实验结果比他们在原始数据集上（带*）14.90 的 MAE 和 22.01 的 RMSE 结果更好，也说明了本文对该数据集的处理是很有效的，去除了一些重复，冗余以及缺失的数据，并按照分层抽样的原则划分了数据集，使得训练集，验证集以及测试集的数据分布情况大致相同，这有利于模型的学习过程。本文也将处理后的数据集发布在 GitHub 上，供广大学者进行学习比较，链接如下:https://github.com/ldy07/RA-Dataset。

表 3-1 不同网络预测 SvH 分数的对比

Model	MAE	RMSE
MobileNetV2*[48]	15.70	22.89
ResNet50*[44]	15.32	22.58
ResNet-Dwise50*[47]	14.90	22.01
MobileNetV2	14.02	20.18
ResNet50	13.57	19.69
ResNet-Dwise50	13.13	19.02
ViT-B/16[36]	19.07	26.38
ConvNeXt-B[49]	20.53	28.4
Ours	**12.86**	**17.60**

尽管在自然图像领域有许多新的、高效的模型，但由于类风湿关节炎领域深度学习应用进展较慢，目前还停留在用一些经典的模型进行 RA 骨损伤的评估任务。相关论文研究也比较少，本文对该领域近几年的研究进行了梳理和汇总，具体情况如表 3-2。可以看出，该领域使用的模型相对比较经典，也没有开源的模型，而使用的数据集大多是与医院类风湿科合作获取的临床病人数据，由于敏感性和涉及隐私等问题很难公开，导致该领域进度一直比较缓慢。直到 2022 年 Wang 等人在其论文里公开了该领域

中国知网 https://www.cnki.net

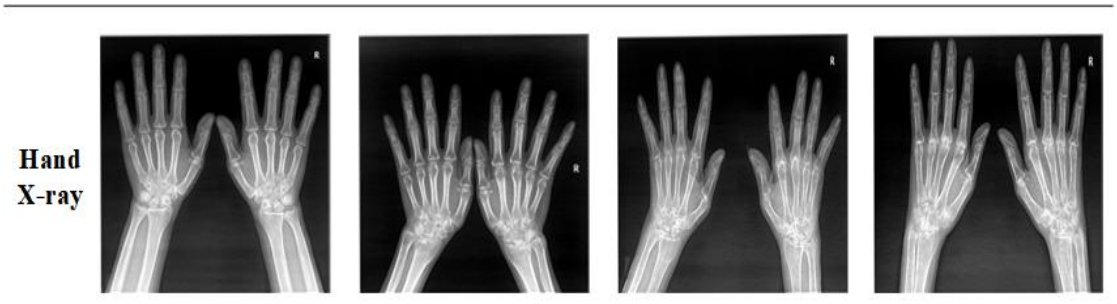
的一个数据集，在文中作者也声称这是目前唯一公开的标有 SvH 评分的类风湿关节炎手部数据集。

表 3-2 近几年类风湿关节炎领域的预测模型及开源情况

Author-Year	Backbone Network	Dataset	Code
Hirano et al.[17]-2019	CNN	No	No
Rohrbach et al.[18]-2019	VGG16	No	No
Mate et al.[50]-2021	CNN	No	No
Chaturvedi et al.[19]-2021	EfficientNet	No	No
Li et al.[20]-2022	U-Net	No	No
Wang et al.[47]-2022	ResNet-Dwise50	Yes	No

其中，Dataset 和 Code 列里，No 表示作者没有公开，Yes 表示作者公开了相关资源。

因此，本文的工作主要是与该数据集上目前的最优模型 ResNet-Dwise50 进行比较。在本文优化后的数据集上进行实验，结果表明所提出的模型比它的 MAE 低 2%，RMSE 低 7.4%，说明了本文的模型在预测 RA 手部骨损伤 SvH 评分的任务中精度更高。在图 3-11 中直观展示了四组样本图像和相应的标签值以及本文所提出模型的预测得分。不难看出，本文的方法可以很好得预测 SvH 分数，而且与标签的真实值差别不大。



G	10	73	115.5	199.5
P	7.5	86	127	185

图 3-11 四个手部 X 光片样本案例

其中，真值（G）显示的是样本的实际 SvH 值，预测值（P）显示的是本文所提出模型的预测分数。

中国知网 https://www.cnki.net

另外，本文也尝试将计算机视觉中自然图像领域里评分较高的模型应用于类风湿关节炎手部损伤评分的任务中，本实验中使用了 ViT-B/16 和 ConvNeXt-B 两个网络模型来预测 RA 手部 SvH 评分。结果表明 ViT-B/16 的 MAE 为 19.07，RMSE 为 26.38；ConvNeXt-B 的 MAE 为 20.53，RMSE 为 28.4。实验效果不是很理想，由于这是首次将自然图像里较新的模型应用在 RA 中，可能一些参数的设置不太合理等原因，本文将在后面的实验结果中分析讨论。

3.5 消融实验

为了进一步证明提出的 RAViT 模型各个组件的有效性，本文设计以下消融对比实验，如表 3-3，来验证本文提出的 LTransformer 模块和 Drloc 的有效性：

（1）本文将 ViT-B/16 模型中核心 Transformer 模块设置为 4 作为基线模型（Baseline,B），以便跟 RAViT 做对比；

（2）在基线模型 B 上使用本文提出的核心 LTransformer 模块作为特征提取模块，B+LTransformer；

（3）将 Drloc 模块引入基线模型 B 中，利用自监督的学习任务帮助模型训练，B+Drloc；

（4）同时在基线模型 B 中，使用核心 LTransformer 模块和自监督学习任务 Drloc，B+LTransformer+Drloc。

由于所提出的 RAViT 模型在设置核心 LTransformer 模块数量时，通过实验验证设置为 4 块时，预测的效果最好，所有基线模型 B 也同样将 Transformer 模块设置为 4。

为了使模型能够捕捉整个 1024 × 1024 尺寸手部 X 光胶片中细微的 RA 病理特征以及弥补 Transformer 模块缺少的通道间特征信息交互，本文优化了内存开销很大的自注意力机制，使用转置注意力来代替，同时加入了本文设计的 ECA 通道注意力，构成了模型的核心特征提取模块该模块 LTransformer，通过消融实验的验证，B + LTransformer 将 MAE 降低了 4.37，RMSE 降低了 5.75，表明它能使模型更加关注图像的局部特征，并聚焦于骨关节炎侵蚀和骨间距变窄等关键信息，同时也可以很好的捕获图像远距离像素点之间的关系，更好的提取 RA 特征。

另外，本研究首次在该领域引入自监督训练的方式来训练模型，一方面可以优化损失函数，结合监督学习的方式共同训练模型；同时可以在更充分得利用有限的数据集更好的训练模型。Drloc 模块就是一种自监督的定位任务，这种自监督学习与监督学习相结合的训练方式可以让模型获得更多的特征信息，从而提高其性能。单独添加 Drloc，即 B+Drloc 使 MAE 降低了 2.17，RMSE 降低了 4.33。这说明了在类风湿关节炎骨损伤评分的任务中，自监督的学习方式可以缓解该领域数据集较少的问题，更好得帮助模型训练。

最后同时添加这两个模块，即 B + LTransformer + Drloc 使 MAE 最终降低了 4.66，RMSE 降低了 6.47。实验表明，所提出的 RAViT 模型中的每个组件都在帮助提高模型

中国知网 https://www.cnki.net

性能方面发挥了重要作用，而且共同作用时产生了更好的效果，在预测 RA 手部骨损伤 SvH 评分的任务中取得了不错的进展。

表 3-3 消融实验

Model	MAE	RMSE
Baseline (B)	17.52	24.07
B + LTransformer	13.15	18.32
B + Drloc	15.35	19.74
B + LTransformer + Drloc	12.86	17.60

3.6 实验结果分析

实验结果表明本文设计的网络模型 RViT 在预测类风湿关节炎手部 X 光片 SvH 分数的任务中表现更为出色。在评估模型精度的 MAE 和 RMSE 两个指标上都超过了该唯一数据集上目前最优的模型 ResNet-Dwise50。在样本展示中，也可以看到本文模型预测的 SvH 分数与真实值很接近，对辅助医生进行临床诊断提供了强有力的帮助。本文还对 Wang 等人提供的原始数据集进行了优化和划分，并上传到 GitHub 上进行共享，致力于制作出该领域里第一个 SvH 评分的标准数据集，方便广大学者进行直接交流和比较，促进深度学习技术在该领域的发展。

近年来，计算机视觉领域取得了巨大的进展，特别是在自然图像识别方面。然而，本文在实验中，尝试将自然图像领域中评分较高的模型应用于类风湿关节炎手部损伤评分任务时，遇到了一些挑战。本文选择了 ViT-B/16 和 ConvNeXt-B 这两个先进的网络模型来预测类风湿关节炎手部 SvH 评分。然而，实验的评价指标并不乐观，这些结果远远超出了预期，说明了自然图像与医学影像之间还是有差别的，许多自然图像中表现优异的模型直接放到医学影像任务中往往表现不佳，还需要进一步进行优化和改进。有几个可能的原因导致了这种情况。首先，这是首次将自然图像领域较新的模型应用于类风湿关节炎领域，本研究可能没有正确地调整模型参数，使其适应这个特定的任务。其次，这些模型通常需要大量的数据来进行训练，但该领域目前只有 2000 多张图片，这可能导致模型没有得到充分的训练。另外，类风湿关节炎手部损伤评分可能具有自身的复杂性和特点，这些模型可能无法很好地理解和捕捉。此外，模型训练过程中可能存在其他因素，如过拟合或欠拟合等，也可能对结果产生影响。这些问题

中国知网 https://www.cnki.net

也是本课题接下来要继续研究并改进的方向。

总的来说，本课题设计了一种新的特征提取模块 LTransformer 替换原始的 Transformer 模块。在弥补了原本 Transformer 缺失的跨通道特征信息交互的同时，降低注意力图的计算开销。本文还引入了 Drloc 自监督学习任务，形成了本文所提出的网络模型 RViT。这种自监督学习和监督学习相结合的训练方式使模型能够获得更多的位置特征信息，更准确地定位病灶，捕捉细微的 RA 病理特征。这就提高了模型的性能，并能更准确地预测 RA 损伤。相较于该数据集上的最优模型，本文的模型平均绝对误差降低了 2%，均方根误差降低了 7.4%。然而对测试结果的分析表明，模型对 SvH 分数较高的样本有明显的预测偏差，这是由于数据集中缺乏非常严重的 RA 损伤样本，模型的学习效果不够理想。今后，本课题将针对数据集的不平衡分布进行优化，以更准确地预测 RA 患者的骨损伤程度。

3.7 本章小结

本章提出了一种新的类风湿关节炎骨损伤自动诊断方法，基于 ViT 模型优化了其核心特征提取模块，并加入了通道注意力机制和自监督的学习方法，以确保模型可以捕获图像中相对较远的像素之间的联系，同时降低了原始模型的参数量大，显存消耗严重等问题，最后创新性的在该领域引入自监督学习方法以调节对模型的训练，从而缓解了该领域数据集较少的难以充分训练的现状。接下来的章节将介绍基于本章提出的算法设计与实现的 RA 手部骨损伤辅助评分应用软件。

中国知网 https://www.cnki.net

4 软件设计与实现

4.1 引言

本课题旨在基于 Python 语言和 PyTorch 框架开发一套 RA 手部关节损伤评分软件，所使用的模型为训练好的 RAViT 模型。该软件将在一个高性能计算环境中开发，服务器端的硬件配置包括英特尔 Core i7-7700K CPU（4.2GHz×8）、64G 内存和 NVIDIA RTX 3090Ti 显卡，操作系统为 Ubuntu 16.04，开发工具选择了 PyCharm。

通过本文前面的章节，对类风湿关节炎的特征和评估方法进行了详细研究和算法测试，证明了深度学习方法在自动化评分中的有效性。本课题研究成果将帮助医生更精准地评估 RA 患者的手部损伤情况，并在临床诊断中提供辅助支持。

本章节将首先展示 RA 手部关节损伤评分软件的总体设计框架，然后详细介绍系统的各个子模块，包括输入模块、深度学习模型模块、输出模块和用户界面模块。通过测试数据结果，验证该评分软件的准确性和实用性。

4.2 软件架构设计

本 RA 手部关节损伤评分软件旨在为医生提供一套从输入 RA 患者手部 X 光片图像到输出损伤 SvH 评分的端到端解决方案。为了确保软件的可操作性和维护性，软件架构采用了分层框架结构，根据软件的运行流程，将其分为三个主要层次：数据集采集层、数据集处理层和软件可视化交互层。软件架构设计图如图 4-1 所示：

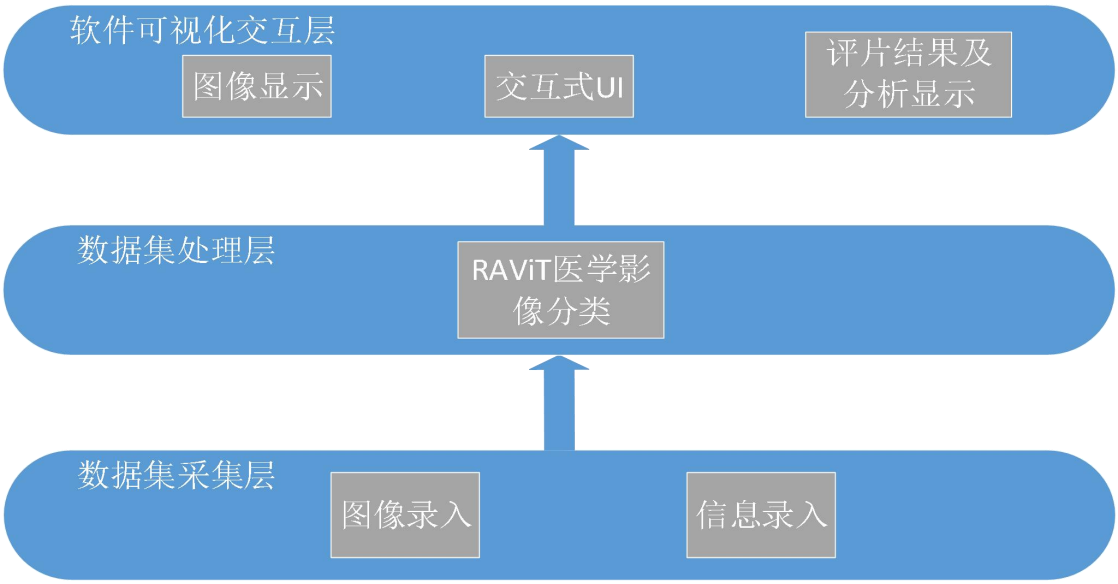


图 4-1 软件架构

中国知网 https://www.cnki.net

（1）数据集采集层

数据集采集层是软件的基础，主要负责图像录入和信息录入两部分。

图像录入:

①图像导入模块: 负责从医院的影像数据库或本地文件系统导入手部X光片图像。

②预处理模块: 对导入的图像进行预处理，如格式转换（例如，从 DICOM 到 JPG）、尺寸调整（标准化图像尺寸）和图像增强（例如，直方图均衡化）。

与软件可视化交互层连接，提供用户界面以选择和导入图像。与数据集处理层连接，传递预处理后的图像以进行深度学习分析。

信息录入:

患者个人信息导入模块: 负责将 X 光片所属患者的个人信息（例如，性别，年龄等）与 X 光片文件名对应起来并保存。

与软件可视化交互层连接，展示选择的 X 光图像所属的患者个人信息。

（2）数据集处理层

该层为我们软件的核心处理层，集成训练好的 RAViT 模型，对预处理后的 X 光片图像进行分析和评分。处理模型输出的结果，准备显示和进一步分析。

RAViT 医学影像分类：

①模型加载模块: 加载训练好的 RAViT 模型，并初始化模型参数。

②图像分析模块: 使用 RAViT 模型对输入的 X 光片图像进行分析，生成 SvH 评分。

③结果处理模块: 处理分析结果，准备输出到用户界面层。

与数据集采集层连接，接收预处理后的图像。与软件可视化交互层连接，传递分析结果以显示给用户。

（3）软件可视化交互层

该层主要负责用户界面和结果展示两部分。

用户界面:

①图像输入接口: 提供用户界面组件，允许用户选择手部 X 光片图像、查看结果和进行保存操作。

②操作按钮: 提供用户操作按钮，如“上传”、“诊断”、“保存”等。

结果展示:

清晰地显示模型的 SvH 评分结果及相关解释信息。

与数据集采集层连接，提供导入图像的接口并接收处理后的图像。与数据集处理层连接，接收分析结果并在界面上显示。

中国知网 https://www.cnki.net

4.3 软件各模块设计

本课题研究的主要模块包括：医学影像数据收集与标注、深度学习诊断模块和软件可视化交互三大模块，模块结构如图 4-2 所示：

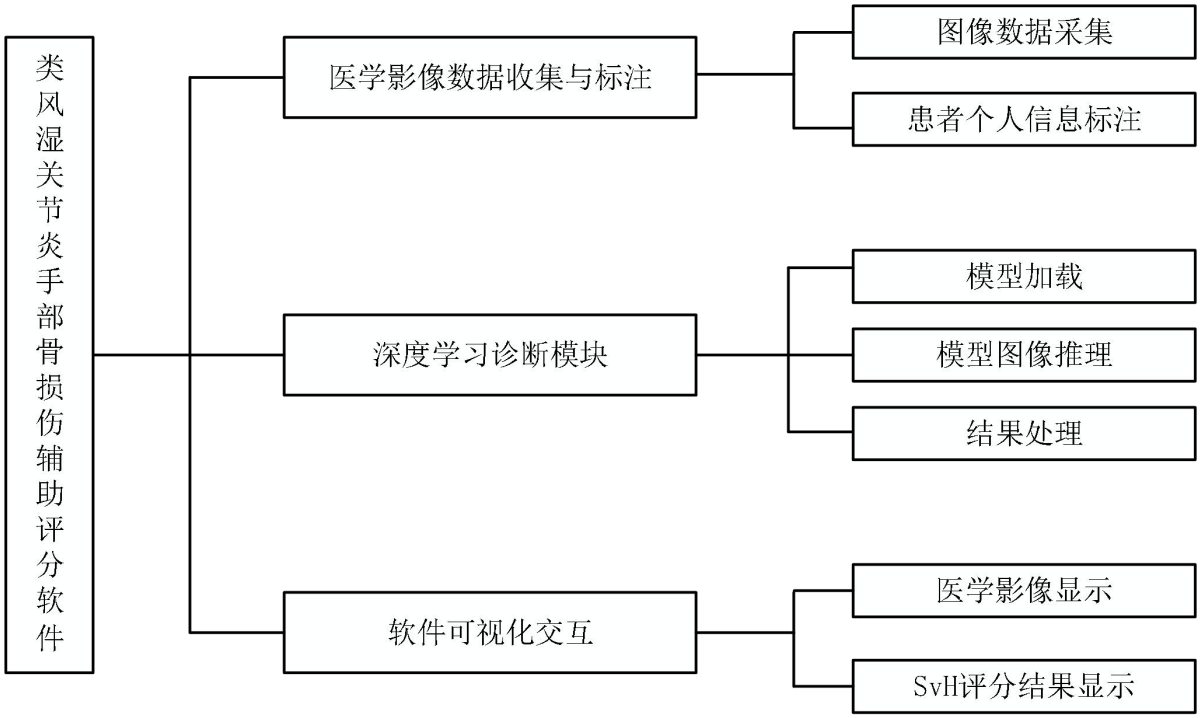


图 4-2 软件模块框架图

首先，在医学影像数据收集与标注模块中，详细介绍了图像数据采集的流程以及患者个人信息的标注方法。将采集到的图片以 jpg 的格式保存到本地，将对应的患者个人信息录入一个 csv 文件中。其次，在深度学习诊断模块中，涵盖了模型加载、模型图像推理以及结果处理的步骤。本文尝试了多种分类模型，如 Inception-V4 模型，用于我们的评分软件，但效果都不如本文提出的 RAViT 分类模型。目前只集成了 RAViT 分类模型进行 SvH 分数的预测。最后，在软件可视化交互模块中，我们展示了医学影像的显示以及 SvH 评分结果的展示。同时，软件还可以将专家人工评片结果录入，以产生新的可用的数据集。其中涉及到两种不同身份人员使用的功能设计流程图：X 光放射科医生和风湿科医生。

（1）X 光放射科医生登录使用的设计流程图如图 4-3 所示。该人员使用的是医学影像数据收集与标注模块，负责在临床上收集 RA 患者的 X 光手部图像和患者的个人相关信息。用户首先使用账号登录软件，如果没有账号则需要注册账号。登录成功后将图像和个人信息数据录入软件中，如果软件录入状态显示成功则结束本次录入，显示失败则重新再次录入该信息。

中国知网 https://www.cnki.net

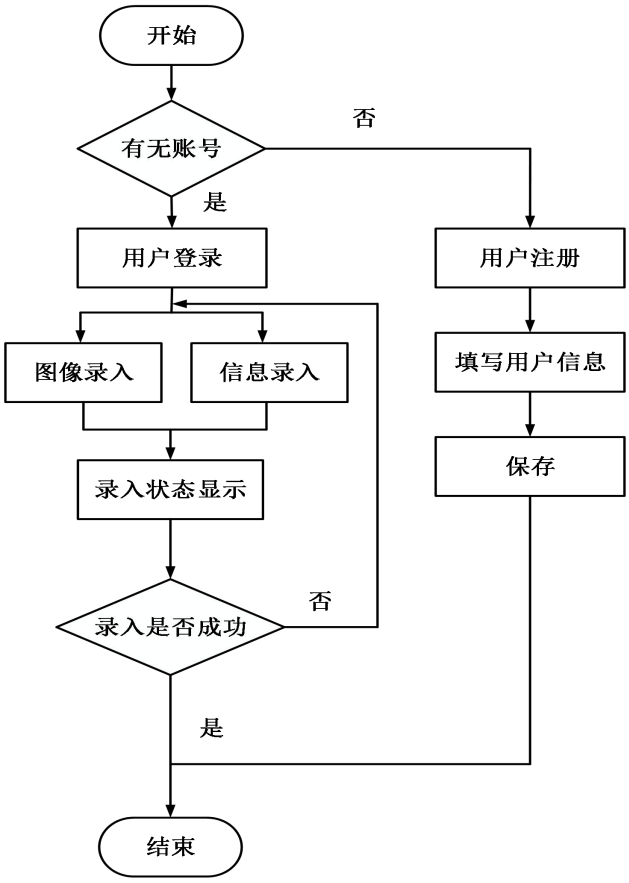


图 4-3 X 光放射科医生使用软件的设计流程图

（2）风湿科医生登录使用的设计流程图如图 4-4 所示。该人员使用的是深度学习诊断模块和软件可视化交互模块，负责对临床上收集到的 RA 患者 X 光手部图像进行诊断评估。用户首先使用账号登录软件，如果没有账号则需要注册账号。登录成功后先选择软件使用的诊断模型和待诊断的 X 光图像。软件会加载训练好的模型对该图像进行推理预测，给出软件计算出的 SvH 评分，并将评分和对应患者的 X 光片，个人信息展示在软件界面上。医生根据 X 光片进行人工评分，将分数填入医生诊断分数栏中。如果需要修改其他数据，可以在界面上直接修改。最后点击保存，将相关信息保存到本地中。

中国知网 https://www.cnki.net

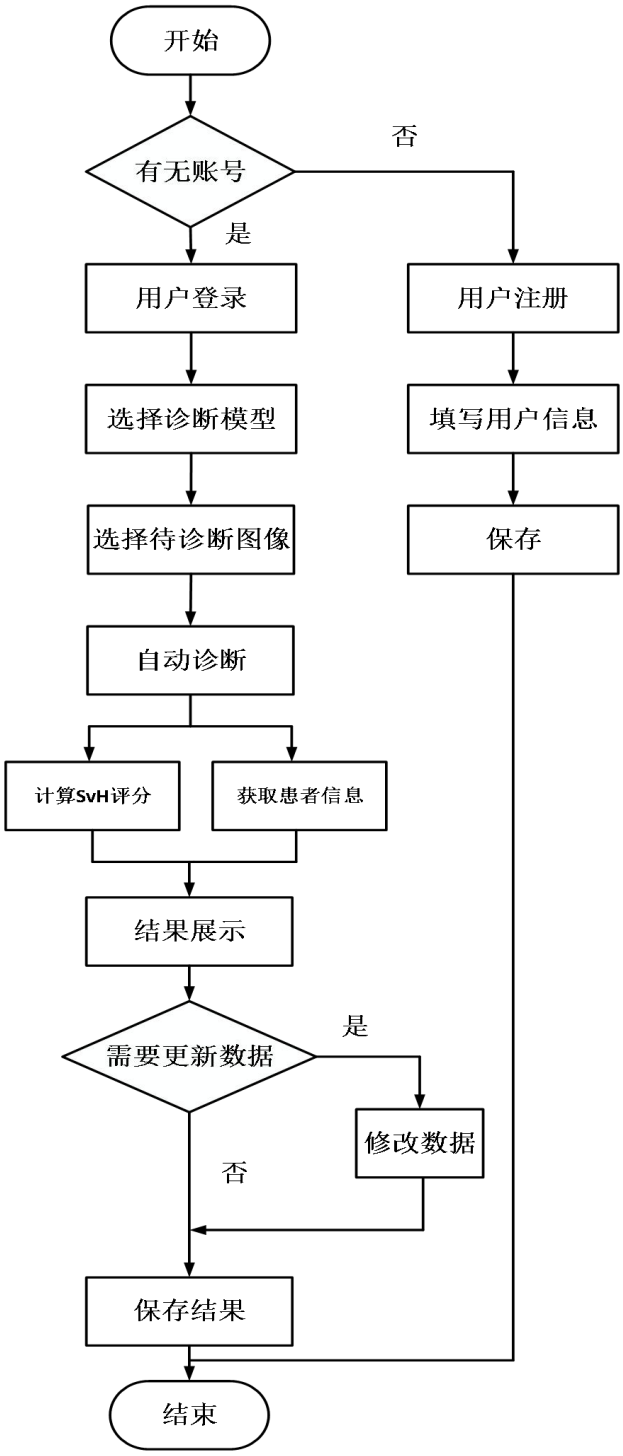


图 4-4 风湿科医生使用软件的设计流程图

4.4 软件界面设计及操作流程

本课题将基于 python 语言、PyTorch 框架训练好的 RAViT 模型嵌入到手部关节损伤评分软件中，该应用软件的界面是基于 PyQt5 设计的，确保各个组件的协同工作，包括图像输入接口、深度学习模型、结果输出和用户界面等。实现输入一个 RA 病人

中国知网 https://www.cnki.net

的手部 X 光片图像到输出该 RA 病人手部损伤 SvH 评分的端到端软件的设计，来辅助医生进行 RA 病情的临床诊断。

使用 Python 开发图形界面的软件其实并不多，相对于 GUI 界面，可能 Web 方式的应用更受人欢迎。Qt 是一个跨平台的 C++图形用户界面库，可以运行于多个平台，包括：Windows，Unix 和 Mac OS 等。PyQt5 是基于 Digia 公司 Qt5 的 Python 接口，由一组 Python 模块构成，为 Python 开发者提供了一个强大的工具，用于创建专业的 GUI 应用程序，而无需深入了解底层的 C++ 编程。PyQt5 本身拥有超过 620 个类和 6000 函数及方法。

4.4.1 界面设计



图 4-5 软件登录界面

为了增强类风湿关节炎骨损伤辅助评分软件的安全性，本章设计了软件登录界面，包括账号登录和账号注册功能，以确保每一位医生都有独立的工作账号。没有账号的医生可以通过注册功能注册自己的账号，医生使用自己的账号进行软件登录，同时还有记住密码和自动登录功能，如图 4-5 所示。

中国知网 https://www.cnki.net

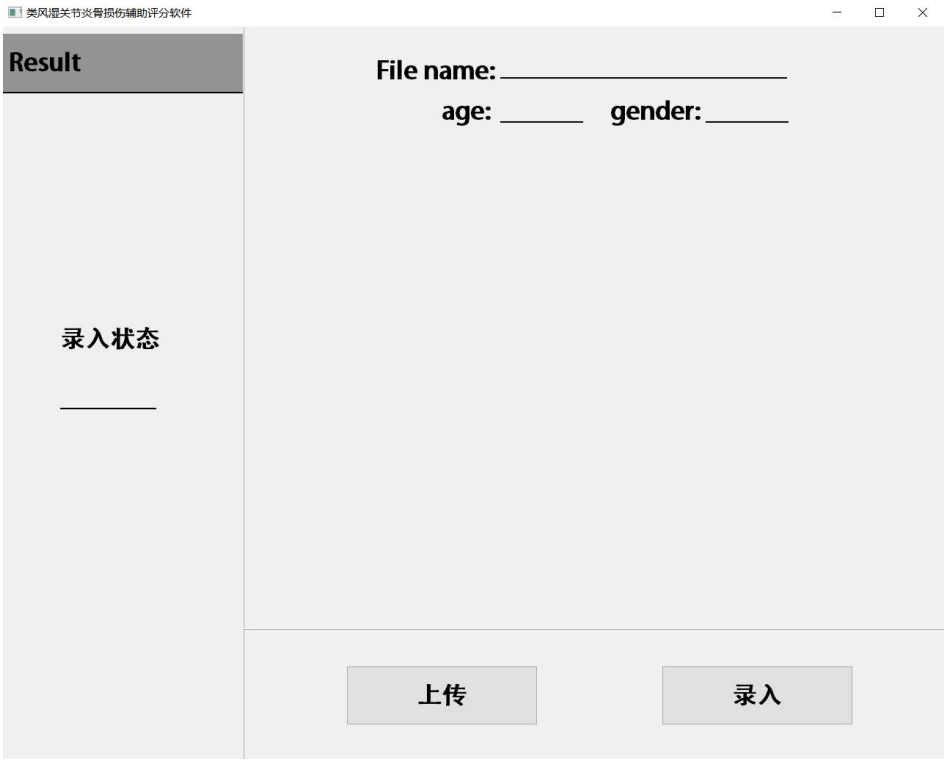


图 4-6 软件数据录入界面

该数据录入界面是为 X 光放射科医生设计的。放射科医生通过上传临床上采集到的患者 X 光片图像（图像名、图像）和个人信息（年龄、性别），将数据录入软件中，经过预处理保存在本地，如图 4-6 所示。



图 4-7 类风湿关节炎骨损伤辅助评分软件主界面

中国知网 https://www.cnki.net

该软件的主界面如图 4-7 所示，供风湿科医生诊断使用。界面左上角 Model 显示的是本软件使用的核心深度算法模型。目前只把本文提出的 RAViT 模型集成到该软件中，之后会增加多一些算法进行比较，也可以实现软件算法的自由选择。界面的左下角则会显示医生给出的该 RA 患者诊断分数以及使用所选 Model 得到的系统评分，辅助医生进行临床诊断。界面的右上部分为患者部分信息的展示以及该患者的手部 X 光片图像。界面的右下角是为操作按钮，上传：选择患者的 X 光片；诊断：运行选中的深度学习 Model 对上传的图像进行 SvH 分数的预测；保存：将医生诊断和系统评分保存到后台的一个.csv 文件，方便查询患者病情和制作新的数据集。

4.4.2 主界面诊断流程

风湿科医生诊断的操作流程分为 4 个阶段：

（1）上传患者的 RA 手部 X 光片。点击“上传”按钮，选择要诊断的患者的手部 X 光片图像，该图像信息使用 jpg 格式存储，如图 4-8。

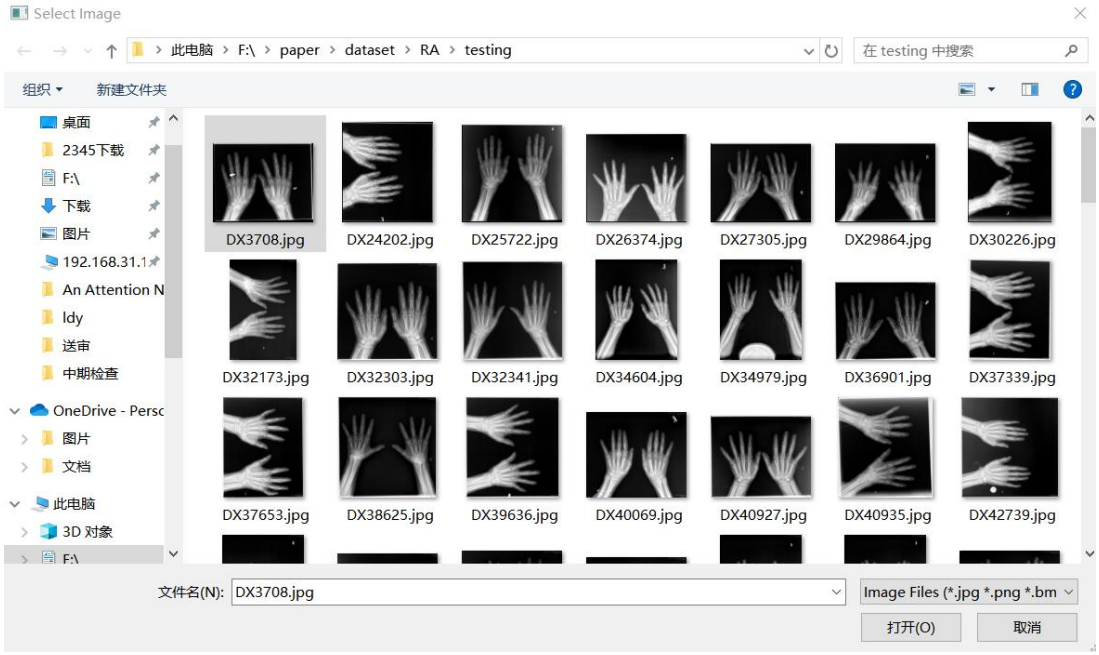


图 4-8 上传读取患者的 RA 手部 X 光图像

（2）选择好上传的图片以后，软件会展示此 X 光图像的患者相关信息，以 DX3708 这张图片为例，应用软件显示了当前选中的图片名（File name）为 DX3708，患者的年龄（age）为 57，性别（gender）为 F（女性），同时如果该 X 光片之前医生诊断过，给出了医生诊断分数，也会显示出来，此例子显示医生上次诊断分数为 11.5 分，如果这次医生诊断分数发生了变化，可以直接在系统上进行分数的修改，如图 4-9。

中国知网 https://www.cnki.net



图 4-9 软件展示选中图片的患者相关信息

（3）选择软件所使用的深度学习模型 Model，对上传的 X 光图像进行 SvH 分数的预测。点击“诊断”按钮，软件会加载训练好的模型对刚刚上传的 X 光片进行分数的预测，会给出的应用软件的系统评分和症状描述（无、轻微、中度、严重、重度），如图 4-10。



图 4-10 软件诊断结果展示

中国知网 https://www.cnki.net

（4）对相应信息进行修改并保存。在诊断结果中，展示的医生诊断是由医生根据临床经验，人工按照 SvH 评分进行评估得到的分数，需要医生手动填写到软件中去，并点击“保存”按钮，此时软件会将该分数存入后台的.csv 文件进行保存，一方面可以保留医生这次的诊断结果，另一方面同时也在为扩充该领域的数据集做准备，如图 4-11。

	A	B	C	D	E
1	file name	age	gender	系统评分	医生诊断
2	DX3708	57	F	12.7	11.5
3					

图 4-11 上述案例保存在.csv 文件中的记录形式

4.5 软件测试

为了验证本课题所设计软件的可行性和正确性，本节对软件关键功能进行了测试，这些功能包括用户登录、医学影像数据收集与标注、深度学习诊断模块以及软件可视化交互模块。以下为具体的测试结果：

表 4-1 功能测试结果

测试内容	测试操作	测试期望	测试结果
用户登录	输入正确的用户名和密码，点击登录按钮。	成功登陆，系统跳转到对应功能界面。	登陆成功。
	输入错误的用户名和密码，点击登录按钮。	登陆失败，系统提示用户名或密码错误。	登陆失败，错误提示正确。
医学影像数据收集与标注	上传正确格式的图像和个人数据信息。	点击录入按钮，录入状态显示成功。	录入成功。
	上传错误格式的图像和个人数据信息。	点击录入按钮，录入状态显示失败。	录入失败，提示重新录入。
深度学习诊断模块	上传一张图片，点击诊断按钮。	模型加载成功，推理顺利，给出系统评分。	系统评分正确给出并显示。
软件可视化交互模块	上传一张图片，点击诊断按钮，再点击保存按钮。	相关信息展示正常并保存到指定位置。	软件展示界面正常，本地保存文件正确生成。

从功能测试结果可以发现，本课题研究中涉及到的关键功能模块均可以正确实现对应功能，从而说明该软件在一定程度上具有足够的稳定性和可行性。

中国知网 https://www.cnki.net

5 总结与展望

在本课题研究中，我们着眼于解决类风湿关节炎患者手部 X 光片的自动化诊断问题，辅助医生进行临床诊断，为早期干预和治疗提供更加精准的帮助。通过深度学习技术，提出了一种创新的自动诊断方法，实现了较高准确率和一致性，设计和实现了本文的网络模型 RAViT，取得了不错的实验结果。RAViT 专门用于预测 RA 患者手部 X 光片的 SvH 分数，这一分数在评估 RA 患者手部关节损伤程度方面具有重要意义。研究结果表明，RViT 模型在 MAE（平均绝对误差）和 RMSE（均方根误差）两个关键性能指标上均优于现有的最佳模型 ResNet-Dwise50，这显示了其在辅助医生进行临床诊断方面的巨大潜力。

然而，尽管取得了一定的成功，但本课题在实验过程中也面临着一些挑战和改进的空间。首先，医学影像与自然图像在特征上存在显著差异，这导致需要对模型进行进一步的优化和调整，以适应医学影像的特殊性。为了解决这一挑战，本文设计了核心特征提取模块 LTransformer，以增强模型的病理特征捕捉能力。同时，本课题还面临着数据集较少的问题，这影响了模型对 RA 损伤样本学习的准确性。为了缓解这一问题，本文引入了自监督学习任务 Drloc，在有限的数据集下更好的训练模型。另外，本文还对该领域唯一公开的数据集存在的缺少，重复以及未划分等问题进行了优化处理，并将处理好的可直接使用的数据集分享至 GitHub 上，供广大学者学习交流，链接如下:https://github.com/ldy07/RA-Dataset。最后，本文将训练好的模型集成到了类风湿关节炎手部 X 光片辅助评分软件中，致力于辅助医生进行临床诊断。此外，该课题还面临着数据集不平衡分布的问题，这影响了模型对严重 RA 损伤样本的预测准确性。

在未来的研究中，将继续优化本文的模型，以进一步提高其在 RA 手部 X 光片评分预测任务中的性能。计划引入更多先进的技术，如迁移学习、强化学习等，以增强模型的泛化能力和鲁棒性。与此同时，也将继续与临床医生合作，深入了解他们的需求和反馈，不断改进本文的算法，并将所提出的模型应用于更多的临床实践中，以探索其在不同医疗场景下的适用性和效果。

除了模型优化外，本课题还将致力于完善辅助评分软件，以便更好地服务于临床诊断工作。计划将更多的关节疾病的诊断领域纳入本课题的研究范围，如骨关节炎、类风湿关节炎等，以为医生提供更多的辅助工具。此外，本文提出的软件在使用过程中还能完整的保存好新的临床数据，在得到患者许可的情况下，医生可以将临床诊断的数据通过该自动评分软件保存在本地，定期去后台获取新的数据集，包括患者的 X 光图像和对应的 SvH 分数，这样就可以收集和制作更多高质量，分布更平衡的数据集来解决该领域目前数据集稀少的重要问题。这将十分有助于深度学习技术在该领域中

中国知网 https://www.cnki.net

的应用发展。

综上所述，本研究为类风湿性关节炎患者的早期诊断和治疗提供了一种新的、有效的方法。该方法利用最新的深度学习技术实现 R 患者手部 X 光片的自动评分，并将训练好的模型集成到自动评分软件中，在医学影像诊断领域具有重要意义，为医生提供了更加方便、快速、准确的辅助诊断手段。我们将继续努力，为医学影像领域的发展贡献一份力量，为患者的健康福祉做出更大的贡献。

中国知网 https://www.cnki.net

参考文献

[1] Cross M, Smith E, Hoy D, et al. The global burden of rheumatoid arthritis:estimates from the Global Burden of Disease 2010 study. Ann Rheum Dis. 2014;73(7):1316-1322.

[2] Rheumatoid arthritis. Nat Rev Dis Primers. 2018;4:18002.

[3] van der Heijde DM, van Leeuwen MA, van Riel PL, van de Putte LB. Radiographic progression on radiographs of hands and feet during the first 3 years of rheumatoid arthritis measured according to Sharp's method (van der Heijde modification).J Rheumatol. 1995;22(9):1792-1796.

[4] He K, Zhang X, Ren S, Sun J. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. arXiv. Preprint posted online February 6, 2015.

[5] Hu J, Shen L, Albanie S, Sun G, Wu E. Squeeze-and-excitation networks. IEEE Trans Pattern Anal Mach Intell. 2020;42(8):2011-2023.

[6] Rajpurkar P, Irvin J, Zhu K, et al. CheXNet: radiologist-level pneumonia detection on chest x-rays with deep learning. arXiv. Preprint posted online December 25, 2017.

[7] Deimel T, Aletaha D, Langs G. GOP0059 AUTOSCORA: deep learning to automate scoring of radiographic progression in rheumatoid arthritis. Ann Rheum Dis. 2020;79:39-40.

[8] Langs G, Peloschek P, Bischof H, Kainberger F. Automatic quantification of joint space narrowing and erosions in rheumatoid arthritis. IEEE Trans Med Imaging. 2009;28(1):151-164.

[9] Peloschek P, Boesen M, Donner R, et al. Assessment of rheumatic diseases with computational radiology: current status and future potential. Eur J Radiol. 2009;71(2):211-216.

[10] Moreland LW, O'Dell JR, Paulus HE, et al; TEAR Investigators. A randomized comparative effectiveness study of oral triple therapy versus etanercept plus methotrexate in early aggressive rheumatoid arthritis: the Treatment of Early Aggressive Rheumatoid Arthritis trial. Arthritis Rheum. 2012;64(9):2824-2835.

[11] 张文瑞,杨爽,吕新亮.类风湿关节炎中医实验动物模型研究进展[J].西部中医药,2024,37(04):106-111.

[12] 王咪咪. RNA 修饰位点、相关基因表达和血浆蛋白水平与类风湿关节炎的关联[D].苏州大学,2024.DOI:10.27351/d.cnki.gszhu.2023.000227.

[13] 陆雨琦. 抗 CCP 抗体与类风湿性关节炎相关间质性肺病的相关性及中医微观辨证的临床研究[D].天津中医药大学,2023.DOI:10.27368/d.cnki.gtzyy.2022.000265.

[14] 刘晨旭,郜娜.蛋白质组学在类风湿关节炎中发病机制及诊疗研究中的最新研究进展[J].中国现代医学杂志,2024,34(07):49-54.

[15] 程增玉. 基于糖代谢重编程关键分子探讨清热化瘀凝胶治疗类风湿关节炎的作用机制[D].中国中医科学院,2024.DOI:10.27658/d.cnki.gzzyy.2023.000101.

[16] Murakami S, Hatano K, Tan J, Kim H, Aoki T. Automatic identification of bone erosions in rheumatoid arthritis from hand radiographs based on deep convolutional neural network. Multimed Tools Appl. 2018;77:10921–37.

[17] Hirano T, Nishide M, Nonaka N, Seita J, Ebina K, Sakurada K, Kumanogoh A.Development and validation of a deep-learning model for scoring of radiographic finger joint destruction in rheumatoid arthritis. Rheumatol Adv Pract. 2019;3:rkz047.

[18] Rohrbach J, Reinhard T, Sick B, Dürr O. Bone erosion scoring for rheumatoid arthritis with deep convolutional neural networks. Comput Electr Eng. 2019;78:472–81.

[19] Chaturvedi N. DeepRA: predicting joint damage from radiographs using CNN with attention[J].

中国知网 https://www.cnki.net

arXiv preprint arXiv:2102.06982, 2021.
[20] Li H, Guan Y. Multilevel Modeling of Joint Damage in Rheumatoid Arthritis[J]. Advanced Intelligent Systems, 2022, 4(11): 2200184.
[21] 汤键. 指关节炎超声图像的智能诊断研究[D].南京大学,2019.
[22] Andersen J K H, Pedersen J S, Laursen M S, et al. Neural networks for automatic scoring of arthritis disease activity on ultrasound images[J]. RMD open, 2019, 5(1): e000891.
[23] Christensen A B H, Just S A, Andersen J K H, et al. Applying cascaded convolutional neural network design further enhances automatic scoring of arthritis disease activity on ultrasound images from rheumatoid arthritis patients[J]. Annals of the rheumatic diseases, 2020, 79(9): 1189-1193.
[24] He X, Wang M, Zhao C, et al. Deep learning-based automatic scoring models for the disease activity of rheumatoid arthritis based on multimodal ultrasound images[J]. Rheumatology, 2024,63(3):866-873.
[25] Sommer OJ, Kladosek A, Weiler V, Czembirek H, Boeck M, Stiskal M. Rheumatoid arthritis: a practical guide to state-of-the-art imaging, image interpretation, and clinical implications. Radiographics. 2005;25:381–98.
[26] Tripoliti EE, Fotiadis DI, Argyropoulou M. Automated segmentation and quantification of inflammatory tissue of the hand in rheumatoid arthritis patients using magnetic resonance imaging data. Artif Intell Med. 2007;40:65–85.
[27] Boesen M, Kubassova O, Bouert R, Axelsen MB, Ostergaard M, Cimmino MA, Danneskiold-Samsoe B, Horslev-Petersen K, Bliddal H. Correlation between computer-aided dynamic gadolinium-enhanced MRI assessment of inflammation and semi-quantitative synovitis and bone marrow oedema scores of the wrist in patients with rheumatoid arthritis – a cohort study. Rheumatology (Oxford). 2012;51:134–43.
[28] Czaplicka K, Wojciechowski W, Włodarczyk J, Urbanik A, Tabor Z. Automated assessment of synovitis in 0.2T magnetic resonance images of the wrist. Comput Biol Med. 2015;67:116–25.
[29] 吴玉寒. 基于定量蛋白质组学的类风湿性关节炎预后不良指标筛选及预测模型建立的研究[D]. 宁波大学,2023.DOI:10.27256/d.cnki.gnbou.2021.001403.
[30] Geurts P, Fillet M, de Seny D, Meuwis MA, Malaise M, Merville MP, Wehenkel L.Proteomic mass spectra classification using decision-tree based ensemble methods. Bioinformatics. 2005;21:3138–45.
[31] 王建梅,强树华,高虹,等.miR-34a-5p 靶向调控 MMP-9 对类风湿关节炎大鼠氧化应激及滑膜细胞分化的作用机制[J].中国老年学杂志,2024,44(06):1494-1498.
[32] Heard BJ, Rosvold JM, Fritzler MJ, El-Gabalawy H, Wiley JP, Krawetz RJ. A computational method to differentiate normal individuals, osteoarthritis and rheumatoid arthritis patients using serum biomarkers. J R Soc Interface. 2014;11:20140428.
[33] Ahmed U, Anwar A, Savage RS, Thornalley PJ, Rabbani N. Protein oxidation, nitration and glycation biomarkers for early-stage diagnosis of osteoarthritis of the knee and typing and progression of arthritic disease. Arthritis Res Ther. 2016;18:250.
[34] Chocholova E, Bertok T, Jane E, Lorencova L, Holazova A, Belicka L, Belicky S, Mislovicova D, Vikartovska A, Imrich R, et al. Glycomics meets artificial intelligence—potential of glycan analysis for identification of seropositive and seronegative rheumatoid arthritis patients revealed. Clin Chim Acta. 2018;481:49–55.
[35] Ormseth MJ, Solus JF, Sheng Q, Ye F, Wu Q, Guo Y, Oeser AM, Allen RM, Vickers KC, Stein CM. Development and validation of a MicroRNA panel to differentiate between patients with rheumatoid arthritis or systemic lupus erythematosus and controls. J Rheumatol. 2020;47:188–96.

中国知网 https://www.cnki.net

[36] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words:Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
[37] 孙鑫. 光声断层成像系统研究及其在关节炎和药物递送中的应用[D].中南大学,2023.DOI:10.27661/d.cnki.gzhnu.2023.002007.
[38] 周丽萍. 肌骨超声联合实验室检查在类风湿关节炎活动度评估中的应用研究[D].南昌大学,2023.DOI:10.27232/d.cnki.gnchu.2022.001126.
[39] 毛瑾玲. 基于 DCE-MRI 图像和 TIC 曲线分析法的类风湿关节滑膜炎定量评估[D].华东师范大学,2024.DOI:10.27149/d.cnki.ghdsu.2023.003022.
[40] Shen L, Lin Z, Huang Q. Relay backpropagation for effective learning of deep convolutional neural networks[C]//Computer Vision – ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11 – 14, 2016, Proceedings, Part VII 14. Springer International Publishing, 2016: 467-482.
[41] Galanis N I, Vafiadis P, Mirzaev K G, et al. Convolutional neural networks: A roundup and benchmark of their pooling layer variants[J]. Algorithms, 2022, 15(11): 391.
[42] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
[43] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
[44] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
[45] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
[46] Lin S, Xie H, Wang B, et al. Knowledge distillation via the target-aware transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10915-10924.
[47] Wang Z, Liu J, Gu Z, et al. An efficient cnn for hand x-ray overall scoring of rheumatoid arthritis[J]. Complexity, 2022, 2022.
[48] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
[49] Liu Z, Mao H, Wu C Y, et al. A convnet for the 2020s[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 11976-11986.
[50] Mate G S, Kureshi A K, Singh B K. An efficient CNN for hand X-ray classification of rheumatoid arthritis[J]. Journal of Healthcare Engineering, 2021, 2021.

中国知网 https://www.cnki.net