北京交通大学

硕士专业学位论文

基于知识图谱的医学影像辅助标注系统的研究与实现

Research and Implementation of a Medical Image Annotation System Based on Knowledge Graphs

作者：杜　洋

导师：夏佳楠

北京交通大学

2024 年 6 月

中国知网　https://www.cnki.net

学校代码：10004 密级：公开

北京交通大学

硕士专业学位论文

基于知识图谱的医学影像辅助标注系统的研究与实现

Research and Implementation of a Medical Image Annotation System Based on Knowledge Graphs

作者姓名：杜洋 学　　号：22140462

导师姓名：夏佳楠 职　　称：讲师

专业领域：软件工程 学位级别：硕士

北京交通大学

2024 年 6 月

中国知网 https://www.cnki.net

摘要

医学图像标注的专业性和复杂性使得纯手工标注的效率低下，同时自动化标注技术难以提供足够的标注精确性。尽管深度学习技术已经在医学影像分析中取得了重要的突破，但它们需要大规模的高质量标注数据来训练模型，而医学影像数据集的数量虽然不断增加，但训练模型的数据量需求仍然很难满足。以上问题导致了深度学习技术无法较好的给医学影像标注领域提供有效的支持，为了解决这些问题，本研究使用前沿的预训练模型技术构建了面向医学影像标注的知识图谱，辅助标注人员进行标注，为医学影像标注和其他医学领域的研究提供更高效、质量更优的支持。并结合当下流行的前后端技术框架，实现了一款高效快捷的医学影像辅助标注系统。具体研究工作内容如下：

(1) 针对当前主流手动标注软件在医学领域应用中专业知识支持不足的痛点，本研究积极引入前沿的大模型技术，实现对医学教材、临床报告等丰富数据源进行精准、快速的知识提取。通过运用当下流行的图数据库 neo4j，成功构建了专门服务于医学影像标注任务的知识图谱，为后续结合影像报告构建结构化文本信息，以辅助标注人员进行标注奠定了坚实的数据基础。

(2) 通过对非结构化的医学影像报告文本的关键信息进行抽取，转化为更加直观的结构化数据，使辅助标注人员能够对标注区域进行迅速、精准的定位。然而，在报告文本中的大量专业术语，极大地增加了医疗命名体识别任务的难度。因此，本研究对 BERT 及其变体模型 ERNIE 和 RoBERTa 在中文医疗命名体识别任务上进行了对比实验，实验表明将 RoBERTa 模型和整词掩码以及条件随机场技术结合的 RoBERTa-WWM-CRF 性能最优，经过 40 轮训练 F1 值即达到了 78%。通过自动识别医学影像报告中的关键信息，结合知识图谱生成结构化且易于理解的文本标注，显著提高了影像标注的效率和准确性。

(3) 在以上研究的基础上，本文使用 MVVM 架构设计实现基于知识图谱的医学影像辅助标注系统。该系统包含知识图谱辅助标注、算法自动标注、标注审核等模块。通过构建基于知识图谱的文本辅助的标注功能，能够在医学影像的标注过程中使标注人员迅速把握医学影像检查报告的要点及病变的具体信息，从而能够在影像上迅速且准确地标记出病变区域，实现对影像的精确标注。同时，标注审核模块可以对已经上传的手动、自动标注结果进行审核及修改，确保标注的准确性。

关键词：医学影像标注；医疗命名实体识别；医学知识图谱；医学影像标注 WEB 系统

中国知网 https://www.cnki.net

ABSTRACT

The professionalism and complexity of medical image annotation make purely manual annotation inefficient, while automated annotation technologies struggle to provide sufficient annotation accuracy. Despite significant breakthroughs in medical imaging analysis with deep learning technologies, they require massive amounts of high-quality annotated data to train models. Although the quantity of medical imaging datasets is increasing, the demand for data to train models is still difficult to meet. These issues hinder the effective support of deep learning technologies for medical image annotation. To address these challenges, this study aims to implement a medical image annotation system using cutting-edge pre-trained model technologies to build a medical image knowledge graph, assisting annotators in their work. By integrating medical imaging textbooks and clinical imaging reports to construct a medical image knowledge graph, this system can provide more efficient and higher quality support for medical image annotation and research in other medical fields. With mainstream front-end and back-end technology frameworks, a fast and efficient medical image auxiliary annotation system is developed. The specific research work includes:

(1) Addressing the lack of professional knowledge support in current mainstream manual annotation software applications in the medical field, this study actively introduces cutting-edge large model technologies to achieve precise and rapid knowledge extraction from rich data sources such as medical textbooks and clinical reports. Using the popular graph database neo4j, a knowledge graph specifically serving medical image annotation tasks has been successfully constructed. This establishes a solid data foundation for building structured textual information to assist annotators, thereby enhancing the accuracy and efficiency of medical image annotation.

(2) By extracting key information from unstructured medical imaging report texts and converting it into more intuitive structured data, the system enables annotators to quickly and precisely locate annotation areas. However, the abundance of professional terminology in report texts significantly increases the difficulty of medical named entity recognition tasks. Thus, this study compared the BERT model and its variants, ERNIE and RoBERTa, on Chinese medical named entity recognition tasks. The results show that the RoBERTa model, combined with Whole Word Masking and Conditional Random Field technology (RoBERTa-WWM-CRF), performs best, reaching an F1 score of 78% after 40 training rounds. By automatically identifying key information in

中国知网 https://www.cnki.net

medical imaging reports and integrating it with the knowledge graph to generate structured and comprehensible text annotations, the efficiency and accuracy of image annotation are significantly improved.

(3) Based on the above research, this study uses the MVVM architecture to design and implement a knowledge graph-based medical image auxiliary annotation system. This system includes modules for knowledge graph-assisted annotation, algorithmic automatic annotation, and annotation review. The text-assisted annotation feature based on the knowledge graph enables annotators to quickly grasp key points and specific details of pathological changes from medical imaging reports, allowing for rapid and precise marking of pathological areas on images, achieving accurate image annotations. Additionally, the annotation review module can audit and modify manually and automatically uploaded annotation results to ensure accuracy.

KEYWORDS： Medical Image Annotation; Medical Named Entity Recognition; Medical Knowledge Graph; Medical Image Annotation Web System

中国知网 https://www.cnki.net

目　录

1 引言.....1
1.1 研究背景和意义.....1
1.2 国内外研究现状.....2
1.2.1 医学知识图谱研究现状.....2
1.2.2 医学影像标注软件现状.....4
1.3 本文主要研究内容.....5
1.4 本文的结构安排.....7
2 相关研究与方法.....8
2.1 自然语言处理与信息抽取技术.....8
2.2 知识图谱技术.....10
2.3 深度学习相关算法.....11
2.3.1 循环神经网络及其变体模型.....11
2.3.2 注意力机制和 Transformer.....12
2.3.3 BERT 及其变体模型.....14
2.4 基于 MVVM 架构的系统设计.....15
2.5 本章小结.....17
3 面向医学影像标注的知识图谱设计与构建.....19
3.1 医学影像标注知识图谱的构建方法.....19
3.2 医学影像标注知识图谱的结构设计.....20
3.3 医学影像标注知识图谱的知识获取与整合.....20
3.3.1 知识图谱数据收集.....20
3.3.2 数据整理与校验.....22
3.3.3 知识存储与管理.....22
3.4 本章小结.....25
4 结构化文本辅助医学影像标注的方法与实现.....26
4.1 结构化文本辅助医学影像标注的方法.....26
4.2 基于预训练模型的医疗命名实体识别.....26
4.2.1 BERT 及其变体模型.....26
4.2.2 整词掩码技术.....28
4.2.3 条件随机场.....29
4.3 实验结果与分析.....30
4.3.1 实验环境.....30
4.3.2 实验数据.....31
4.3.3 评估指标.....32

中国知网　https://www.cnki.net

4.3.4 实验策略.....33
4.3.5 实验与结果.....33
4.4 结构化文本辅助标注的实现.....35
4.4.1 实体与图谱匹配策略.....35
4.4.2 结构化文本的可视化.....36
4.5 本章小结.....37
5 医学影像辅助标注系统的设计与实现.....39
5.1 需求分析与架构设计.....39
5.2 标注流程与系统设计.....41
5.2.1 标注任务流程设计.....41
5.2.2 前台标注系统设计.....41
5.2.3 后台管理系统设计.....43
5.3 系统实现.....43
5.3.1 系统开发软件环境.....43
5.3.2 前台标注系统功能及页面实现.....44
5.3.3 后台管理系统功能及页面实现.....48
5.4 与现有标注软件的对比分析.....50
5.5 本章小结.....51
6 总结与展望.....52
6.1 本文主要工作总结.....52
6.2 未来工作展望.....53
参考文献.....55

中国知网 https://www.cnki.net

1 引言

医学影像标注是现代医学研究和临床诊断中的一个关键环节，它涉及到将医学影像中的特定结构、病变等元素进行精确识别和标记。随着医学技术的不断进步，医学影像数据的数量急剧增加，这对影像标注的效率和质量提出了更高的要求。然而，传统的手工标注方法不仅耗时耗力，而且容易受到个体差异的影响，影响标注结果的一致性和可靠性。虽然深度学习技术为自动化医学影像标注提供了新的可能，但其对大规模高质量标注数据的依赖成为了实际应用的一大瓶颈。因此，开发一种高效、准确的医学影像辅助标注系统显得尤为迫切。

1.1 研究背景和意义

在当今医疗领域，人工智能技术的引入和应用已经成为推动医疗科技进步的关键力量之一。特别是在医学影像诊断领域，人工智能技术的发展为提高诊断效率和精度带来了前所未有的机遇[1]。医学影像，如 X 光、MRI、CT 等，是现代医学不可或缺的诊断工具，它们为医生提供了观察患者体内情况的窗口，帮助诊断和评估多种疾病。然而，随着医学影像数据量的激增，医疗专业人员面临着巨大的分析和诊断压力[2]，这就需要更高效、更精准的工具来辅助他们完成这一任务。

人工智能，尤其是深度学习技术，在医学影像分析中展现出了巨大潜力。通过训练深度神经网络，人工智能可以学习识别和分类影像中的复杂模式，辅助医生进行诊断[3]。这种技术的优势在于它能够处理大量数据，并在某些情况下达到或超过人类专家的表现。然而，这种高性能依赖于大量的、高质量的标注数据，而在医学领域，获取这样的数据集是一个巨大的挑战[4]。医学图像的标注不仅需要专业的医学知识，还需要时间和精力，这使得手动标注成为一个繁重且效率低下的任务[5]。

尽管自动化标注技术的发展为解决这一问题提供了可能，但这些技术往往难以达到医学应用所需的精确度。此外，由于医学图像的复杂性和多样性，以及影像报告中上下文的重要性，自动化技术在理解和处理这些数据方面仍面临重大挑战。因此，开发一套既能利用人工智能技术的优势，又能保证标注质量和效率的医学影像标注系统显得尤为重要。

针对以上问题，本研究提出的医学影像辅助标注系统，通过使用前沿的预训练模型技术和构建医学影像标注知识图谱提高标注效率和质量，该系统的设计充分考虑了医学影像标注的专业性和复杂性，结合了医学影像教材和临床影像检查

中国知网 https://www.cnki.net

报告，以确保标注的准确性和科学性。此外，系统采用 Model-View-ViewModel (MVVM)[6]架构，使其不仅功能全面，而且具有高度的灵活性和可维护性，为医学影像标注领域提供了一种新的解决方案。

医学影像分析作为人工智能在医疗领域应用的重要方向，面临着巨大的机遇和挑战。本研究的重大社会价值和现实意义在于，它可以减轻医疗专业人员的工作负担，提高诊断效率和精度，利用人工智能、深度学习等尖端技术，重塑医学影像分析的准确度、智能性与效率，推动医疗诊断领域的进步。此外，该研究还可能为其他需要大量高质量标注数据的领域提供借鉴和参考，具有广泛的应用前景和深远的影响。

1.2 国内外研究现状

近年来，随着人工智能技术的发展，医学领域的研究逐渐向智能化、精准化方向发展。医学知识图谱和医学影像标注作为这一领域的重要研究方向，受到了广泛关注。医学知识图谱通过整合多种医学数据资源，构建复杂的医学知识网络，为医学研究和临床应用提供了重要支持。医学影像标注软件则主要用于为模型训练提供高质量的标注数据集，在医学影像处理和分析中起到了关键作用。以下将分别介绍医学知识图谱研究现状和医学影像标注软件现状，以更好地理解这一领域的最新进展和未来发展趋势。

1.2.1 医学知识图谱研究现状

2012 年，谷歌首次引入了知识图谱这一概念，目的是优化其搜索引擎的性能，使之能够更迅速地提供与查询更加语义化匹配的答案。知识图谱构建了一个复杂的语义网络，它详细描述了现实世界中的各种实体及它们之间的相互关系。这种网络主要采用<实体 1，关系，实体 2>，<实体，属性，属性值>等形式的三元组来存储信息，这种结构旨在捕捉丰富的语义信息。

知识图谱的发展建立在语义网的基础之上，但其数据量和复杂性远远超出了早期的语义网络。例如，谷歌的知识图谱包含了超过 10 亿个实体和高达 700 亿条的关系，构成了一个庞大而复杂的数据网络。目前，许多知识图谱的构建项目利用了互联网上的开放知识库资源，如维基百科和百度百科，作为知识获取的主要渠道。

知识图谱的构建和应用并不是一个孤立的学科领域，而是一个跨学科的技术领域，它与自然语言处理有着紧密的联系，同时也与机器学习、数据挖掘、语义

中国知网 https://www.cnki.net

技术等其他领域密切相关。这种跨学科的特性使知识图谱成为了连接不同技术和领域知识的重要桥梁，为信息检索、数据分析和智能决策提供支持。

经过多年的发展，知识图谱已在人工智能的众多领域中广泛应用，对自然语言处理的多个方面产生了显著影响。在全球范围内，已经开发了众多大型的知识图谱项目。在国际层面上，几个著名的项目包括 DBpedia[7]、FreeBase[8]、YAGO[9]。DBpedia 是一个跨语言知识库项目，旨在从维基百科的各种语言版本中抽取结构化信息。类似的，Freebase 从各国各地的百科类网站，例如维基百科等，获取信息，目前已经提取了约七千万条实体信息。YAGO 由德国马克斯·普朗克信息学研究所的研究人员开发，结合了 Wikipedia（维基百科）的丰富性、WordNet[10]的语义框架和 GeoNames[11]等其他资源的专业知识，构建了一个包含数百万实体（如人、地点、组织）和它们之间关系的庞大知识库。

作为知识图谱应用最广泛的领域之一，医疗领域可以通过知识图谱技术来整合、分析和应用医学数据，以辅助临床决策、推动医学研究、提升医疗服务品质与效率[12]。在国际上，美国国家医学图书馆开发的医学语言统一系统（Unified Medic al Language System，UMLS）[13]致力于整合不同来源的生物医疗术语和观念，以便于不同的健康信息系统之间能够更好地进行信息交换和合作。该系统由几个主要部分组成：一个综合性的元词表、一个语义网络、各种专业辞典以及词汇处理工具。在这个框架中，语义网络定义了 133 种不同的语义类别和 54 种可能的语义关系，而综合性的元词表则蕴含了超过三百万的医学概念及超过一千三百万的概念命名，其核心组件 Metathesaurus、Semantic Network 和 SPECIALIST Lexicon 为医疗保健领域的信息检索、临床决策支持、教育和研究提供了强大的支持，从而改善了医疗信息的共享和通信效率。在国内，奥德玛等人在人机协同的框架下，开发了名为 CMeKG（Chinese Medical Knowledge Graph）[14]的系统，该系统结合了自然语言处理和文本挖掘的技术，借鉴了国际上公认的医学术语集，如 ICD-10、ATC 和 MeSH 等，同时汇集了大量的多元化和异构性资源，包括临床路径指南、真实临床操作以及医学相关的百科知识。CMeKG 广泛涵盖了与疾病、药物和诊断治疗技术相关的领域，并构建了超过一百万个医学概念之间的关系实例。李丹亚等研发的中文一体化医学语言系统（CUMLS）[15]融合了超过十个生物医学领域的词汇表、分类表、术语集合以及医疗文本资料，建立了一个包含医学术语库、语义网络和构建工具的知识结构体系。利用 CUMLS，成功开展了对医疗文档的自动主题和分类标记，同时实现了包括知识引导、智能查询、以及文献关联性搜索在内的一系列知识服务功能。肖宇等建立了针对 COVID-19 领域的专门本体[16]，其实现方式为，提取和重构来自国内外现有本体、知识库以及诊断治疗指导原则中关于 COV ID-19 的相关信息，实现了 COVID-19 领域知识的整合与复用。何霆及

中国知网 https://www.cnki.net

其团队对大量电子健康档案（EHR）中的医疗数据进行了深入分析，从此过程中汲取了珍贵的医疗智识与实践经验，并基于这些 EHR 数据创建了一个医学知识图谱[17]。

目前，构建中文医疗领域的知识图谱主要依赖于专业人士的审核与计算机技术人机协同的方式进行[18]。尽管这种方式在知识图谱的构建技术、流程设计以及医疗数据标准化等多个方面都已经展现出了成效。然而，关于如何利用知识图谱来支持和改进医疗影像的标注工作，目前的研究仍相对有限。这一领域的深入探索对于提升医疗影像分析的准确性和效率具有重要意义。

1.2.2 医学影像标注软件现状

深度学习技术在医学影像领域的应用已经实现了显著的进展，推动了对疾病诊断和治疗方法的革新。这些技术依赖于大量的、经过精确标注的数据集来进行模型的训练，以确保算法能够有效地识别和分析医学影像中的复杂模式。尽管医学影像数据的可用量正在逐渐增加，但是为了满足深度学习模型对数据规模和质量的高要求，现有的数据集往往还是显得不足[19]。

随着医学影像技术的不断进步，产生的影像数据日益增多，然而，将这些数据转化为可用于深度学习模型训练的高质量标注数据集仍然是一个挑战。高质量的数据标注不仅需要专业的医学知识，还需要考虑到数据的多样性和复杂性，以及标注的一致性和准确性。此外，医学影像数据的隐私和敏感性问题也限制了数据共享和利用的可能性，进一步加剧了数据短缺的问题。

手工标注与自动化标注也面临着严峻挑战。在传统的医学影像处理领域，数据的标注工作往往依赖于标注者的专业医学背景和深厚的临床实践经验。由于不同的医学专家在解读和标注同一影像资料时可能会有不同的理解和判断，因此，这一过程不可避免地涉及到了主观性的因素，导致了标注结果之间可能存在一定的差异[20]。这种基于个体专家经验的标注方式，虽然在某种程度上能够确保数据的专业性和准确性，但同时也是一项耗时且劳动密集的工作。此外，传统的医学影像标注方法往往更注重于生成适合图像检索的标注结果，而不是为深度学习模型的训练和研究提供优化的数据[21]。深度学习在医学影像分析中的应用需要大量的、标注精确的数据集，以便于算法能够从中学习到复杂的图像特征和模式。然而，传统标注方法产生的数据往往难以直接满足深度学习的这一需求，因为这些方法可能无法提供足够详细或格式化的注释信息，以支持深度学习算法对医学影像中复杂和细微差别的识别和学习。

当前主流的手动标注软件，如 LabelMe[22]、CVAT（Computer Vision Annotation

中国知网 https://www.cnki.net

Tool）[23]和 LabelImg[24]等，主要用于让用户以多边形的形式手动勾画出影像中的特定区域。这类工具的设计重点在于提高标注的灵活性和适用性，适用于各种图像标注任务。然而，它们大多没有直接整合医学专业知识或引入针对医学影像特有需求的功能[25]。这类标注工具虽然在通用性方面表现良好，但由于缺乏专业医学知识支持，在应对复杂的医学影像标注任务时，无法提供相应的指导和帮助。医学影像标注不仅需要标注者识别图像中的结构，还需要根据医学知识对这些结构进行正确的分类和解释，这便需要标注工具不仅要能够支持精确的图形绘制，还能够引导标注者根据医学标准进行标注。

因此，为了更好地服务于医学影像分析领域，标注软件的开发需要考虑到医学领域的特殊需求，比如引入疾病分类、解剖结构识别、病变程度评估等医学知识支持，并提供更为精细的标注指导。通过整合这些专业知识，可以大大提高医学影像数据标注的效率和准确性，为后续的图像分析和深度学习模型训练提供更高质量的数据。

1.3 本文主要研究内容

本文着重探讨了医学影像标注的关键技术与系统设计及实现，旨在通过智能化工具和方法，提升医学影像数据的处理、标注和应用效率。研究内容主要分为以下三个方面：

(1) 面向医学影像标注的知识图谱设计与构建。针对目前医疗影像领域的知识图谱相关研究较少、开放领域知识图谱无法适用于辅助标注的问题，本文设计并实现了适用于医学影像辅助标注任务的知识图谱。该知识图谱以医学影像数据为核心，结合医学影像教材和临床影像检查报告等多源信息，构建了一个结构化的知识体系。通过对医学影像特征、病理类型、临床表现等维度的深入分析和整合，本知识图谱能够为医学影像的辅助标注、疾病诊断和治疗决策提供有力支持。在设计阶段，本研究首先对现有的医学影像数据进行了归纳和分类，明确了知识图谱中需要包含的基本实体类型和关系类型。接着，通过文献调研和专家咨询，收集并整理了大量医学专业知识，以确保知识图谱的内容准确性和实用性。在实现阶段，本研究采用了前沿的图数据库技术来存储和管理知识图谱，利用自然语言处理技术从医学文献和临床病历中提取知识。

(2) 结构化文本辅助医学影像标注的生成与实现。为了有效应对当前主流的手动标注软件中存在的诸多挑战，如在软件中缺乏直接整合医学专业知识、未引入针对医学影像特有需求的功能，以及在复杂的医学影像标注任务面前缺乏专业医学知识支持，从而无法提供有效的指导和帮助等问题。本研究首先对比不同的命

中国知网 https://www.cnki.net

名实体识别（Named Entity Recognition, NER）[26]技术在医学领域的应用效果，在实验中选择了 BERT（Bidirectional Encoder Representations from Transformers）[27]及其变体模型 ERNIE（Enhanced Representation through kNowledge Integration）[28]和 RoBERTa（Robustly optimized BERT approach）[29]，通过在公开的医学文本数据集上进行实验，比较了不同模型在识别精确度、召回率和 F1 分数等关键性能指标上的表现，基于实验结果选择表现最优的模型，并将其应用于对输入的医学影像检查报告进行处理，自动识别和提取病变位置、类型、属性等关键医学信息，与已有的医学影像标注知识图谱相结合，形成一个结构化的文本标注框架。再对其进行可视化处理，通过这种互动式的可视化界面，标注人员可以更加直观地理解医学影像检查报告的信息，进一步提升标注工作的效率和质量。

(3) 医学影像辅助标注系统的设计与实现。针对纯手工标注的效率低下和精确性不足的问题，本研究采用了 MVVM 架构，设计并实现了一个基于知识图谱的医学影像辅助标注系统。MVVM 架构使得数据处理逻辑、用户界面和数据展示能够高效地分离，提升了系统的可维护性和扩展性。该系统旨在通过使用前沿的自然语言处理和深度学习技术，自动化提取和利用医学文本数据中的关键信息，如解剖结构、影像学表现等，结合专门构建的医学影像标注知识图谱，生成结构化文本辅助标注人员进行标注，以提高工作效率和标注质量。标注系统还拥有配套的后台管理系统，通过任务管理模块的精确任务分配和进度跟踪功能，确保了标注任务的有序、高效执行。同时，为了保证标注结果的高质量，系统引入了专门的标注审核模块，该模块设定了严格的审核流程，所有标注结果都需经过二次复核，从而有效避免了错误或不一致的标注结果。角色管理模块则为不同用户定义了清晰的职责和权限，根据用户的角色自动分配适当的任务和权限，确保了标注和审核工作的顺畅和有序。

图 1-1 概括了本文的主要研究内容。

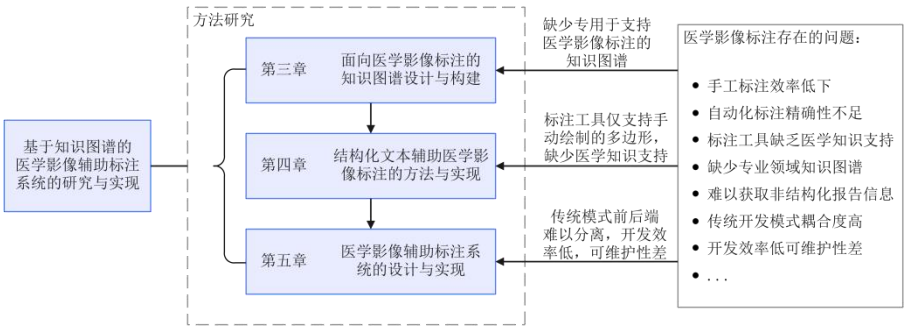


图 1-1 研究内容

Figure 1-1 Research Content

中国知网 https://www.cnki.net

1.4 本文的结构安排

第一章是引言部分，首先介绍了本文的研究背景及意义，接着从医学知识图谱和医学影像标注两个方面介绍了国内外的研究现状，之后将本文的研究内容分成三个点进行阐述，最后介绍了论文组织结构安排。

第二章是相关研究与方法，阐述了自然语言处理与信息抽取技术、知识图谱技术、构建知识图谱所需的深度学习算法及其相关研究现状，以及 MVVM 架构系统的设计要点。

第三章是面向医学影像标注的知识图谱设计与构建，这部分将介绍构建知识图谱的流程，包括从医学文献、临床报告和影像注释中提取实体（如疾病、症状、体征）和关系（如疾病与症状之间的关联），再讨论知识表示与管理的方法。

第四章是结构化文本辅助医学影像标注的方法与实现，首先对 BERT 及其变种模型 RoBERTa 和 ERNIE，在中文医疗命名体识别任务上的性能进行评估，实验结果使用精确率、召回率和 F1 值作为评价指标，展示了各模型在医学实体识别任务上的性能，其中 RoBERTa-WWM-CRF 模型表现最佳。随后使用训练好的模型，深入分析临床检查报告中的非结构化文本数据，结合第三章构建的知识图谱，将其转化为易于理解和操作的结构化信息，进而生成直观的可视化标注，辅助标注人员高效、准确地识别和圈定病变区域。

第五章是医学影像辅助标注系统的设计与实现，本章从系统的总体架构出发，阐述了设计理念的核心，即如何通过高效的模块化设计实现数据、逻辑和视图的有效分离，以提高系统的可维护性和用户交互体验。在实现层面，本章详细介绍了基于 MVVM 架构的系统开发过程，包括执行标注任务的流程、对医学影像进行标注等所涉及到的模块与功能的关键技术点的具体实现步骤。并介绍了配套的后台管理系统的功能及使用的流程。

第六章为总结与展望，对当前的研究成果进行了复盘，分析了目前研究的局限性，同时提出了对该系统的优化方案及潜在的研究方向。

中国知网 https://www.cnki.net

2 相关研究与方法

本文的主要研究内容为基于知识图谱的医学影像辅助标注系统，本章节围绕构建医学影像标注知识图谱及生成结构化文本辅助标注所需的信息抽取任务中的医学命名实体识别和实体关系抽取任务的研究和方法进行阐述，同时对医学影像辅助标注系统进行需求分析与介绍所需的关键技术。

2.1 自然语言处理与信息抽取技术

构建知识图谱是一项涉及复杂数据处理和分析的任务，其核心在于从非结构化数据中抽取有用信息并组织成易于查询和分析的结构。中文自然语言处理与信息抽取技术的实现主要涉及多个关键步骤和方法，文本预处理与结构分析以及信息抽取（Information Extraction, IE）[30]技术在此过程中起着至关重要的作用，特别是命名实体识别和关系抽取等技术的应用，对于从文本中提炼信息至关重要。

(1) 文本预处理与结构分析

中文文本预处理与结构分析是自然语言处理领域中的一项基础而关键的任务，其目的是将原始文本转换为更适合计算机处理的格式，并识别其中的语言结构和含义。中文文本处理由于中文的特殊性，如汉字的构造、缺乏明确的词界等，比起其他语言（如英语）来说更为复杂。中文分词、词性标注和句法分析是文本预处理与结构分析中的关键步骤。中文分词是将连续的文本切分为有意义的单词或词语的过程。由于中文文本中通常不像英文那样有空格分隔单词，这一步骤对于中文文本处理尤为重要。当前主流的分词方法包括基于统计的分词、基于规则的分词以及深度学习方法。基于统计的方法依赖于大量的语料库来学习词语的边界，如隐马尔可夫模型（Hidden Markov Model，HMM）[31]和条件随机场（Conditional Random Field，CRF）[32]。近年来，随着深度学习技术的发展，基于深度神经网络的分词方法，如 Bi-LSTM 配合 CRF，已经显示出更优越的性能[33]。词性标注是指为分词后的每个单词标注正确的词性（如名词、动词等）。这一步骤对于理解词语在句子中的语法角色非常关键。传统的词性标注方法包括基于规则的方法和基于统计的方法，如 HMM 和最大熵模型。近期，基于深度学习的模型，特别是基于 Transformer[34]的模型如 BERT，已经被广泛应用于词性标注任务，显示了更好的性能。

(2) 命名实体识别

命名实体识别（Named Entity Recognition, NER）[35]是自然语言处理（Natural Language Processing，NLP）[36]领域的一个基础任务，旨在从文本中识别具有特定

中国知网 https://www.cnki.net

意义的实体，如人名、地名、组织名、时间表达式和数值表达式等[37]。这一任务是信息提取、问答系统、机器翻译、内容摘要、情感分析等许多 NLP 应用的重要组成部分。

实现命名实体识别通常包括基于规则的方法、基于统计的方法以及最近流行的基于深度学习的方法。基于规则的方法依赖于手工编写的规则来识别文本中的实体，这需要大量的语言学知识和人工劳动[38]。基于统计的方法，如 HMM、CRF 等，通过从大量标注数据中学习实体和上下文之间的统计关系来识别实体。近年来，随着深度学习技术的发展，基于深度学习的方法，特别是基于循环神经网络（Recurrent Neural Network，RNN）[39]、长短期记忆网络（Long Short-Term Memory, LSTM）[40]和 Transformer 模型的方法，已经成为 NER 任务的主流，因为它们能够捕获文本数据中的复杂特征和解决长程依赖问题。

命名实体识别仍有诸多难点。首先，实体的多样性和模糊性使得准确识别具有挑战性。一个词在不同的上下文中可能表示不同的实体类型，或者相同的实体名称可能指代不同的实体[41]。其次，对于小众语言或专业领域，缺乏足够的标注数据也是一个重要问题[42]。此外，文本中的新词和新命名实体的出现也需要模型能够不断适应新的数据[43]。

为了解决这些问题，研究人员提出了多种解决方案。一种方法是通过迁移学习和领域适应技术，将在资源丰富的语言或领域上训练的模型迁移到目标语言或领域[44]。另一种方法是利用半监督学习和无监督学习技术，从未标注数据中提取有用信息来增强模型的性能[45]。此外，实体链接和知识库的使用也可以帮助解决实体的多义性问题，通过将文本中的实体与知识库中的实体相链接，来提高实体识别的准确性[46]。

尽管存在这些问题，但通过持续的研究和技术进步，这一领域已经取得了显著的进展，并在多个应用中展现了其重要价值。

(3) 关系抽取

关系抽取的目标是识别并分类文本中实体对之间的语义关系。关系抽取在信息检索、知识图谱构建、问答系统等应用中扮演着重要角色，是理解文本语义的关键步骤之一。举例来说，在句子“比尔·盖茨创立了微软”中，关系抽取任务是识别“比尔·盖茨”和“微软”这两个实体，并确定它们之间的关系是“创立”。

关系抽取的实现方法大致可分为三类：基于规则的方法、基于特征的方法和基于深度学习的方法。基于规则的方法依赖于手工编写的规则来识别文本中的关系模式。这些规则可以基于语法结构、关键词、实体类型等来定义，这种方法的优点是在特定领域内可以非常精确，但缺点是缺乏泛化能力且难以扩展。基于特征的方法通过机器学习算法，根据从文本中抽取的特征（如词性标注、句法结构

中国知网 https://www.cnki.net

等）来训练分类器。这种方法相对灵活，但需要大量的特征工程和充足的标注数据[47]。基于深度学习的方法特别是卷积神经网络、循环神经网络、长短期记忆网络和 Transformer 架构，在关系抽取任务中取得了显著的成果。这些方法能够自动从数据中学习复杂的特征表示，避免了繁琐的特征工程[48]。

关系抽取面临的难点主要包括实体歧义性、关系多样性与细粒度问题、以及长程依赖问题。实体歧义性指的是同一实体在不同上下文中可能指代不同的事物，这给准确识别实体间的关系带来了困难[49]。关系的多样性和细粒度问题则是同一种关系，在不同的文本中也可能以多种不同的方式表达，增加了抽取的复杂性[50]。长程依赖问题则涉及到在长篇幅的文本中，实体之间的关系可能跨越多个句子甚至多个段落，这使得基于传统局部特征的方法难以捕捉到这些关系[51]。

以上问题可以通过外部知识、注意力机制和上下文编码以及远程监督和弱监督学习在内的多种方案解决。通过整合外部知识库，如 Wikidata 和 Freebase，可以提高实体识别的准确性和关系抽取的精度。利用注意力机制和上下文编码技术，如 BERT 和 Transformer，可以更有效地捕捉长程依赖和复杂的上下文信息，从而更好地理解实体之间的关系。远程监督和弱监督学习技术通过自动生成标注数据来克服标注数据稀缺的问题，尽管这可能引入一些噪声，但通过算法可以在一定程度上缓解这一问题，从而在关系抽取任务中取得更好的性能[52]。

2.2 知识图谱技术

知识图谱技术是人工智能和语义网（Semantic Web, SW）[53]领域的一个核心概念，旨在通过一定的符号系统来描述现实世界中的概念、实体及其相互关系，以实现知识的组织、存储、检索和应用。知识表示方法主要包括形式逻辑、语义网络、框架、本体论和概念图等[54]。实现这些技术的方法多种多样，通过计算机程序来模拟人类的认知过程，以便更好地理解和处理复杂的数据和信息。

为了实现这一目的，需要知识的高效获取与表示、大规模知识库的管理、知识的一致性和完整性维护、以及知识的实时更新和融合等。解决这些难点需要综合运用自然语言处理、深度学习等技术，以及有效的知识库架构和算法设计。

知识图谱作为知识表示与管理的一种高效方式，通过图形化的方式组织和管理知识，便于知识的查询和关联分析。构建知识图谱通常涉及知识的提取、整合、存储和更新等步骤。

知识融合（Knowledge Fusion）[55]是构建知识图谱过程中的一个关键环节，它涉及如何有效地合并来自多个源的信息和知识，以获得更全面、更准确的知识表示。实现知识融合的方法通常包括数据预处理、源选择、冲突检测和解决、以及

中国知网 https://www.cnki.net

知识整合等步骤。数据预处理涉及数据清洗和规范化，以保证数据的质量和一致性。源选择是基于数据源的质量和可信度进行选择，以确保融合后的知识的准确性。冲突检测和解决是识别和解决来自不同源的信息之间的不一致和冲突，通常需要复杂的算法和人工判断。最后通过知识整合将处理后的信息合并到统一的知识体系中，同时对知识库进行更新和维护[56]。

知识的存储和查询是知识管理的另一个重要方面，特别是在大规模知识图谱的背景下。Neo4j[57]作为当下最流行的图数据库，其核心是基于节点、关系和属性构建的灵活图形数据结构，这种灵活的图形数据结构允许知识图谱以非常直观和自然的方式来表示现实世界中的复杂关系，同时保持了高效的查询性能[58]。节点代表图谱中的实体，关系描述实体间的连接，属性则为节点和关系提供详细描述，这种结构使得数据表示和查询直观且高效。Neo4j 也提供了强大的查询语言 Cypher，一种声明式的图查询语言，允许用户以直观的方式查询和操作图数据。Cypher 的语法简洁，易于理解和使用，特别适合于复杂的图形查询和分析任务。除了 Cypher 语言，Neo4j 还提供了丰富的 API 和多种语言的驱动程序，如 Java、Python、JavaScript 等，这些接口和工具使得从不同的应用程序和服务中可以方便的访问和操作 Neo4j 数据库。Neo4j 通过高效的存储机制、优化的查询引擎以及事务管理等功能克服了数据模型设计、大规模数据处理以及数据一致性和完整性等问题，提供了一个强大且灵活的平台，用于构建和管理知识图谱，支持各种复杂的知识表示和智能应用的开发，使其在多个领域中得到广泛应用，包括社交网络、推荐系统和复杂网络分析等。

2.3 深度学习相关算法

深度学习技术的一大优势在于其免除了手动特征工程的需求，通过从简单的词嵌入中自动组合并形成复杂的高阶特征表示，有效提升了从数据中挖掘最优特征的能力，减少了因特征选择不当带来的负面影响，同时也大幅降低了人力成本。

2.3.1 循环神经网络及其变体模型

在处理自然语言时，单词之间存在着内在的语义联系，循环神经网络因其在捕捉这种序列数据中的动态特性方面展现出卓越性能，被广泛应用于文本分类、意图识别等自然语言处理任务中。RNN 通过其循环的网络结构，有效地编码了序列数据中元素之间的关系。然而，RNN 在训练过程中容易遇到梯度消失或爆炸的问题，这限制了其在捕捉长程依赖方面的能力。

中国知网 https://www.cnki.net

为了克服这些难题，研究者们引入了 LSTM，该模型通过在神经单元中集成遗忘门、输入门和输出门来管理信息流。这些门的机制允许 LSTM 单元有选择地遗忘过时的信息并保留有用的知识，从而在一定程度上缓解了传统 RNN 的梯度问题。尽管 LSTM 在处理序列数据方面取得了显著进步，但其无法进行并行处理的特性在处理大量文本数据时可能导致效率低下。此外，门控循环单元（Gated Recurrent Unit, GRU）[59]作为 LSTM 的一个变种，以更简化的结构进一步提高了模型的效率和性能。GRU 通过合并遗忘门和输入门为一个单一的更新门，并将单元状态和隐藏状态合并，简化了 LSTM 的结构。这种简化不仅减少了参数的数量，还加速了模型的训练过程，同时保持了对长程依赖的捕捉能力。

2.3.2 注意力机制和 Transformer

尽管 LSTM 和 GRU 有效缓解了传统 RNN 面临的梯度消失和梯度爆炸的问题，并提高了模型对于长程依赖信息的处理能力，但是其结构的复杂性限制了其并行处理能力，导致在处理大量文本数据时，时间成本显著增加。针对这个问题，注意力机制的提出为处理序列数据提供了新的方案。该机制使模型能够注意到序列中的关键信息，而不是同等地对待序列中的每个元素，从而提高了信息处理的效率。Vaswani 等人提出的 Transformer 架构进一步革新了序列模型的设计，通过引入自注意力（self-attention）机制，使得模型能够直接计算序列中任意两个位置之间的依赖关系，从而更有效地捕捉长程依赖。这种机制不仅提高了模型处理序列数据的能力，还显著提升了训练效率。

Transformer 采用了 Encoder-Decoder 架构[60]，这种结构在许多序列到序列（Seq2Seq）的任务中非常常见，如机器翻译、文本摘要等。Encoder 负责将一个符号表示的输入序列$(x_1,\ldots,x_n)$映射为一个连续表示的序列 $z=(z_1,\ldots,z_n)$。然后将 z 作为 Decoder 的其中一个输入，Decoder 会一次一个的产生字符输出序列$(y_1,\ldots,y_n)$。在解码过程中的每个时刻，Transformer 是自回归的，这意味着在生成当前词时，模型会使用之前已经生成的词作为额外的输入信息，这种方式确保了输出序列的连续性和语义的一致性。Transformer 模型核心部件包括多层的堆叠结构，在其 encoder 和 decoder 中均使用 self-attention 和逐点全连接前馈网络。自注意力机制通过计算输入序列中各个位置间的关系，使模型能够捕获内部依赖性。这一机制在多头自注意力（Multi-Head Attention）形式中得以扩展，其中将注意力拆分为多个头，分别在不同的子空间学习信息，增强了模型的处理能力。每个自注意力单元由 Query、Key 和 Value 向量组成，通过计算 Query 与所有 Key 的点积，再通过 softmax 标准化来获得注意力分数，以此来决定各个 Value 的重要性。紧随

中国知网 https://www.cnki.net

其后的是逐点全连接前馈网络，它独立地应用于序列中的每个位置，包含两个线性变换和一个 ReLU 激活函数，进一步加工信息。每个子层的输出通过残差连接与输入相加，然后进行层归一化，其整体框架结构如图 2-1 所示。

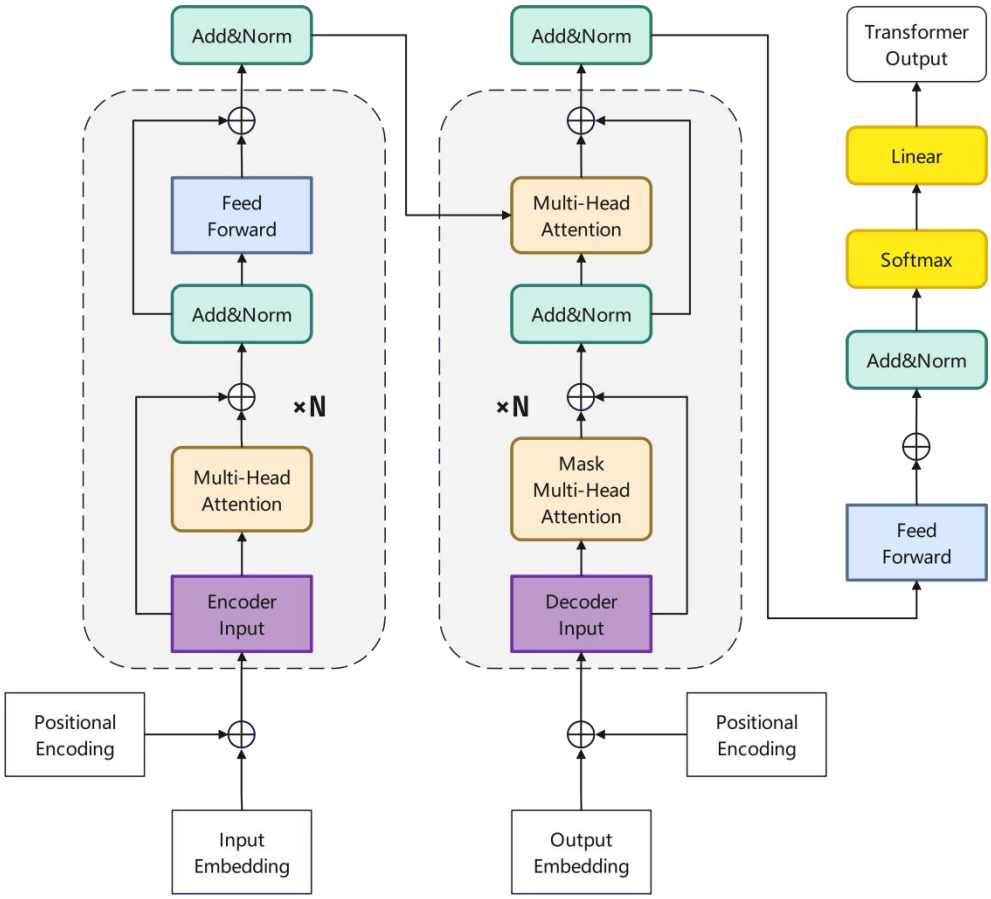


图 2-1 Transformer 框架结构图

Figure 2-1 Structure Diagram of the Transformer Framework

传统 attention 的注意力概率分布来自外部，而自注意力机制是探索当前序列中每一个元素对当前元素的影响程度（相关程度）。两者具体计算过程是一样的，只是计算对象发生了变化。自注意力机制的关键在于将输入序列的每个元素转换为三个向量：查询（Query）、键（Key）和值（Value）。对于每个元素，计算其查询与序列中所有键的兼容性得分，可以通过对应元素的查询向量与所有其他元素的键向量进行点积得到。然后，这些得分通过 softmax 函数进行归一化，以获得每个元素对序列中所有其他元素的注意力权重。最后，这些权重与对应的值向量相乘并求和，以得到加权的表示，这就是注意力机制的输出，公式表示如式 2-1 所示。

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2\text{-}1)$$

其中，Q，K，V，分别代表查询（Query）、键（Key）和值（Value）矩阵，

中国知网 https://www.cnki.net

d_k是键向量的维度。通过这种机制，每个序列元素可以动态地依据其他元素的信息加权得到自己的表示。

2.3.3 BERT 及其变体模型

BERT 模型在 Transformer 的基础上进一步扩展，引入了双向训练的概念，使模型能够更全面地理解语言的上下文。BERT 的核心是其预训练（Pre-training）和微调（Fine-tuning）的过程，通过这两个阶段，BERT 能够学习到丰富的语言表示，然后将这些表示适应于各种特定的下游任务。BERT 的创新之处在于其预训练任务设计，它采用了掩码语言模型（Masked Language Model, MLM）和下一句预测（Next Sentence Prediction, NSP），这两个任务共同训练 BERT 模型以理解单词之间和句子之间的上下文关系。在 MLM 任务中，模型的输入是一系列单词，其中随机选取的一部分单词被替换为一个特殊的掩码符号[MASK]。BERT 的目标是预测这些掩码位置上的原始单词。这种预训练机制迫使 BERT 学习使用左右两侧的上下文信息来推断缺失的单词，从而学会深入理解语言的双向上下文。NSP 任务则是为了让 BERT 学习理解两个句子之间的关系。输入一对句子，需要预测第二个句子是否是第一个句子在原文中紧接着出现的下一句。这个任务通过让模型理解句子间的连贯性和逻辑关系，帮助 BERT 捕捉更广泛的语言结构。预训练完成后，BERT 模型可以通过微调来适应各种 NLP 任务，如文本分类、情感分析、问答系统等。微调阶段的关键是在 BERT 预训练模型的基础上，添加少量与特定任务相关的层，然后在特定任务的数据集上继续训练模型。在微调时，所有的预训练参数都会被保留，但学习率通常会设置得较小，以避免预训练阶段学到的表示被快速覆盖。微调可以视为在预训练得到的通用语言模型上进行特定任务的“调校”，如图 2-2 所示。

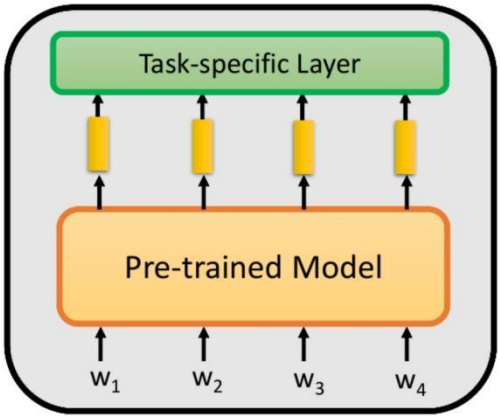


图 2-2 BERT 预训练与微调
Figure 2-2 BERT Pre-training and Fine-tuning

中国知网 https://www.cnki.net

在 MLM 中，模型被训练来预测输入序列中被随机掩盖的单词，而在 NSP 中，模型则需要判断两个句子是否在原始文本中相邻，这种预训练方式使得 BERT 能够捕捉到句子间的复杂关系。给定一个输入序列$X = (x_1, x_2, \ldots, x_n)$，BERT 首先通过一个嵌入层将每个词$x_i$转换为对应的向量$e_i$。然后将这些嵌入向量被送入多层 Transformer 编码器中，每层编码器均由自注意力层和前馈神经网络组成，公式表示见式(2-2)。

$$Output = Transformer(LayerNorm(e_i + Attention(e_i))) \quad (2\text{-}2)$$

其中，Attention 表示自注意力机制，LayerNorm 表示层归一化。BERT 模型通过堆叠 N 个这样的编码器层来提取深层次的语言特征。在预训练阶段，BERT 利用 MLM 和 NSP 任务来调整模型的参数，使其能够理解文本中的复杂依赖关系。预训练完成后，BERT 模型可以通过微调（fine-tuning）的方式适应各种特定的 NLP 任务，只需在预训练好的模型上添加少量任务相关的层即可。

自 BERT 问世以来，出现了许多基于 BERT 的变体模型，它们在原始 BERT 的基础上进行了改进或针对特定任务进行了优化。由 Facebook AI 在 2019 年提出的 RoBERTa 模型，通过动态掩码、扩充训练数据、去除 NSP 任务、使用更大的 batch size 和更长的训练时间，使得 RoBERTa 在多个 NLP 任务上超越了原始的 BERT 模型。而 BERT-wwm（BERT with Whole Word Masking）[61]在预训练阶段采用了全词掩码策略，当对文本中的词进行掩码时，如果选择了词中的一部分，不仅仅是词中的单个字符或子词，而是整个词都会被掩码。这可以使模型更好地理解整个词的含义，从而提高模型对文本的理解能力。BERT-wwm 特别适用于中文，因为中文词汇通常由多个字符组成，而这些字符单独出现时可能具有不同的含义。这种改进使得 BERT-wwm 在多个中文自然语言处理任务上表现更好。

2.4 基于 MVVM 架构的系统设计

基于 MVVM 架构的系统设计是近年来软件开发领域的一个重要趋势，尤其在构建客户端应用程序，如 Web 和移动应用程序时，其优势更加明显。MVVM 架构首先由 Microsoft 在 2005 年提出，旨在通过引入一个中介层 ViewModel 来分离用户界面（User Interface, UI）的表示和业务逻辑，从而提高应用程序的可维护性、可扩展性和测试性[62]。这种区分不仅有助于保持代码的组织性，还增强了应用程序的可维护性、可扩展性和测试性。

Model 层是应用程序的核心，包含了应用程序的数据和业务逻辑，负责数据的存取、数据模型的定义以及业务逻辑的实现，它独立于用户界面，并且不直接与 V

中国知网 https://www.cnki.net

iew 层交互。View 层包含了所有的用户界面元素，如按钮、文本框和布局容器等。View 层的主要职责是展示数据和响应用户操作，其设计应保持尽可能的轻量，不包含业务逻辑，仅负责数据的显示和基本的用户交互。View 层通常会通过数据绑定来与 ViewModel 层交互，这样可以保持 View 和 Model 的解耦，简化开发和测试工作。ViewModel 层则是 Model 和 View 之间的桥梁，它负责将 Model 的数据转换成 View 可以展示的形式，同时处理用户的输入并反馈到 Model 层[63]。ViewModel 也处理如数据验证、视图状态的保存和视图逻辑等任务，从而进一步减轻 View 层的负担。MVVM 整体结构见图 2-3。

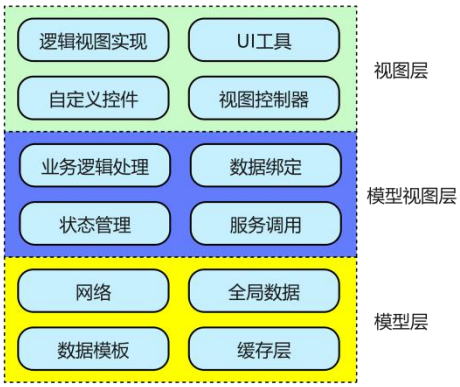


图 2-3 MVVM 架构
Figure 2-3 MVVM Architecture

在 MVVM 架构中，数据绑定是核心概念之一，它允许 View 层的元素直接绑定到 ViewModel 层的属性上，这样当数据发生变化时，UI 可以自动更新，反之亦然。这种双向数据绑定机制极大地简化了 UI 和业务逻辑之间的数据同步工作。

此外，MVVM 架构支持更好的关注点分离（Separation of Concerns, SoC）[64]，每一层都专注于处理自己的任务。这不仅使得开发更加模块化，也让单元测试变得更加容易。ViewModel 可以独立于 View 进行测试，因为它不依赖于任何具体的 UI 实现。

近年来，随着响应式编程（Reactive Programming）[65]的兴起，MVVM 架构在处理复杂的 UI 交互和数据流方面展现出了更大的潜力。通过结合使用观察者模式和响应式扩展，MVVM 能够更加高效地处理异步数据流和事件驱动的 UI 更新，从而提升了用户体验。

在实践中，MVVM 架构在前端开发中得到了广泛应用，尤其是在 Vue.js[66]和 React[67]等流行的 JavaScript 框架中。这些框架利用了 MVVM 的核心概念来提高应用程序的可维护性、可测试性和扩展性，同时简化了数据与 UI 之间的交互。

由 Evan You 创立的 Vue.js 是一款渐进式 JavaScript 框架，专为构建用户界面而设计。Vue 的核心库只关注视图层，易于学习且集成程度高，但它同时也能轻松

中国知网 https://www.cnki.net

配合其他库或现有项目使用。在 Vue 中，ViewModel 由 Vue 实例扮演，连接 Model 层的数据和 View 层的 DOM 表示[68]。Vue 的响应式系统能够自动跟踪依赖关系，并在数据对象的属性变化时通知视图进行更新，极大地减少了 DOM 操作的复杂性和开销[69]。

React 是由 Facebook 开发的一个用于构建用户界面的 JavaScript 库，通过采用声明式编程范式，使创建交互式 UI 变得简单。React 的核心理念是组件化，每个组件都代表着页面上的一部分 UI 元素[70]。尽管 React 本身并不是一个纯粹的 MVVM 框架，它更多地被描述为采用虚拟 DOM 的库，但它可以与 Redux[71]等架构模式一起使用，以实现类似于 MVVM 的数据流管理。React 组件（View 层）通过 props 和 state 与应用的模型层交互，而使用 Redux 等状态管理库可以充当 ViewModel，管理数据的状态和逻辑，从而使得组件更加专注于 UI 的呈现和用户交互。

然而，MVVM 架构也不是万能的，过度使用 ViewModel 或错误地管理数据绑定可能导致性能问题和难以追踪的 bug。因此，合理地使用 MVVM 架构，开发者在设计系统时必须考虑平衡其提供的便利和潜在的复杂性。

2.5 本章小结

本章主要探讨了医学影像标注系统设计与实现的核心技术和方法，包括自然语言处理与信息抽取技术、知识图谱技术、深度学习相关算法，以及基于 MVVM 架构的系统设计。每个部分都聚焦于特定的技术领域，展示了这些技术如何共同作用，以支持高效、精确的医学影像标注。

在“自然语言处理与信息抽取技术”部分，通过中文分词、词性标注、句法分析等步骤，将原始文本转换为更适合计算机处理的格式，为后续的知识图谱构建提供了结构化的医学信息，为医学知识的进一步整合和应用打下了基础。

在“知识图谱技术”部分，介绍了知识图谱的构建、管理和应用技术。通过运用自然语言处理、机器学习等技术，以及有效的知识库架构和算法设计，解决知识获取、大规模知识库管理、一致性维护和实时更新等问题。提出了知识图谱通过图形化方式组织知识，以便于查询和分析，而知识融合技术则解决了如何将多源信息有效合并以提升知识质量的问题。同时介绍了 Neo4j 图数据库如何通过其图形数据结构、查询语言 Cypher 和强大的 API 支持，高效地存储和查询大规模知识图谱，解决了数据表示、处理和一致性维护的问题。

在“深度学习相关算法”部分，探讨了深度学习在自然语言处理中的应用，特别是如何通过自动特征学习克服手动特征工程的挑战。首先回顾了 RNN 及其在

中国知网 https://www.cnki.net

捕捉序列数据动态特性方面的能力，以及其面临的梯度消失或爆炸问题。虽然LSTM 和 GRU 通过引入门控机制来缓解这些问题，但仍然受限于并行处理能力和复杂性。而注意力机制和 Transformer 架构通过直接计算序列中任意两个位置之间的依赖关系，显著提高了捕捉长程依赖的能力和训练效率。进一步地，介绍了 BERT 如何通过预训练和微调的方法，利用 MLM 和 NSP 来深入理解语言的上下文，使得模型能够在各种 NLP 任务中取得显著的性能提升，并探讨了如 RoBERTa 和 BERT-ww m 等基于 BERT 的模型变体，如何通过对原始模型的进一步优化，在特定的任务上实现了更好的性能。

最后介绍了“基于 MVVM 架构的系统设计”，该架构不仅促进了前后端的有效分离，提高了系统的可维护性和扩展性，也为用户提供了更加直观和友好的交互界面。

中国知网 https://www.cnki.net

3　面向医学影像标注的知识图谱设计与构建

目前，虽然拥有丰富的开放领域知识图谱资源以及一定数量的医疗领域专属知识图谱，这些资源在诸多领域都发挥了重要作用。然而，这些开放领域的知识图谱往往不适合直接应用于医学影像的标注工作。此外，尽管存在部分与医学相关的知识图谱，但它们往往局限于某一特定领域或应用场景，难以全面满足医学影像标注的复杂需求。

因此，本章节致力于设计并构建一个既符合医学专业要求又能高效服务于医学影像标注任务的知识图谱。从医学影像数据的特性出发，深入分析了影像标注所需的专业知识体系，包括但不限于解剖学、病理学以及临床医学等相关领域，构建一个既全面又深入的知识图谱，以支撑医学影像的精准标注和高效分析。本部分深入探讨了面向医学影像标注的知识图谱的设计与构建过程，将从以下几个角度进行分析。

首先是医学影像标注知识图谱的构建方法，鉴于辅助医学影像标注的知识图谱相关研究较少，在该部分介绍了在本研究中，知识图谱的构建流程。在确定了构建流程后，将进行知识图谱的结构设计，在对当前医学领域的知识图谱进行研究，并考虑到标注系统的需求后，本研究将以人体器官、组织、属性以及它们的正常和异常状态作为核心实体；随后是知识获取与整合，通过对医学教材与检查报告进行处理，得到构建图谱所需的知识基础，再进行存储；最后，基于已经构建的图谱将临床检查报告与图谱进行匹配，生成结构化文本辅助标注的数据。

3.1　医学影像标注知识图谱的构建方法

在构建医学领域的知识图谱时，通常采用两种主要方法：自顶向下和自底向上。自顶向下方法侧重于利用已有的结构化数据源，如百科类网站，通过提取这些高质量数据中的本体信息来建立知识库。而自底向上的方法则是偏向于从大量的公共数据中挑选出可靠信息，这些信息在加入知识图谱之前会经过严格的验证。

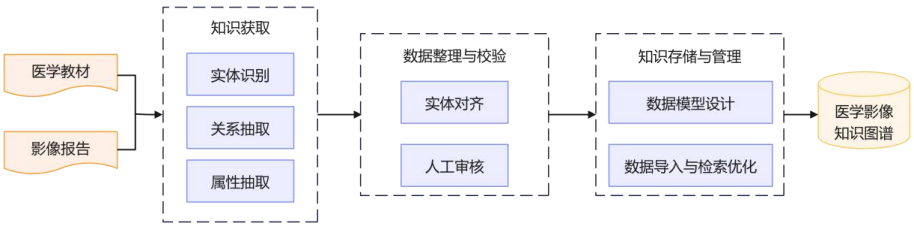


图 3-1　医学影像标注知识图谱构建过程

Figure 3-1 Construction Process of the Medical Imaging Annotation Knowledge Graph

中国知网　https://www.cnki.net

鉴于医疗领域知识的复杂多变性，采用自底向上的方式构建知识图谱在这一领域更为普遍。在本研究中，面向医学影像标注的知识图谱的构建过程如图 3-1 所示。

3.2 医学影像标注知识图谱的结构设计

作为现有医学影像知识的数字化表达形式，医学影像标注知识图谱的构建必须基于精细且合理的结构设计，并确保所包含内容的准确性和全面性。这一过程不仅需要医学专业知识的深入理解，还需将工程学科的方法论和技术手段进行有效整合。在知识图谱的架构设计上，要充分考虑到未来标注任务和系统开发的实际需求，确保图谱结构的灵活性和扩展性[72]。

本研究中构建的医学影像标注知识图谱，主要服务于标注系统，为操作人员提供必要的医疗知识支持。通过分析现有的医学知识图谱研究，并结合标注系统的具体需求，本文提出了一种针对医学影像的知识图谱架构设计方案。考虑到 pandas 提供的 read_csv 函数可以轻松加载 CSV 文件数据到 DataFrame 中[73]，再借助 py2neo 高效地与 Neo4j 图数据库交互，将数据结构化为图谱形式。因此采用 CSV 格式来实现知识的表达和结构化，利用 CSV 的简洁性和通用性，便于数据的管理和处理，其大致结构如表 3-1 所示。

表 3-1 CSV 文件结构
Table 3-1 Structure of CSV Files

System	Organ	Tissue	Attributes	AttributeValues
一组相互关联的器官和组织，实现特定生理功能的整体结构	被研究的具体器官，如肺部、心脏等	器官内的具体组织类型，如肺纹理、肺门等	与组织相关的特定属性，如数量、粗细、大小等	属性的可能取值，例如正常、增粗、增大等

3.3 医学影像标注知识图谱的知识获取与整合

在确定了知识图谱的结构后，构建主要分为三个部分：知识图谱数据收集、数据整理与校验以及知识存储。下面将详细介绍这几个方面的实现方式。

3.3.1 知识图谱数据收集

中国知网 https://www.cnki.net

数据是构建知识图谱的基石，因此，构建知识图谱的首要步骤是数据的采集。目前，在医疗领域中医学数据源可以分为结构化数据、半结构化数据以及非结构化数据三类。结构化数据是指那些以固定格式存储的信息，常见于医疗信息系统中，包含医学知识库、疾病信息库及临床管理数据等。半结构化数据则位于结构化数据和非结构化数据之间，它不符合严格的结构化数据格式，但又包含一些可识别的模式使得数据部分可被自动化工具解析。此类数据包括但不限于各类表格数据、网页内容、药品说明书以及某些医学检测数据（如心电图、脑电图）等。尽管这些数据不如结构化数据那样规范，但通过特定的工具和技术，可以提取出有用的信息。非结构化数据是指那些不易以传统数据库形式存储和管理的信息，主要包括医学研究文献、病例报告、医生的笔记及诊断报告等，尽管从非结构化数据中提取知识有助于丰富知识图谱，为其注入大量的实体和关系，形成有价值的三元组，但这个过程涉及到一系列复杂的处理[74]。

在本研究中，通过以下技术步骤实现了从医学教材和临床检查报告中提取、识别的目标。首先需要将医学教材和临床检查报告中的文本转换为可处理的数字格式，由于这些资料多以纸质文档形式存在，因此采用了 OCR 技术进行文本识别。在文本数据经过 OCR 转换后，接下来的任务是从中提取医学命名实体并识别这些实体之间的关系。为此，选择了具有强大的自然语言理解和生成能力的大型语言模型 GPT-4[75]，其主要任务为中文医学命名实体识别和实体关系抽取[76]。命名实体识别的目标是从文本中自动识别出与医学影像直接相关的实体，如器官、组织等，以及这些实体的相关属性和属性值。在本研究中，通过训练 GPT-4 识别特定的医学术语和表述，能够让模型准确地从医学文本中提取出所需的实体信息。在识别出实体之后，通过实体关系抽取进一步确定这些实体之间的语义关系。例如识别出不同器官和组织之间的关系，以及这些器官或组织的属性之间的关联。

在本章节构建的知识图谱旨在为标注系统提供专业的知识支持，鉴于这一应用场景对数据的准确性和可靠性有着极高的要求，本研究选择了以下数据源：

(1) 全国中医药行业高等教育“十四五”规划教材《医学影像学》[77]。这本教材中包含的数据属于半结构化类型，既包含了丰富的专业知识，又具备一定的组织结构。数据类别涵盖了解剖区域、生理结构、常态特征及病态特征等方面。

(2) 全国中医药行业高等教育“十四五”规划教材《系统解剖学》[78]中的信息也呈现为半结构化形式，融合了深入的解剖学理论和实践知识，并按照明确的逻辑结构进行组织。此教材覆盖的内容包括各个身体系统的详细解剖、组织结构、功能特性以及相互关系等关键领域。

(3) 医学检查数据，尤其是医学影像报告，通常呈现为非结构化格式，蕴含了丰富的医疗专业知识和细节。这些报告一般包括影像的解析、特征描述以及基于

中国知网 https://www.cnki.net

影像的初步诊断意见，主要以自然语言文本的形式呈现，缺乏统一的数据结构。从这些文本中，可以提炼出关于患者特定解剖结构的观察、疾病特征的描述以及可能的医学条件推断，这些信息对于疾病的诊断和治疗具有重要价值。

3.3.2 数据整理与校验

本部分将探讨数据整理与校验的关键步骤，通过医学教材和检查报告得到的原始数据中包含很多与本文所要构建的知识图谱无关的信息，因此需要对收集的数据进行实体对齐与人工审核与校对等操作，为后续的分析和应用奠定坚实基础。

在实体对齐阶段，使用预先构建的术语字典和分类体系，对数据中的关键实体进行标准化处理和对齐。例如，不同报告中可能使用不同的术语来描述同一病理特征或诊断结果，通过字典匹配和实体对齐，可以统一这些表达，以提高数据的一致性和可用性。

GPT-4 处理后，提取的实体和关系信息被存储为 CSV 文件，方便后续的分析和处理。CSV 文件以表格的形式组织数据，每一行代表一个实体或实体之间的关系，列包括但不限于实体名称、属性、属性值等。考虑到自动化处理过程可能存在误差，于是通过人工审核的方式对数据进行细致审查，识别并修正自动处理过程中可能遗漏或错误解析的信息。由于自动化工具可能无法完全准确地处理所有情况，特别是在面对复杂的医学文本和术语时，所以这一步是整个流程中不可或缺的一部分。专业的医学人员会定期审查 CSV 文件中的数据，确保实体识别和关系抽取的准确性。在必要时，人工审核员会对数据进行更正或补充，以保证知识图谱的质量和可靠性。在清除和纠正原始数据中的错误后，便可对数据进行格式化处理。以胸部 CT 知识图谱为例，结合胸部影像学特征和医学影像标注任务的需求，本研究将其分为系统名称、器官名称、组织名称、属性名及属性值 5 大类数据项，在医学教材和检查报告中均可找到相应的关联数据。

3.3.3 知识存储与管理

目前，知识图谱存储方式主要分为关系型数据库、图数据库、NoSQL 数据库等。关系型数据库如 MySQL[79]通过表结构来存储数据和关系，易于理解和使用，但在处理大量复杂关系时可能效率不高。NoSQL 数据库如 MongoDB[80]适合存储结构化不强的大数据，提供高扩展性和灵活的数据模型，但可能缺乏一些复杂查询的支持。图数据库则是专门用于存储和操作图形结构的数据，如 Neo4j，专注于存储和查询图形数据结构，自 2007 年以来被广泛应用于各种行业，能高效处理复

中国知网 https://www.cnki.net

杂的网络结构和关系，尤其是深度关联查询时表现出色。本研究选择 Neo4j 作为知识图谱的存储方式，可以充分利用其在处理复杂关系和图结构方面的优势，提高查询效率和数据处理能力。

在完成了对数据的收集、整理、校验后，即可对这些数据进行存储与管理，主要任务如下：

(1) CSV 文件准备：数据收集和准备的阶段，需要确保 CSV 文件中的数据结构适合转换成图形结构。并确保数据的一致性和完整性，包括检查并处理缺失值、错误格式、重复记录等问题。

(2) 存储结构设计：设计图谱的存储结构，包括定义图中的节点（实体）、边（实体间的关系）以及它们的属性。节点（实体）代表图中的对象，如系统、器官、组织等，节点应有明确的标签和唯一标识。边表示节点之间的连接和关系，边不仅链接两个节点，还可以包含关系的属性。

(3) 数据读取：编写脚本以实现读取 CSV 文件并创建对应的结构，通过使用 Python，结合图数据库的 API，将 CSV 中的每一列适当地映射到图的节点或边的属性上。

(4) 数据存储：将构建好的图谱数据创建节点和边，并将它们正确关联，实际存储到数据库。

(5) 生成图谱：数据存储完成后，可通过可视化工具和查询功能来生成和查看图谱，探索数据间的关联和模式。

整体流程如图 3-2 所示。

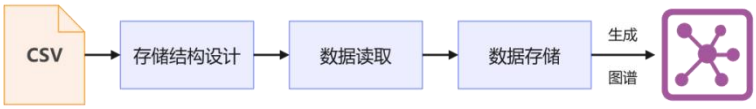


图 3-2 数据存储流程

Figure 3-2 Data Storage Process

接下来使用 Py2neo 这一强大的 Python 库来操作 Neo4j，构建知识图谱。Py2neo 提供了一套简洁的 API，通过编写 Python 脚本，可以轻松地连接到 Neo4j 实例、创建和修改图中的节点和关系、执行 Cypher 查询以及处理查询结果。在使用 Py2neo 构建知识图谱的过程中，首先利用 pandas 这样的数据处理库来读取 CSV 文件，使用 pandas.read_csv 即可将数据加载到 DataFrame 中，然后可以遍历这些数据，为每一行数据创建图中的节点和关系。使用 Py2neo 创建节点需要实例化 Node 类，并指定节点类型以及任何必要的属性。例如，Node("Organ", name="肺部") 创建了一个表示器官的节点，名字为肺部。类似的，关系的创建通过 Relationship 类实现，它可以指定两个节点之间的关系类型和属性，如 Relationship(organ_node, "HAS",

中国知网 https://www.cnki.net

tissue_node)表示器官节点包含组织节点。最后，通过 Graph 类连接到 Neo4j 数据库，并使用该类的方法如 create 来将节点和关系添加到图中。此外，Py2neo 还支持执行 Cypher 语言查询，允许更复杂的数据操作和分析。以肺纹理组织为例，图 3-3 展示了系统、器官、组织、属性与属性值的关系。

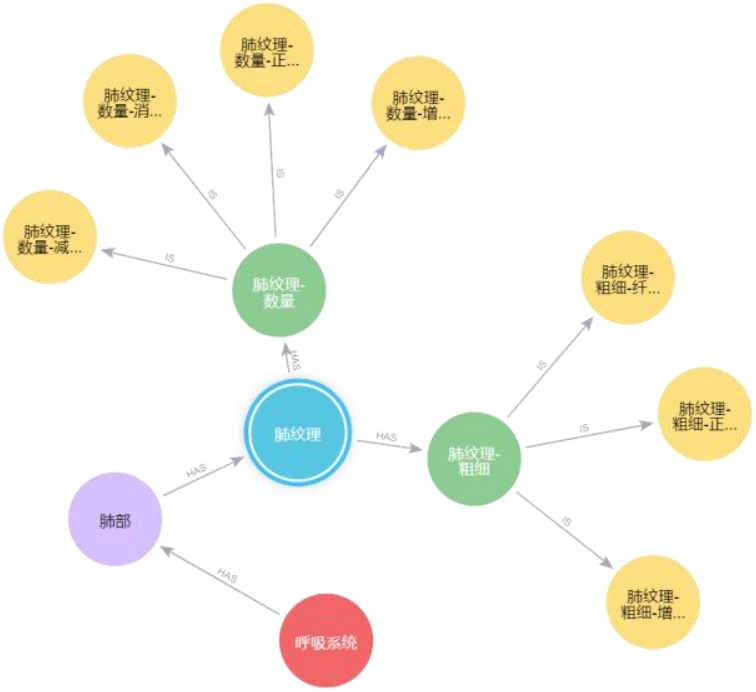


图 3-3 节点间关系

Figure 3-3 Relationship Between Nodes

对于已构建的知识图谱进行统计分析，结果显示，图谱共包含了 746 个实体节点，详细统计情况见表 3-2。

表 3-2 实体节点数量及占比

Table 3-2 Number and Proportion of Entity Nodes

生理系统	结点数量	占比
中枢神经系统	145	19.44%
头颈部	129	17.29%
呼吸系统	166	22.25%
循环系统	124	16.62%
消化系统	111	14.88%
骨骼与肌肉系统	71	9.52%
总数	746	100%

中国知网 https://www.cnki.net

本文构建的医学影像标注知识图谱的部分内容如图 3-4 所示，其中红色节点为系统，紫色节点为该系统包含的器官，蓝色节点为器官下的组织，绿色节点为组织具有的属性，黄色节点为属性所对应的属性值。



图 3-4　部分医学影像标注知识图谱

Figure 3-4 Partial Medical Imaging Annotation Knowledge Graph

3.4　本章小结

本章节深入探讨了构建适用于医学影像标注任务的知识图谱的过程。这一过程涵盖了知识图谱的构建方法、结构设计，与如何收集、整理和校验知识图谱数据，以及知识存储。由于采用了 GPT-4 技术从医疗影像学习资料及临床诊断报告中提取和整理数据，为了确保数据的一致性和准确性，采用了基于词典的方法来对关键数据点，如器官、组织和属性进行实体对齐和人工审核。在完成数据的整合和验证工作后，通过编写 Python 脚本与图数据库进行交互，包括数据的批量导入、建立数据间的关联关系，高效地将构建好的知识图谱导入存储，确保知识图谱在图形数据库中的结构化存储，以便未来进行高效的查询和分析，并为实现医学影像的文本辅助标注提供支持。

中国知网　https://www.cnki.net

4 结构化文本辅助医学影像标注的方法与实现

为了使标注人员能够迅速理解临床检查数据，并能够在图像中高效地手动圈定病变区域，从而完成对医学影像的精准标注工作，本研究采用了一种结构化文本辅助标注的策略。这种方法通过直观的文本提示，不仅极大地降低了标注人员在识别和定位病变区域时的难度，从而提高了标注的准确性和效率。

4.1 结构化文本辅助医学影像标注的方法

这一方法的核心思想是使用前沿的自然语言处理技术，对临床影像检查报告中大量的非结构化数据进行深入分析。这一过程涉及多个关键步骤，目的是将复杂、难以解读的临床检查报告数据转化为有组织、易于理解和操作的结构化信息，从而极大地提高标注人员对影像数据的解读速度和准确性，为医疗决策提供坚实的数据支持。

首先，研究中采用了命名实体识别技术，用于识别输入系统的临床影像学表现文本中关键的医学实体，如器官、组织、症状、属性与属性值等。随后，将这些经过处理的数据与第三章构建的医学影像标注知识图谱相结合，将非结构化的临床数据被转化为有组织、易于理解的结构化信息，再把结构化信息以直观且易于解读的可视化形式呈现。通过使用树状图、彩色标记和影像注释等方式，突出显示各种器官和组织的特性及其状况，以及异常区域的确切位置和可能的性质，其流程如图 4-1 所示。

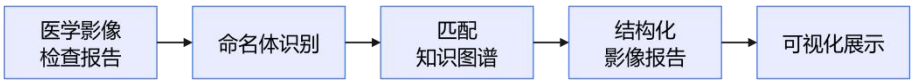


图 4-1 结构化文本辅助标注实现流程
Figure 4-1 Workflow of Structured Text Assisted Annotation

结构化文本辅助标注功能有助于医学专业人员更快、更准确地解读影像数据，从而提高了标注的效率和准确性。

4.2 基于预训练模型的医疗命名实体识别

4.2.1 BERT 及其变体模型

中国知网 https://www.cnki.net

在自然语言处理领域，BERT 及其变体模型如 ERNIE 和 RoBERTa 已成为处理各种文本任务的核心技术。这些模型都基于 Transformer 架构，通过大规模预训练捕获深层次的语言特征，从而能够在多种下游任务中实现显著的性能提升。

BERT（Bidirectional Encoder Representations from Transformers）的创新之处在于采用双向 Transformer，允许模型同时考虑到单词左右两侧的上下文信息，从而获得更为丰富的词义表示。BERT 的预训练包括两个主要任务：掩码语言模型（MLM）和下一句预测（NSP），这两个任务共同促使 BERT 学习到强大的语言表示能力。在 BERT 的训练过程中，MLM 任务是通过随机选择输入序列中的一部分词（约 15%），将它们替换为特殊的 [MASK] 标志，然后让模型预测这些被遮蔽（或掩码）的词的原始词汇，其实现如图 4-2 所示。

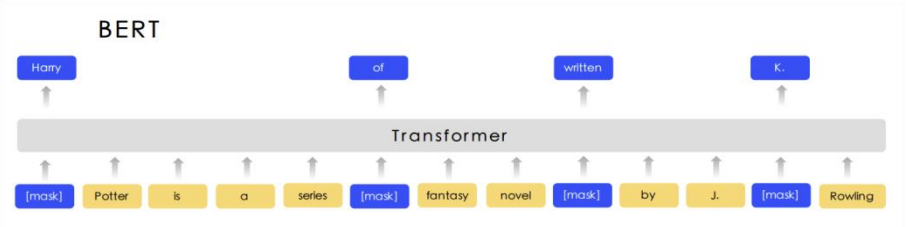


图 4-2 BERT MLM 策略
Figure 4-2 BERT MLM Strategy

RoBERTa 由 Facebook 在 2019 年提出，是 BERT 的一个改进版本，通过几个关键的策略优化来增强模型的性能。首先，它去除了 BERT 原始架构中的下一句预测任务，这一任务被认为对于模型性能提升不是必要的。同时，RoBERTa 通过大幅增加训练数据量，进一步扩展了模型的知识范围和理解能力。此外，RoBERTa 对训练策略进行了微调，包括使用更大的批次大小和更精细的学习率调整，这些改动共同提升了模型的学习效率和最终性能。RoBERTa 的研究还特别强调了长时间训练和较大批次大小在提升模型表现中的重要作用，表明在资源允许的情况下，这些因素可以显著提升深度学习模型的效果。通过这些综合优化措施，RoBERTa 在多项自然语言处理任务上取得了比原始 BERT 更优越的成绩，展现了持续优化和调整预训练语言模型的巨大潜力。

ERNIE（Enhanced Representation through kNowledge IntEgration）[56]是百度推出的一款百亿参数大模型，其核心思想是利用大规模语料库进行预训练，同时引入知识图谱中的知识，以提升模型的语义表示能力。ERNIE 模型基于 Transformer 结构，与 BERT 模型类似，但引入了全新的预训练任务设计，对各种类型的知识进行建模，从而改善自然语言理解任务的性能。通过多粒度知识建模，使 ERNIE 不仅关注词的表示，还关注短语、实体和句子的表示。这种多粒度的知识建模有助于捕捉语言中的丰富结构。同时，连续语义融入策略可以在预训练阶段，让 ERNI

中国知网　https://www.cnki.net

E 将实体识别和语义关系挖掘融入其中，从而更好地理解句子的语义。最后，ERNIE 利用大量的知识图谱数据，在预训练阶段将结构化知识融入到模型中，提高了模型的知识表示能力。ERNIE 在多个自然语言处理任务中取得了显著的性能提升，如阅读理解、命名实体识别和情感分类等。通过全局目标语言模型的机制，ERNIE 在命名实体识别任务中能够更好地捕捉实体之间的关系，提高了准确率和鲁棒性。同时，ERNIE 通过有效地融合了领域知识，大幅提升了文本分类任务的准确性。ERNIE 将知识分为三个层次，分别是标记级别（Token-Level）、短语级别（Phrase-Level）以及实体级别（Entity-Level）。利用对这三个级别的对象进行 Masking，实现了模型对单词、短语知识理解能力的提升，该策略的图示见图 4-3。

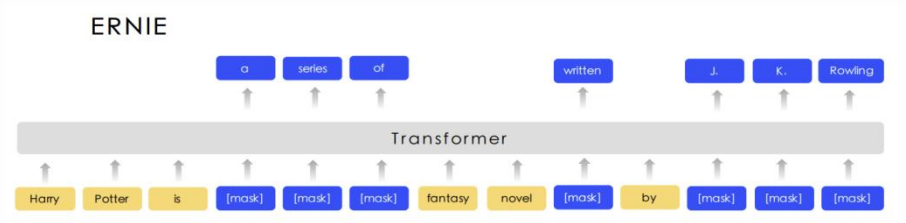


图 4-3 Knowledge Masking 策略
Figure 4-3 Knowledge Masking Strategy

4.2.2 整词掩码技术

整词掩码技术通常被称为全词 Mask 或整词 Mask，是谷歌在 2019 年对 BERT 模型的一个重要升级，致力于更加有效地理解和处理语言信息，其核心是改进原始 BERT 预训练阶段的训练样本生成策略。

在原始的 BERT 模型中，预训练阶段使用了基于 WordPiece[81]的分词方法，这种方法会将一个完整的词分割成若干个子词。在生成训练样本时，这些子词可能会被随机选中并进行 mask 操作。mask 操作具有广义性，不仅仅是将单词替换成[MAS K]标记，还包括保持原词不变或随机替换成另一个词。这种方法的问题在于，分割的子词可能无法完全捕捉到整个词汇的语义，尤其是当这些子词在不同的上下文中有不同的含义时。

WWM 的核心改进在于，如果一个词的任何部分（基于 WordPiece 分割的子词）被选中进行 mask 操作，那么属于同一词汇的其他所有部分也将被一同 mask。这意味着整个词汇作为一个单元被考虑，从而提高了模型对词汇完整语义的理解能力。

在中文的应用中，由于谷歌官方发布的 Bert-base-chinese 模型是以单个汉字为切分粒度，没有考虑到传统的中文分词，这就忽略了汉字组合成词时的语义信息[82]。

中国知网 https://www.cnki.net

而如果将 WWM 技术应用到中文中，可以在一定程度上克服这种限制。同时，选择 Chinese Wikipedia 作为训练材料，采用哈尔滨工业大学语言技术平台提供的 LTP 分词工具，将组成同一个词的所有汉字一同 mask，从而促使模型更好地理解和处理中文词汇的整体语义。全词 Mask 的生成样例如图 4-4 所示。

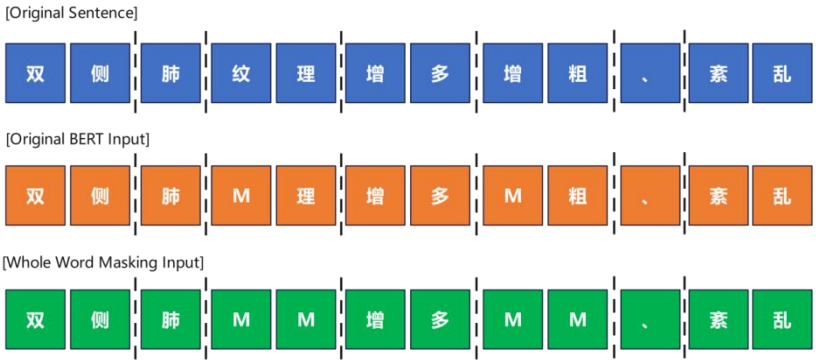


图 4-4 wwm 样例

Figure 4-4 WWM (Whole Word Masking) Example

通过将 WWM 技术应用于中文，不再单独对每个中文字符进行 Masking，而是将连续的词语作为一个整体进行 Masking，使得模型能够更好地捕捉词语之间的语义关系，有效地增强了模型对中文语言结构的理解，提高了模型在处理中文文本时的准确性和效率。

4.2.3 条件随机场

条件随机场是一种常用于标注和分割序列数据的统计建模方法，最早由 Lafferty 等人在 2001 年的 *Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data* 中提出。CRF 用于给定一组输入随机变量条件下另一组输出随机变量的条件概率分布模型，它假设输出变量形成一个马尔科夫随机场。在序列建模任务中，给定观测序列$X=(x_1,x_2,\ldots,x_n)$，CRF 会建模标注序列$Y=(y_1,y_2,\ldots,y_n)$的条件概率$P(Y|X)$。

对于线性链条件随机场，即每个标记y_i仅依赖于其前一个和后一个标记，在给定观测序列X的情况下，标记序列Y的联合概率可以表示见式（4-1）。

$$P(\boldsymbol{Y}|\boldsymbol{X})=\frac{1}{Z(\boldsymbol{X})}exp(\sum_{i=1}^{n}\sum_{k}\lambda_k f_k(y_{i-1},y_i,\boldsymbol{X},i)+\sum_{i=1}^{n}\sum_{l}\ \mu_l\, g_l(y_i,\boldsymbol{X},i)) \quad (4\text{-}1)$$

其中λ_k和μ_l是模型参数，f_k是定义在转移y_{i-1}到y_i上的特征函数，用于捕捉相邻标记之间的依赖关系，g_l是定义在当前位置i的状态y_i和观测X上的特征函数，用于捕捉观测和标记之间的依赖关系，$Z(X)$是规范化因子，确保概率分布的总和为 1，由式（4-2）可得。

中国知网　https://www.cnki.net

$$Z(X) = \sum_Y exp(\sum_{i=1}^{n}\sum_k \lambda_k f_k(y_{i-1}, y_i, X, i) + \sum_{i=1}^{n}\sum_l \mu_l g_l(y_i, X, i)) \quad (4\text{-}2)$$

CRF 模型的训练通常涉及最大化观测到的标记序列的对数似然函数，可能通过梯度下降等优化算法来求解模型参数λ_k和μ_l。

通过在预训练模型之后添加 CRF 层，可以有效地利用序列中的依赖关系来提高实体识别的准确性。预训练模型（如 BERT、ERNIE、RoBERTa）通过在大规模语料上进行预训练，能够学习到丰富的语言表示，包括词汇、句法和语义信息，能够为下游任务提供强大的特征表示基础，而 CRF 层则专注于优化序列标注任务的输出，通过建模标签之间的转移概率，能够在整个序列级别上做出更加连贯和一致的预测。将预训练模型和 CRF 相结合，可以有效地利用各自的优势，提升命名实体识别的整体性能，特别是在处理医学文本等专业领域内的复杂实体时，提升对医学文本中复杂实体的识别能力，其任务的设计为，在顶层增加 CRF 层，如图 4-5 所示。

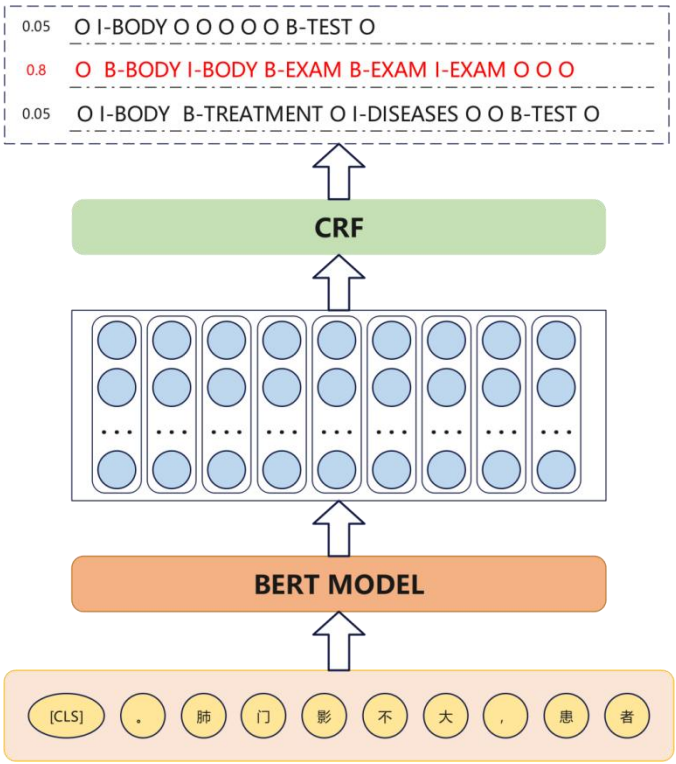


图 4-5 BERT-CRF 模型结构图

Figure 4-5 BERT-CRF Model Structure Diagram

4.3 实验结果与分析

4.3.1 实验环境

中国知网 https://www.cnki.net

在本研究中采用了 PyTorch 构建和训练模型，开发和训练过程基于 Python 编程语言完成，主要软硬件配置及版本信息如表 4-1 所示。

表 4-1 软硬件配置及版本信息
Table 4-1 Software and Hardware Configuration and Version Information

硬件配置	CPU	AMD EPYC 7002
	内存	48GB
	GPU	RTX 4090
	显存	24GB
软件环境	操作系统	ubuntu22.04
	Python	3.10
	PyTorch	2.1.0
	CUDA	12.2

4.3.2 实验数据

本研究采用了 CCKS2019 面向中文电子病历的命名实体识别数据集，进行命名实体识别（NER）任务，该任务中预定义了 6 种实体类型，包括解剖部位、影像检查、手术、实验室检验、疾病和诊断、药物。由于原始数据集的覆盖范围可能有限，特别是在医学影像标注所需的实体类型上，如影像检查相关的关键字。本研究在原有数据集基础上，自行标注了额外的临床医学影像学表现文本数据，从而扩展了数据集的范围和应用深度。

在数据处理阶段，首先将原始的电子病历数据按照文本（text）和标签（label）进行提取。随后，为了进行有效的序列标注，采用了 BIO 标注方式对文本数据中的实体进行标记。在 BIO 标注方法中，在这种标注方法中，每个词（或字符）都被标注为三种可能的标签之一，“B”代表实体的开始，“I”代表实体的内部，“O”代表非实体部分。BIO 标注方法较为简洁，易于理解和实现，其优点在于它能够清晰地划分出每个实体的边界，使得模型更容易区分和理解各个实体，为后续的模型训练提供了准确的标注数据，从而提高了模型的性能和鲁棒性。整个数据集涵盖各类型共 5949 个标注实体，数据集中各个样本类别的分布情况如表 4-2 所示。

中国知网 https://www.cnki.net

表 4-2 实体基本信息
Table 4-2 Basic Information of Entities

实体类型	中文含义	实体数量	示例
BODY	解剖部位	3079	两 B-BODY 肺 I-BODY
EXAMINATIONS	影像检查	345	胸 B-EXAMINATIONS 部 I-EXAMINATIONS C I-EXAMINATIONS T I-EXAMINATIONS
TEST	实验室检验	572	白 B-TEST 细 I-TEST 胞 I-TEST
DISEASES	疾病和诊断	1311	直 B-DISEASES 肠 I-DISEASES 癌 I-DISEASES
TREATMENT	手术	162	气 B-TREATMENT 管 I-TREATMENT 插 I-TREATMENT 管 I-TREATMENT
DRUG	药物	480	阿 B-DRUG 司 I-DRUG 匹 I-DRUG 林 I-DRUG
TOTAL	总计	5949	

4.3.3 评估指标

在评估一个模型的性能时，通常采用以下三种关键指标来衡量：精确率(Precision)、查全率(Recall)、F1 得分(F1-Score)。这些指标通过混淆矩阵的不同组合计算得到，能够提供对模型表现的全面理解，如表 4-3 所示。

表 4-3 混淆矩阵
Table 4-3 Confusion Matrix

实际\预测	正例	负例
正例	真正例（TP）	假负例（FN）
负例	假正例（FP）	真负例（TN）

精确率是衡量模型在预测为正类别的情况下，实际为正类别的比例。它反映了模型预测正类别的准确性。精确度的计算公式如公式（4-3）所示。

$$Precision = \frac{TP}{TP+FP} \quad (4\text{-}3)$$

其中真正例是模型正确预测为正的样本数，假正例是模型错误预测为正的样本数。

其次，查全率也被称为召回率，是衡量模型找到所有实际正类别的能力，它表示模型能够检测到的正类别样本的比例。召回率的计算公式见式（4-4）

中国知网 https://www.cnki.net

$$Recall = \frac{TP}{TP+FN} \quad (4\text{-}4)$$

其中假负例是模型错误地预测为负的样本数。

最后，F1 得分是精确率和召回率的调和平均值，用于综合反映两者的平衡性。当模型的精确率和召回率都较高时，F1 得分也会较高，表明模型的性能较好。F1 得分的计算公式如式（4-5）所示。

$$F1 - Score = \frac{2PR}{P+R} \quad (4\text{-}5)$$

通过综合考虑精确率、召回率和 F1 得分这三个指标，能够全面评估一个模型在不同方面的性能，从而在实际应用中做出更加合理的选择和调整。

4.3.4 实验策略

本次实验选取了来自 Hugging Face[83]的 Transformers 库的三个模型作为研究基础，采用 bert-base-chinese 模型作为实验的基线模型，作为专门为中文文本设计的 BERT 模型，已被广泛证明在多种中文 NLP 任务上具有良好的性能。为了进行全面的性能对比，还同时选取了 ernie-3.0-base-zh 和 chinese-roberta-wwm-ext 两种模型。ernie-3.0-base-zh 是基于 BERT 架构的变体，通过增加了知识增强的预训练任务，可以捕获更丰富的语义信息。chinese-roberta-wwm-ext 则是 RoBERTa 模型的一个针对中文优化的版本，采用了整词掩码的策略，以提高模型对中文文本的理解能力。

为了增强各模型在命名实体识别任务中的表现，本实验在每个预训练模型的顶部增加了一个 CRF 层。CRF 层利用其序列建模的优势，以更准确地预测实体的边界和类别。通过结合预训练模型和 CRF 层的方法，充分利用预训练模型深层次的语言理解能力和 CRF 在序列数据建模方面的优势，从而在复杂的自然语言处理任务中实现更高的准确率和效率。

4.3.5 实验与结果

实验中采用了 AdamW 优化器[84]对模型进行训练，设置了批量大小为 64，学习率 $3e-4$，同时为了防止模型过度拟合训练数据，增强模型的泛化能力，在嵌入层输出和全连接层之间集成了 Dropout 机制，并设置了$P_{dropout} = 0.1$。为了提升模型的训练效果并缓解梯度更新过大可能引起的训练不稳定，提升模型的训练效果，还实施了 warm-up 策略[85]，在该阶段学习率从零开始，逐渐增加到预设的最大值 $3e-4$，通过这种方式，模型在训练初期可以以较小的步长进行参数更新，有助于避免梯度更新过大导致的训练不稳定现象。随着训练的进行，学习率逐渐

中国知网 https://www.cnki.net

达到最大值，从而使模型能够有效地探索参数空间，加快学习进度。实验将在 40 个 epoch 内完成整个训练过程，以确保模型能够充分学习并吸收数据集中的特征。最终实验结果如表 4-4 所示。

表 4-4 实验结果
Table 4-4 Experimental Results

	准确率	精确率	召回率	F1 值
BERT-CRF	0.922	0.803	0.656	0.722
ERNIE-CRF	0.915	0.738	0.658	0.696
RoBERTa-WWM-CRF	**0.938**	**0.819**	**0.744**	**0.780**

经过对实验结果的综合分析，可以观察到基线模型 BERT-CRF 在命名实体识别任务中表现优异，在 F1 值方面可以达到 72.2%，充分证明了该模型能够有效处理此类任务。与此相比，采用 RoBERTa-WWM-CRF 模型后可以发现，模型在特征提取上的显著增强，与 BERT-CRF 相比，模型的各项评价指标有了显著提升，其中精确率提高了约 1.5%，召回率更是提升了高达 8.8%，F1 值提升 5.8%，达到了 78.0%。然而 ERNIE-CRF 模型在本实验中的表现未能达到预期，相较于基线模型，其各项指标均有所降低，精确率降低了约 6.5%，仅有 73.8%，F1 也降低了 2.6%，仅有 69.6%。

表 4-5 六类实体实验结果
Table 4-5 Experimental Results for Six Types of Entities

实体	RoBERTa-WWM-CRF			ERNIE-CRF			BERT-CRF			实体
类别	精确率	召回率	F1 值	精确率	召回率	F1 值	精确率	召回率	F1 值	数量
BODY	0.825	**0.892**	**0.857**	0.701	**0.842**	0.765	0.805	**0.856**	**0.830**	3079
EXAMS	0.812	0.565	0.667	0.714	0.072	0.132	0.819	0.301	0.441	345
TEST	0.875	0.463	0.606	0.725	0.194	0.306	**0.898**	0.215	0.347	572
DISEASES	0.796	0.703	0.747	0.684	0.549	0.609	0.764	0.637	0.695	1311
TREAT	0.772	0.438	0.559	0.864	0.117	0.207	0.638	0.228	0.336	162
DRUG	**0.878**	0.779	0.826	**0.876**	0.708	**0.783**	0.871	0.631	0.732	480

从表 4-5 中的数据可以了解到在该数据集上 RoBERTa-WWM-CRF 和 ERNIE-CRF 两种模型对六个不同类别实体识别的表现。结果显示，两种模型在识别解剖部位（BODY）这一类别时表现最佳，F1 分数分别为 85.7%和 76.5%。然而，在识别手术（TREATMENT）类实体时，各模型的表现却不尽如人意，特别是 ERNIE-CRF

中国知网 https://www.cnki.net

模型，其 F1 分数仅为 20.7%。初步推测，这可能与数据集的标注质量参差不齐以及手术实体样本分布不均有关。在训练集中，手术实体的标注数量相对较少，这可能导致模型在识别此类实体时遇到困难，从而影响了整体的识别效果。

通过对本次实验的结果分析，三种中文预训练模型性能差异可能源于模型结构的差异，BERT、RoBERTa 和 ERNIE 虽然都基于 Transformer 架构，但它们在预训练任务和技术上存在差异。例如，RoBERTa 取消了 BERT 的 NSP 任务，在预训练阶段采用了更长的训练时间和更大的数据集，这可能提高了模型的泛化能力和语言理解能力，从而在命名实体识别任务中表现更好。而 ERNIE 结合了实体识别等任务进行预训练，有助于模型更好地理解实体信息，但在本实验中未能充分发挥优势。

总体而言，在本次命名实体识别任务中，RoBERTa-WWM-CRF 的表现最为优秀，其性能优越性主要源于模型结构的改进、更合适的预训练任务、更强大的特征提取能力等因素的综合作用，这为进一步优化命名实体识别任务提供了重要参考。

4.4 结构化文本辅助标注的实现

4.4.1 实体与图谱匹配策略

对于未经处理的非结构化医学影像检查报告，需要首先对其进行分句处理。利用正则表达式的方法，将文本按照常见的分隔符，包括标点符号、空格等，进行拆分。Python 中的 re 模块提供了一套强大的正则表达式工具，其中的 re.split 函数可以通过正则表达式指定复杂的分割规则，从而高效地将整段的文本报告分割为单独的句子。

胸廓基本对称，
双肺纹理增多、增粗、紊乱，
双肺透亮度增高，
双上肺见弥漫性小斑片低密度影，
右肺上叶见小斑片影，
两肺门不大，
纵隔居中，
其内未见明显肿大淋巴结影，
心影不大，
主动脉及冠脉可见钙化斑。
所及肝脏见小结节密度灶。

图 4-6 分句结果
Figure 4-6 Sentence Segmentation Results

在分句操作完成后，将每个句子存入一个列表中，对一段非结构化医学影像

中国知网 https://www.cnki.net

检查报告的分句结果结果如图 4-6 所示。

随后，遍历刚刚得到的句子列表，对于每个句子，使用训练好的命名实体识别模型来提取医学相关的实体，如器官、组织、属性等。如上图中分割后的单句“双肺纹理增多、增粗、紊乱”经过抽取得到的实体信息为[“双肺”, “纹理”, “增多”, “增粗”, “紊乱”]。提取的实体可能包含各种同义词或变体，使用同义词表将它们映射到标准化的术语上，以便能够与知识图谱中的实体进行匹配。通过编写的 Python 脚本，使用 Py2neo 库连接到 Neo4j 数据库，根据提取和标准化的实体信息查询知识图谱。检索与这些实体匹配的图谱节点，并提取相关的器官、组织信息。最后将查询结果整合，并根据需要进行修改或扩展，生成包含异常属性和相关医学实体的结构化 JSON 文件，其形式如图 4-7 所示。


```
{
  "肺部": {
    "影像异常": ["斑片影"],
    "肺纹理": {"粗细": ["增粗"], "数量": ["增多"], "走行": ["紊乱"]},
    "肺野": {"透亮度": ["增高"]}, "肺门": {"大小": ["缩小"]}
  }
}
```


图 4-7 异常属性输出

Figure 4-7 Output of Anomalous Attributes

通过以上流程，可以有效地将医学影像报告等非结构化数据转化为结构化数据，便于后续的存储、查询和分析。

4.4.2 结构化文本的可视化

在获得了包含医学检查报告中异常信息的结构化 JSON 数据后，将 JSON 格式的数据转化成易于阅读和分析的形式，对于标注人员至关重要。为了实现这一目标，本研究使用了基于 Element Plus 的 Virtualized Tree 组件在 Vue 应用中实现高性能的数据可视化。该组件通过虚拟化技术优化了大量数据的渲染，只渲染视口内的节点，从而显著提高了渲染效率，即使是在数据量庞大的情况下也能保持流畅的用户体验。使用 Virtualized Tree 来展示带有树状结构的数据，不仅提供了一个直观的信息架构视图，还允许标注专家通过折叠和展开节点来灵活控制信息显示的层级。通过为不同类别的数据节点分配特定的颜色，例如，将正常属性用绿色标示，异常属性用红色标示，可以进一步提高信息的辨识度和可读性，如图 4-8 所示。

中国知网 https://www.cnki.net



图 4-8 结构化文本辅助标注树

Figure 4-8 Tree of Structured Text Assisted Annotation

Virtualized Tree 组件还支持交互操作，如手动添加、删除和修改节点，这对于标注人员在校对数据、修正漏标、多标或误标等问题时至关重要。这样的交互设计不仅提高了数据校对的效率，也保证了数据质量的准确性和可靠性。通过集成 Virtualized Tree 组件，可以将结构化的 JSON 数据转换成一种更加人性化和互动性强的格式，极大地提高了数据的可用性和易用性，使得专家能够更高效、更准确地进行工作。

4.5 本章小结

本章节主要探讨了如何构建与实现文本辅助标注。在结构化文本辅助医学影像标注的方法中，分析了将复杂的临床检查报告转换为结构化信息的过程。该过程包括利用命名实体识别技术提取关键医学实体，并将这些信息与知识图谱结合，进而生成易于理解的结构化数据，帮助标注人员更快更准确地解读影像数据，从而极大地简化了标注人员识别和定位病变区域的难度。在命名体识别实验部分，详述了 BERT 及其变体模型在处理文本任务中的优势。通过双向 Transformer 架构，这些模型能够捕捉到深层次的语言特征，提高了在多种下游任务中的性能。ERNIE 模型通过融入知识图谱的信息，进一步增强了模型的语义表示能力。而 RoBERTa 模型通过优化策略，如去除下一句预测任务、增加训练数据量和微调训练策略，实现了性能的显著提升。本研究通过对比 BERT-CRF、RoBERTa-WWM-CRF 和 ERNIE-CRF 模型在命名实体识别任务上的表现，发现 RoBERTa-WWM-CRF 模型在多项评价指标上均有显著提升，而 ERNIE-CRF 模型表现未达预期。这些实验结果不仅验证了采用预训练模型和 CRF 层结合的方法在提升命名实体识别性能上的有效性，同时也指出了不同模型在处理特定类型实体时的差异。最后，在结构化文本辅助标注的实现部分，描述了实体与图谱的匹配策略和结构化文本的可视化过程，展示了如何将非结构化的医学影像报告转化为有助于标注工作的结构化数

中国知网 https://www.cnki.net

据。通过虚拟化技术优化的 Virtualized Tree 组件，实现了大量数据的高效可视化展示，极大地提高了标注人员的工作效率和标注数据的准确性。

中国知网 https://www.cnki.net

5 医学影像辅助标注系统的设计与实现

本章在前文建立的医学影像标注知识图谱和结构化文本辅助标注工作的基础上，采用 MVVM 架构，设计并实现了一套医学影像辅助标注系统。该系统利用为用户提供了一个直观、高效的标注环境，通过整合医学影像知识和自动化文本分析功能，极大地减少了人工查找和判断的时间，显著提高了标注任务的执行效率。

5.1 需求分析与架构设计

本系统旨在为标注人员提供一个高效且精准的医学影像标注平台，在系统的前台标注系统部分，通过设计直观、简洁的用户界面，用户可以通过直观的操作完成医学影像的标注任务；后台管理系统则负责管理标注任务、用户权限，确保前台标注系统的顺利运行，包括任务分配、权限控制等功能。

首先，标注系统界面的设计应当简洁直观，易于上手。标注人员可能需要处理大量的医学影像数据，因此界面的简洁性对于减少操作负担和提高工作效率至关重要。合理的布局可以帮助用户快速找到需要的功能，从而降低学习成本和操作复杂度。同时，操作流程应当逻辑清晰，减少不必要的步骤。在医学影像标注过程中，标注人员需要按照一定的流程进行操作，包括加载影像、进行标注、提交结果等。系统应当设计合理的工作流程，尽可能减少用户的手动操作，提高整体的工作效率。最后，系统中的数据，包括标注任务、用户信息、权限设置等，都需要通过有效的管理机制进行维护。这包括数据的存储、查询、更新和备份等，确保数据的安全性和一致性。

为了满足以上的需求，该系统以 MVVM 设计模式为核心，采用了前后端分离的开发模式。在这种模式下，前端专注于构建用户界面和处理用户交互，后端则专注于提供数据处理和业务逻辑。这种架构设计为系统带来了诸多优势，包括良好的分工协作、易于维护和扩展、更高的可重用性等。MVVM 设计模式将视图与数据逻辑分离，降低了系统的耦合度，使得前端和后端可以独立开发和测试，同时也提升了系统的整体性能和用户体验。

在 MVVM 架构下，系统的层次结构清晰，分为视图层（View）、视图模型层（ViewModel）、模型层（Model）。视图层负责展示用户界面，接收用户输入；视图模型层负责处理视图层的逻辑和数据，并与视图层进行双向数据绑定；模型层负责处理数据的存储、查询、更新和备份等操作。这样的架构设计使得系统能够更好地实现高效、精准的医学影像标注，同时保证数据的安全性和一致性，提升用户体验和工作效率。图 5-1 为本系统的层次架构图。

中国知网 https://www.cnki.net

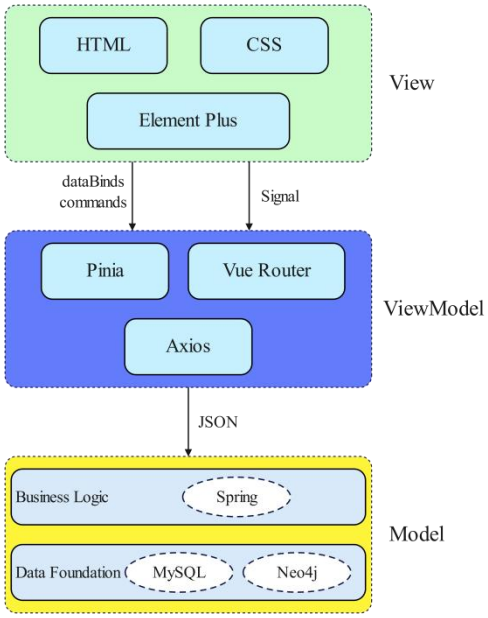


图 5-1 前台标注系统结构图

Figure 5-1 Structure Diagram of the Front-end Annotation System

(1) 视图层：View 层是用户与系统交互的最前端界面，它包含了构成页面的模板代码。在本系统中，前端技术选型为 Vue 框架，它通过 Vue 的组件化系统实现界面构建，通常每个独立的页面对应一个 Vue 组件。这些组件不仅负责展示信息，也负责监听并处理用户的交互行为。为了丰富界面元素和提高开发效率，本系统集成了 Element-Plus 这一 UI 组件库，并结合传统的 HTML 和 CSS 技术进行页面布局和样式设计，以实现既美观又功能丰富的用户界面。

(2) 视图模型层：ViewModel 层主要承担页面级的业务逻辑处理任务。在前端框架 Vue 中，每个 UI 组件对应一个 Vue 实例，使得 ViewModel 层能够通过双向数据绑定、指令和事件监听等机制与 View 层进行交互。利用 Pinia 和 Vue-Router，ViewModel 层能够实现前端的全局数据管理以及不同组件之间的通信。在采用前后端分离架构的应用中，前后端的数据交换主要通过 RESTful API 完成。前端使用 Axios 这一基于 Promise 的 HTTP 客户端，对 Ajax 技术进行封装和增强，以便发起异步 HTTP 请求并处理返回的数据，这些操作均在 ViewModel 层中进行。

(3) 模型层：在 MVVM 架构模式中，Model 层负责为 ViewModel 层提供所需的数据。在使用 RESTful API 的系统中，Model 层通常负责处理后端业务逻辑，并以 JSON 格式与前端进行数据交互。这里的 Model 层主要指代系统的后端部分，根据分层的思想被可以进一步细化为数据基础层和业务处理层。在数据基础层，系统采用了 Neo4j 和 MySQL 数据库，Neo4j 数据库中存储了第三章构建的医学影像标注知识图谱。数据业务基础层负责实现系统的业务处理，基于 Spring 框架，并通过 Spring MVC 来解析前端的 HTTP 请求，将其路由到相应的控制器中，以执

中国知网 https://www.cnki.net

行系统的核心业务功能。

5.2 标注流程与系统设计

5.2.1 标注任务流程设计

本系统的关键特性是对医学影像进行高效精准的标注。为实现此目的，通过设计一套标注任务流程，使用户能够顺利地对医学影像进行标注，包括领取标注任务、获取待处理的图像文件、进行详细的图像标注工作，并最后提交标注结果以供审核。通过这一系列步骤，系统确保了标注的效率与准确性。标注任务的整体流程如图 5-2 所示。

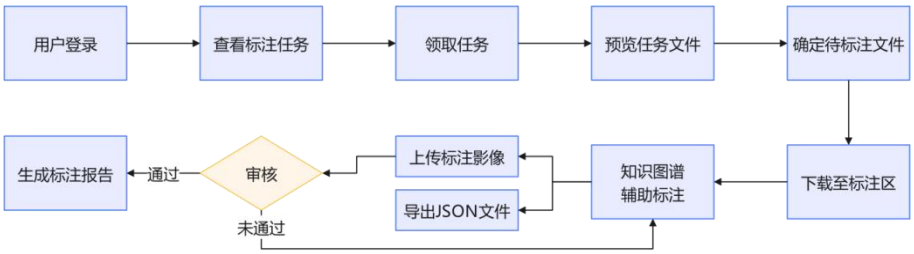


图 5-2 标注任务流程

Figure 5-2 Annotation Task Process

5.2.2 前台标注系统设计

在前台标注系统中，标注人员采用两种主要方法来进行医学影像的标注：

(1) 手工标注：这种方法适用于只有医学影像数据而无影像报告文本的情况。标注人员将直接在影像上进行操作，手工绘制多边形以选定特定区域，并对这些区域添加适当的标签来进行标注。这一过程完全依赖于标注人员对医学影像的理解和识别能力。

(2) 文本辅助标注：当处理多模态医学数据时，即同时拥有医学影像文件和对应的文本数据（例如病历描述、检查报告等），首先要进行的是文本分析。通过文本数据的知识提取，系统将识别和提取文本中的关键信息。随后，这些信息将与已建立的医学影像标注知识图谱进行匹配并整合，以形成一个结构化的医学影像报告。这个报告将协助标注人员理解影像内容，并据此对影像进行更准确的标注。

影像标注完整流程如图 5-3 所示。

中国知网 https://www.cnki.net

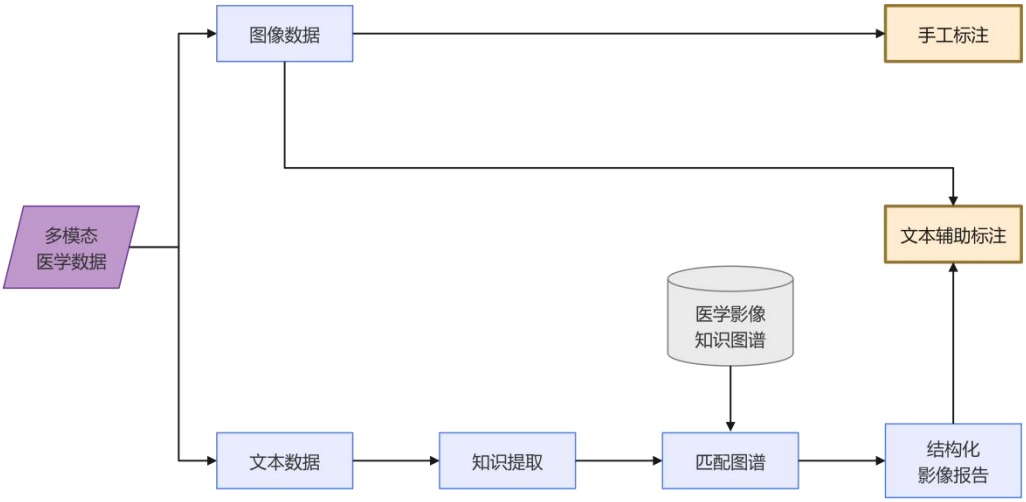


图 5-3 影像标注流程

Figure 5-3 Imaging Annotation Process

为了有效地支持上述的标注流程，标注系统需要设计一个用户友好且高效的界面，包括以下核心模块和功能：

(1) 用户注册与登录：该模块应提供一个安全的登录机制，确保标注人员的权限管理和信息安全。

(2) 标注任务模块：这个模块应允许标注人员查看和领取任务，通过在界面上查看任务列表，了解任务的详细信息，并选择领取适合自己的任务。并支持任务的状态跟踪，如“提交审核”、“已审核”和“已撤销”等，同时有一个直观的界面来管理和下载待标注的影像资料。

(3) 文本标注模块：结合可视化技术，该模块能够直观地展示医学影像报告的结构化信息，该模块通过突出显示关键的病变特征和相关医学信息，使标注人员更好地理解和标注影像，并提供必要的交互和提示，以确保标注的准确性和一致性。

(4) 标注标签模块：这一模块提供了一个综合的、可定制的标签和分类库，使得标注人员可以为标注区域轻松地选择合适的标签。同时支持标签的搜索、添加和编辑等功能。

(5) 图像标注模块：该功能在图像标注区展示待标注的医学影像，支持影像的放大、缩小、旋转等操作，并提供多种图像标注工具，如多边形选框、折线等，以适应不同类型的标注需求。同时，集成的人工智能算法，提供初步的自动标注建议，减少人工标注的工作量。

通过精心设计的用户界面和功能模块，该辅助标注系统为医学影像标注提供了一个全面、高效且用户友好的平台。从用户的注册与安全登录，到具体的标注任务处理，每个环节都经过细致的考虑，以确保操作的直观性和易用性。文本标注功能通过 AI 算法的支持与图像的标注工作进行结合，大大提高了标注的准确性

中国知网 https://www.cnki.net

和效率。同时，灵活的标签系统进一步提升了工作流程的便捷性，使得标注人员能够统一化、标准化的进行标注，从而提高标注结果的质量。

5.2.3 后台管理系统设计

为了确保标注任务、标注标签、算法模型以及用户与权限管理的高效有序，本标注系统配备了一个全面的后台管理系统。该系统将整合以下核心模块和功能：

(1) 标注任务管理：管理员创建新的标注任务，并将其分配给相应的标注人员，并可以对完成的标注任务进行审核，确保标注结果的准确性和质量。

(2) 文本标注管理：实现对医学影像标注知识图谱的维护，允许管理人员浏览、编辑图谱内容，确保信息的准确性和最新性。支持对知识图谱的结构进行调整，包括添加新的节点、编辑现有节点之间的关系，以及删除不再需要的元素。

(3) 标注标签管理：管理标注标签的添加、修改和删除，以确保标签库的准确性和最新性。并对标签进行分类管理，提高查找和应用的效率。

(4) 模型管理：该模块用于对自动标注算法模型进行管理，包括通过上传权重文件新增模型、编辑模型、删除不再需要的模型，以及查看现有模型的详细信息。

(5) 用户管理：管理用户的创建、角色管理、权限管理和删除等，包括标注人员、审核人员和管理员等角色。并设置各角色的权限，根据不同角色分配相应的权限和访问级别，确保系统操作流程的有序和数据的安全。

利用这些综合性的管理功能，后台管理系统确保了整个标注流程的高效性和有序性，同时保障了数据的准确性和安全性。标注任务管理模块使得任务的分配和审核变得简单高效，文本标注管理和标注标签管理模块则确保了知识图谱和标签库的实时更新和准确性。模型管理模块为自动标注提供了强大的支持，使得标注过程更加智能化和精确。用户管理模块确保了系统的安全性，为系统的稳定运行提供了坚实的基础。

5.3 系统实现

5.3.1 系统开发软件环境

在设计和开发任何计算机系统之前，了解所使用的软件环境至关重要。软件环境是指系统开发所需的各种软件工具和平台，正确选择和配置这些工具和平台对于系统的稳定性、性能和功能的实现至关重要，本研究中采用了一系列先进的技术和工具来支持系统的开发和实现。前台标注系统与后台管理系统开发环境见

中国知网 https://www.cnki.net

表 5-1。

表 5-1 软件开发环境
Table 5-1 Software Development Environment

软件	版本
操作系统	Windows 11 家庭版 64 位
Nodejs	18.17.1
Vue.js	3.3.4
React.js	18.2.0
Python	3.11.5
Neo4j	Community-5.16.0

5.3.2 前台标注系统功能及页面实现

本系统使用 Vue3+Typescript+Pinia+Vite 作为前端技术栈，其组件化的特性很好的将一个庞大复杂的前端工程中的各个功能模块拆分为一个个组件。Vue3 通过引入 Composition API，优化了组件的逻辑复用与组织，进而提升了代码的可维护性和可扩展性。Typescript 作为 JavaScript 的超集，为系统增添了静态类型检查功能，极大地提升了代码的健壮性和开发效率。Pinia 作为当下最流行的状态管理库，以其轻量和模块化的特点，为组件间的状态共享提供了优雅的解决方案。Vite 是一个基于现代浏览器特性的构建工具，通过利用 ES 模块导入机制，实现了快速的热重载和按需编译。将组件化视为一种自下而上的抽象方法，可以用公式（5-1）概括：

$$C = \oplus_{i=1}^{n} f_i(M_i, S_i, D_i) \quad (5\text{-}1)$$

其中 C 代表最终构建的复杂前端应用，f_i表示第 i 个组件的构造函数，M_i、S_i,、D_i分别代表该组件的方法集、状态集和依赖集。通过这种方式，每个组件都作为一个独立的单元，负责特定功能模块的实现，保障了系统的高内聚与低耦合特性。

(1) 登录页面

进入标注系统需要用户输入用户名和密码进行身份验证，并填写验证码以防自动化攻击。登录成功后，根据用户的角色权限，展示不同的操作界面和功能选项。如图 5-4 所示。

中国知网 https://www.cnki.net



图 5-4 标注系统登录页
Figure 5-4 Login Page of the Annotation System

(2) 标注页面

影像标注页面的设计考虑了用户体验和操作效率，采用了直观且功能丰富的三栏布局，确保了标注人员可以高效、准确地完成医学影像的标注工作。

页面的顶部是一个全宽的导航栏，提供了快速访问系统主要功能的菜单项，包括项目概览、标注指南、系统设置等。此外，导航栏右上角还集成了用户管理功能，如个人账户信息查看和注销登录操作，方便用户随时管理其会话和个人设置。

内容区域被划分为左中右三部分，以支持不同的操作和信息展示。左侧的标注工具栏紧凑而全面，涵盖了各种标注工具，如选框、多边形和折线等，满足不同类型医学影像的标注需求。同时，工具栏还提供了清空标注、上传新影像和导出标注结果等实用功能，使得标注工作流程更加连贯和高效。

中间部分是影像标注区，占据了页面的主体位置。这一区域内嵌了一个功能强大的 canvas 画布，使标注人员能够直接在医学影像上进行精确的绘制和编辑。画布支持多种交互方式，包括缩放、拖拽和旋转等，确保标注人员可以从最佳角度和比例观察和标注影像。

右侧区域包含 3 个 tab 标签，分别对应“标注任务”、“影像标签”和“文本标注”。在“标注任务”标签下，标注人员可以查看和领取当前可用的标注任务，同时也支持自动标注和标注文件的导入功能，进一步提高标注效率。“影像标签”标签展示了当前影像所有标注区域的标签列表，使得标注人员可以快速查看和管理这些标签。“文本标注”标签则提供了一个树形结构的文本辅助标注视图，以便标注人员快速确定文本报告中各个器官、组织的异常信息。

中国知网 https://www.cnki.net

影像标注页的整体效果如图 5-5 所示。

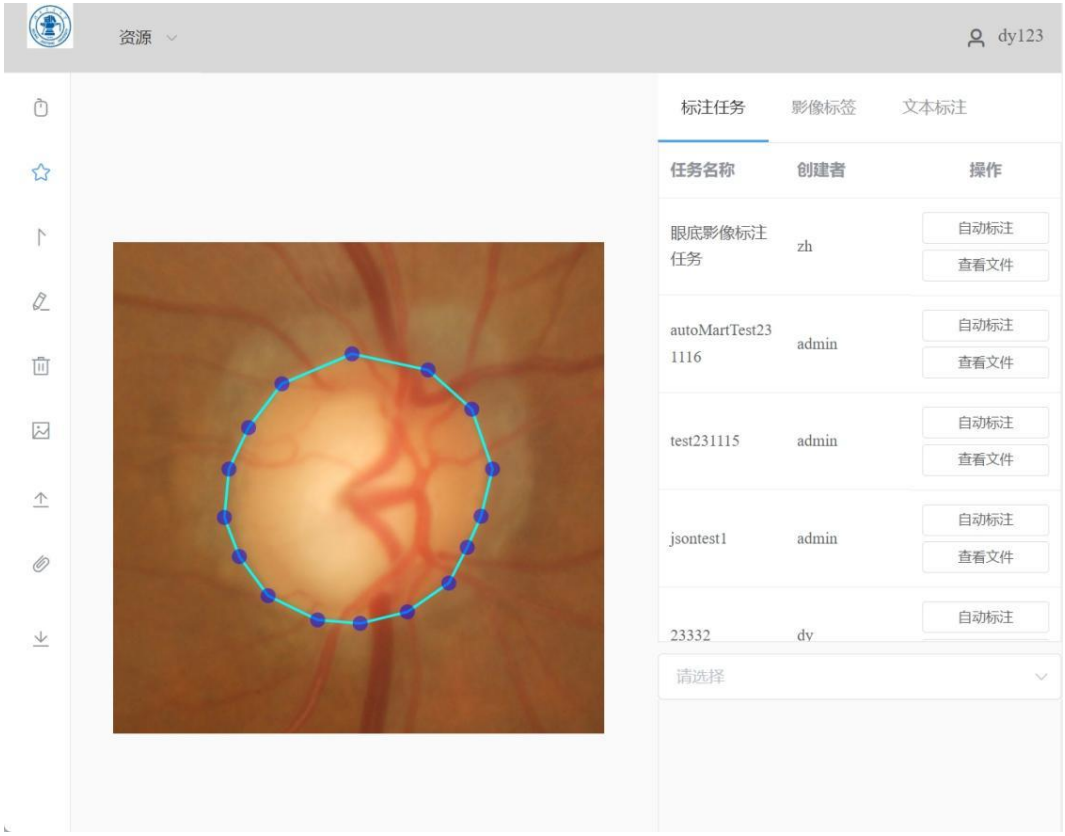


图 5-5 影像标注页
Figure 5-5 Imaging Annotation Page

在图像标注操作上，本系统采用基于 HTML5 Canvas 的 Fabric.js 技术。Fabric.js 是一个用于创建交互式的 HTML5 canvas 元素的 JavaScript 库，支持绘制图形、添加文本等操作，其丰富的 API 可以方便地操作和管理 canvas 上的各种对象。同时，Fabric.js 支持生成 JSON 数据，这些数据可以记录下图像标注的详细内容。通过调用 fabric 的 toJSON 方法，可以将标注操作序列化为 JSON 格式，从而方便存储和后续处理。

(3) 文本辅助标注

对于同时拥有图像文件和对应检查报告的任务，在标注人员领取该任务后，系统会在待标注影像文件下载导入的同时，对检查报告进行分句并利用训练好的命名实体识别模型来提取关键信息，再与知识图谱中的实体进行匹配及整合，形成完整的包含正常、异常属性信息的结构化报告。最后，这份报告以 JSON 格式返回，便于在前端应用中通过树状控件进行直观展示，从而实现信息的可视化和快速访问。

在文本标注树的下方，为标注人员提供了原始的影像检查报告，并通过不同

中国知网 https://www.cnki.net

的颜色展示了文本标注在原文本上的效果，标注人员能够直观地验证和校对文本标注树的内容，方便了标注人员对标注结果的复核和修正，保障了医学影像标注的质量和准确性。

该模块在标注系统中的界面见图 5-6。



图 5-6 文本标注界面

Figure 5-6 Text Annotation Interface

(4) 文图互动提示

文图互动提示旨在增强医疗影像分析的互动性和直观性，通过文本标注的内容来指导标注人员对图像中的特定区域进行识别。标注人员通过点击树形控件中的节点，如器官或组织，即可在图像标注区高亮显示相应的区域。为了实现该功能，本研究对输入的医学影像，基于解剖学知识和传统的图像处理技术，进行器官的粗粒度分割。通过基于固定模式的粗粒度分割，标注人员能够在没有复杂模型辅助的情况下，快速准确地定位到可能存在异常的组织区域，该模式适用于对即时性要求较高或资源有限的场景，为后续的详细标注和分析奠定了基础。

中国知网 https://www.cnki.net

这种从文本到图像的映射提高了检查报告数据的可理解性，使标注人员能够快速识别并关注图像中的关键信息，有效提高了标注工作的效率和准确性。文本标注到标注区域的映射效果如图 5-7 所示。



图 5-7 文本标注映射

Figure 5-7 Mapping from Text to Image Annotation Areas

5.3.3 后台管理系统功能及页面实现

标注后台管理系统基于 React 技术栈开发，集成了 Ant Design UI 库以提供丰富的界面组件，Redux 用于状态管理，并利用 React Router 进行前端路由控制。该系统采用两栏布局设计，左侧作为固定的导航栏，方便用户快速访问不同的管理模块；右侧则是内容展示区，用于显示用户从导航菜单中选定的具体管理功能的相关信息和操作界面。

在开始一个标注任务之前，首先需要在系统中创建一个新的标注任务。管理员可以通过系统的导航栏访问标注任务管理页面，在该页面点击“新增”按钮，并输入任务的名称、描述以及其他相关信息。一旦新增成功，系统会将该任务添加到任务列表中，供管理员和标注人员进行管理和操作。在任务列表中，管理员可以查看所有的标注任务，并对它们进行各种操作，包括待标注文件上传、任务分配、任务审核、修改和删除等。管理员可以根据任务的要求和标注人员的情况，将待处理的任务分配给不同的标注人员。任务分配给标注人员后，标注人员便可以登录标注系统，查看已分配给自己的任务，并在系统提供的标注界面中进行标注。标注任务管理界面如图 5-8 所示。

中国知网 https://www.cnki.net

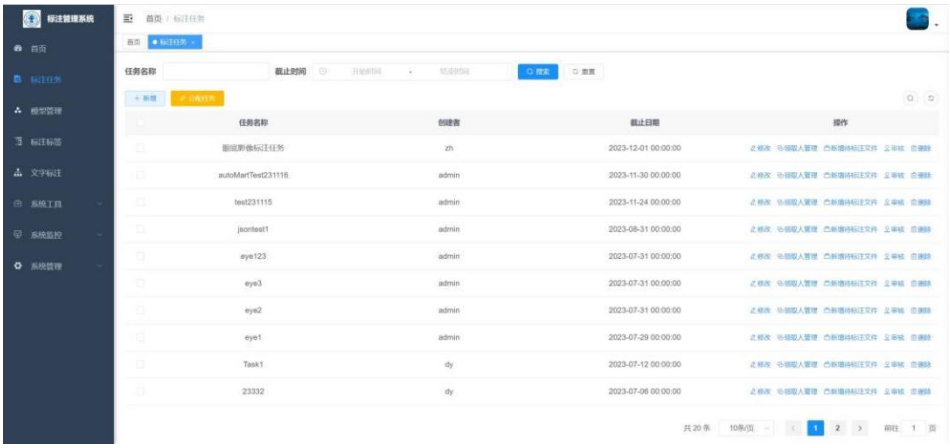


图 5-8 标注任务管理页
Figure 5-8 Annotation Task Management Page

在后台管理系统中，审核人员可以查看和评估标注任务，通过预览标注人员生成的 mask 图像来进行初步审核。这些 mask 图像直观地展示了标注区域，使审核人员能够迅速识别出可能的错误或不准确之处，为了更细致地检查这些标注区域，审核人员还可以登录标注系统对 mask 图像进行详细查看，以便深入分析标注质量，并确定是否满足既定的质量标准。

如果某些影像文件的标注未能通过审核，审核人员会将其任务状态标记为需要修改。此时，标注人员需要重新处理未通过审核的任务，在标注系统中可以访问到这些未通过审核的影像文件，在上次标注的基础上进行修改和优化，无需从头开始重新标注，大大提高了修正的效率。通过这样的迭代过程，可以确保每一份标注都达到较高的准确性和质量标准，从而提高整个项目的最终输出质量。后台管理系统中的审核预览如图 5-9 所示。

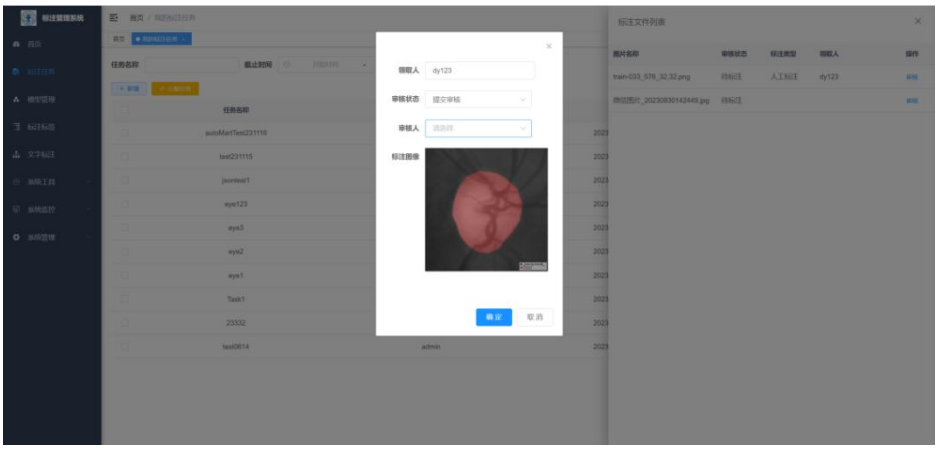


图 5-9 审核预览
Figure 5-9 Review Preview

中国知网 https://www.cnki.net

5.4 与现有标注软件的对比分析

为了验证医学影像辅助标注系统的性能和优势，本研究将其与现有几款常用标注软件（LabelMe、CVAT、LabelImg）进行了详细的对比实验。与其他标注软件的对比通过实际使用不同标注软件进行同一批次医学影像数据的标注任务来进行，在对比实验中，进行标注任务的分配，并记录标注人员在不同软件上的标注时间、标注准确性和操作便捷性。标注准确性的差异结果主要通过标注人员的反馈和对标注结果的人工审核得到。以下是实验结果和分析：

(1) 标注时间对比

在标注时间方面，选取了相同的医学影像数据集进行标注，并记录了每款软件完成相同标注任务所需的时间。

LabelMe：由于需要手动绘制多边形区域，标注时间较长。标注一幅图像平均耗时约 15 分钟。

CVAT：尽管提供了多种标注工具，但由于其复杂的操作界面，初次使用者需要较长的适应时间。标注一幅图像平均耗时约 12 分钟。

LabelImg：主要用于矩形框标注，标注速度较快。标注一幅图像平均耗时约 8 分钟。

医学影像辅助标注系统：结合知识图谱和文本分析，实现了快速定位医学影像中的异常区域，大幅减少了人工标注时间。标注一幅图像平均耗时约 5 分钟。

(2) 标注准确性对比

标注准确性方面，主要关注标注人员能否快速且准确地定位医学影像中的异常区域。医学影像辅助标注系统通过结合训练好的实体识别模型，深入分析临床检查报告中的非结构化文本数据，生成直观的可视化标注信息，显著提高了标注的准确性。

LabelMe：依赖于手动操作，标注人员容易遗漏细小的异常区域，尤其在处理复杂影像时。

CVAT：虽然提供精细标注工具，但缺乏医学知识支持，标注人员在标注过程中容易出现遗漏或误标。

LabelImg：仅支持简单的矩形框标注，对于复杂的医学影像，标注人员难以准确圈定异常区域。

医学影像辅助标注系统：利用医学文本分析功能，结合医学影像标注知识图谱，生成直观地标注建议，帮助标注人员快速定位异常区域，极大地减少了漏标和误标的情况。

(3) 用户体验对比

中国知网 https://www.cnki.net

用户体验通过对多名标注人员进行问卷调查和反馈，综合考虑了操作简便性、功能完善性和用户满意度。

LabelMe：操作简单，但功能较为基础，用户满意度中等。评分为 8/10。

CVAT：功能完善，但操作复杂，初学者需要较长时间适应，用户满意度较高。评分为 7.5/10。

LabelImg：轻量级工具，操作简便，但功能单一，用户满意度较高。评分为 7/10。

医学影像辅助标注系统：界面友好，操作简便，结合文本标注功能，用户满意度最高。评分为 9/10。

实验结果表明，医学影像辅助标注系统在标注时间、标注准确性和用户体验方面相比于传统的标注软件具有一定的优势，通过结合知识图谱和文本分析，有效地帮助标注人员快速定位影像中的异常区域，减少了漏标和误标现象，显著提高了标注的准确性。

5.5 本章小结

本章详细介绍了基于知识图谱的医学影像辅助标注系统的设计与实现，全面展示辅助标注系统的设计理念、功能架构及实现细节，并与当下主流的图像标注软件进行了性能对比。在需求分析与架构设计部分，深入探讨了系统设计的初衷和目标，明确了提高标注效率和准确性的核心需求，并基于这些需求选择了适合的技术栈以及确定 MVVM 架构。标注任务流程设计环节详细规划了从任务分配到标注审核的完整流程，确保了标注工作的高效有序进行。前台标注系统的设计和实现部分，致力于优化标注人员的操作体验，对用户界面和交互进行了详细的设计，并展示了系统的主要功能，如文本标注、影像编辑工具和任务管理等。后台管理系统的设计与实现则侧重于数据管理，包括任务调度和用户权限控制等功能，以支撑前台系统的稳定运行。与现有标注软件的对比分析部分，通过与现有几款常用标注软件进行对比实验，分析了医学影像辅助标注系统的优势，文本标注功能显著提升了医学影像标注任务的执行效率。

中国知网 https://www.cnki.net

6 总结与展望

6.1 本文主要工作总结

本研究旨在解决当前医疗领域，特别是医学影像诊断领域中面临的一系列挑战。随着深度学习技术在医疗诊断中的应用越来越广泛，其所需要的高质量标注数据集也越来越难以满足需求。同时，使用一些传统的标注软件，因其设计初衷为标注多种类型的图像，更加注重普适性，而非为医学影像的标注而特别设计，因此在面对复杂的医疗影像标注任务时，往往因缺乏必要的专业指导而导致标注效率和准确性受限。

为了应对这些问题，本文主要进行了以下三部分内容的研究：面向医学影像标注的知识图谱设计与构建、结构化文本辅助医学影像标注的方法与实现、医学影像辅助标注系统的设计与实现。首先，构建医学影像标注知识图谱是实现辅助标注的基础，通过整合医学影像教材和临床影像检查报告等多源信息，为后续的生成结构化文本辅助标注提供了知识基础。随后，结构化文本辅助医学影像标注的方法与实现则应用先进的自然语言处理技术，自动识别和提取医学影像检查报告中的关键信息，与医学影像知识图谱相结合，形成结构化、标准化的医学影像报告。最后，开发基于 MVVM 架构设计的医学影像辅助标注系统，通过文本标注辅助标注者进行医学影像的标注任务，大大提高了标注工作的效率和准确性。本研究的具体工作如下：

(1) 面向医学影像标注的知识图谱设计与构建

在构建医学影像标注知识图谱的研究中，本研究针对医学影像标注任务需求复杂，且开放领域的知识图谱无法直接应用于医学影像的标注问题，设计并创建了一个以系统、器官、组织、属性以及属性值为核心实体的知识图谱框架。从多种数据源进行对知识图谱的数据采集，再通过对数据的整理与校验，得到表格形式组织的数据文件。最后，对实体的结构、实体间关系的设定以及实体属性进行设计，编写 Python 脚本利用 py2neo 对图数据库 Neo4j 进行操作，实现了知识的存储，从而完成了医学影像知识图谱的搭建工作。

(2) 结构化文本辅助医学影像标注的方法与实现

为了有效提取非结构化临床影像检查报告中的关键信息，需要使用预训练模型对报告文本进行命名体识别。为了实现更好的识别效果，对 BERT 及其变体模型进行了对比实验，并为每个预训练模型增加了一个 CRF 层。实验结果表明，与

中国知网 https://www.cnki.net

基线模型 BERT-CRF 相比，RoBERTa-WWM-CRF 模型的精确率提高了约 1.5%，召回率更是提升了高达 8.8%，F1 值提升 5.8%，达到了 78.0%。在得到了性能较为优秀的模型后，本研究首先对整段的报告分句处理，随后对每个独立的句子进行命名体识别，得到实体信息列表，再利用同义词表映射为标准化术语，与知识图谱中的实体进行匹配。通过与知识图谱数据的结合，生成检查报告的结构化数据。最后，利用 Virtualized Tree 组件实现了结构化数据的前端可视化展示。

(3) 医学影像辅助标注系统的设计与实现

本研究基于 MVVM 架构，使用 Vue3 及 React18 作为前端技术栈，设计实现了医学影像辅助标注系统及其管理系统，通过前后端分离的开发模式，使得前端专注于用户界面（UI）的构建和用户体验的提升。首先，标注任务模块的设计使得标注人员对于领取任务和下载待标注影像这一流程的执行更加条理清晰。同时，在标注人员执行标注任务时，通过前文构建的医学影像知识图谱以及生成的可视化文本标注，实现了在标注过程中提供医疗专业知识的支持。由于医学影像标注对于准确性的要求，在标注区域使用了基于 HTML5 Canvas 的 Fabric.js 库进行图像标注操作及导出、导入等功能。标注标签模块则通过事先定义好的医疗相关标签和类别，使得标注工作人员能够方便地在标划区域时进行选择和使用，从而提升标注名称的统一性。为了对标注系统中各模块展示的内容进行管理，标注系统还拥有配套的后台管理系统，主要包含标注任务管理、文本标注管理、标注标签管理、模型管理、用户管理等功能。

6.2 未来工作展望

本研究成功实现了基于知识图谱的医学影像辅助标注系统，并探讨了知识影像标注图谱构建以及结构化文本辅助医学影像标注等技术，但在实施过程中还存在若干待优化之处，主要包括以下几个方面。

首先是医学影像标注知识图谱的构建。在本研究中，所建立的知识图谱主要源自医学教材的半结构化信息。这些教材上的数据使用的都是标准的医学术语，但在实际应用中，如影像检查报告和患者病历，往往由于医生的不同导致使用的术语也有所差异，虽然在报告信息与图谱匹配的过程中，使用了同义词表将其映射为标准化术语，但这仍在一定程度上限制了知识图谱的普适性。未来的工作中，可以考虑使用语义相似度算法提升实体匹配图谱的效果。

其次在命名体识别实验中，对于模型训练使用的数据集，各个实体样本分布不均，导致模型在识别较少数量的实体时遇到困难，对整体的识别效果产生了负面影响。在后续的研究中需要更加关注数据集的优化和平衡，以提高模型对于各

中国知网 https://www.cnki.net

类实体的识别能力。同时也需要在条件允许的情况下增加训练的轮次，进一步降低损失，以提升模型整体表现。

最后，在医学影像辅助标注系统的开发层面，本文成功开发了系统中包括执行整个标注任务的流程以及相关的管理功能。未来的工作可以在现有基础上，进一步增强系统的功能和用户体验。例如，可以加入更智能的标注推荐算法，利用机器学习技术自动预测和推荐标注标签，减少标注人员的工作量。同时，增加更为高级的数据分析和可视化工具，帮助用户更好地理解和分析标注数据，从而提高标注数据的质量和使用价值。此外，引入更加灵活的用户权限管理和协作标注功能，可以支持多人协作和任务分配，提高标注项目的效率。

中国知网 https://www.cnki.net

参考文献

[1] 李勇.人工智能在医学影像中的研究与应用[J]. 国际全科医学, 2023,4(2): 4-6.
[2] 林冰洁,王梅云.深度学习在医学影像学中的研究现状及发展前景[J]. 山东大学学报 (医学版),2024,61(12): 21-9.
[3] 薄众,张宏莉.人工智能在医学影像辅助诊断中的应用综述[J].临床医学前沿,2023,5(3):145-7.
[4] Aljabri, M., Alamir, M., Alghamdi M, et al.Towards a better understanding of annotation tools for medical imaging: a survey[J]. Multimedia tools and applications,2022,81(18): 25877-25911.
[5] 蒋西然, 蒋韬, 孙嘉瑶, et al. 深度学习人工智能技术在医学影像辅助分析中的应用[J]. 中国医疗设备, 2021, 36(6): 164-71.
[6] Gaudioso V. Mvvm:Model-view-viewmodel[C]. //Foundation Expression Blend 4 with Silverlight.Springer,2010: 341-367.
[7] Bizer C., Lehmann J., Kobilarov G., et al. Dbpedia-a crystallization point for the web of data[J]. Journal of web semantics, 2009, 7(3): 154-165.
[8] Bollacker K, Cook R, Tufts P. Freebase: A shared database of structured general human knowledge[C]. //AAAI.2007. 1962-1963.
[9] Suchanek, Fabian M., Kasneci G., et al. Yago: A large ontology from wikipedia and wordnet[J]. Journal of Web Semantics, 2008, 6(3): 203-217.
[10] Miller G A.WordNet:a lexical database for English[J].Communications of the ACM,1995,38(11): 39-41.
[11] Rebele T, Suchanek F, Hoffart J, et al.YAGO:A multilingual knowledge base from wi kipedia, wordnet, and geonames[C]. //The Semantic Web–ISWC 2016:15th International Semantic Web Conference, Kobe, Japan,October 17–21,2016,Proceedings, Part II 15.Springer,2016: 177-185.
[12] 黄贺瑄, 王晓燕, 顾正位, et al. 医学知识图谱构建技术及发展现状研究[J]. Journal of Computer Engineering & Applications, 2023, 59(13): 33-34.
[13] Bodenreider O. The unified medical language system (UMLS): integrating biomedical terminology [J]. Nucleic acids research, 2004, 32: D267-D270.
[14] 奥德玛,杨云飞,穗志方,代达劢,常宝宝,李素建,咎红英.中文医学知识图谱 CMeKG 构建初探[J]. 中文信息学报. 2019, 33(10): 1-7.
[15] 李丹亚,胡铁军,李军莲,等.中文一体化医学语言系统的构建与应用[J]. 情报杂志, 2011, 30(02): 147-151.
[16] 肖宇.新冠肺炎领域本体构建研究[J].军事医学, 2022, 004: 263-268.
[17] 何霆, 吴雅婷, 王华珍, 等.基于 EHR 的医疗知识图谱研究与应用综述[J].哈尔滨工业大学学报, 2018,50(11): 1-8.
[18] 赵悦淑,王军,王蕊,咎红英,张坤丽,穗志方.中文医学知识图谱研究进展[J].中国数字医学,2021,16(6): 86-91.
[19] 陈朝一, 许波, 吴英, 吴凯文. 医学图像处理中的注意力机制研究综述[J]. Journal of Computer Engineering & Applications, 2022, 58(5): 23-24.
[20] 赵阳, 李俊诚, 成博栋, et al. 深度学习在口腔医学影像中的应用与挑战[J]. 中国图象图形学报, 2024, 29(3): 586-607.

中国知网 https://www.cnki.net

[21] 李祥霞, 谢娴, 李彬, et al. 生成对抗网络在医学图像处理中的应用[J]. Journal of Computer Engineering & Applications, 2021, 57(18): 24-25.
[22] Torralba A, Russell B C, Yuen J. Labelme: Online image annotation and applications [J]. Proceedings of the IEEE, 2010, 98(8): 1467-1484.
[23] cvat-ai. Computer Vision Annotation Tool (CVAT).[EB/OL]. https://github.com/cvat-ai/cvat.
[24] HumanSignal. labelImg.[EB/OL]. https://github.com/HumanSignal/labelImg.
[25] 李子良. 基于深度学习的消化道医学影像半自动化标注与智能分析系统[D].西安电子科技大学, 2022. 2-5.
[26] Grishman R, Sundheim B M. Message understanding conference-6: A brief history[C]. // COLING 1996 volume 1: The 16th international conference on computational linguistics.1996: 1-6.
[27] Kenton J D M-W C, Toutanova L K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. //Proceedings of NAACL-HLT. 2019: 4171-4186.
[28] Sun Y, Wang S, Li Y, et al. Ernie 2.0:A continual pre-training framework for language understanding[C]. //Proceedings of the AAAI conference on artificial intelligence.2020.8968-8975.
[29] Liu Y, Ott M, Goyal N, et al. Roberta: A robustly optimized bert pretraining approach [J].arXiv preprint arXiv:190711692, 2019: 1-13.
[30] Salton G. Automatic Text Processing: The Transformation, Analysis, and Retrieval of Information by Computer[J]. Reading: Addison-Wesley, 1989, 169: 1-11.
[31] Baum L E, Petrie T, Soules G, Weiss N. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains[J]. The annals of mathematical statistics, 1970, 41(1): 164-71.
[32] Lafferty J, McCallum A, Pereira F. Conditional random fields: Probabilistic models for segmenting and labeling sequence data[C]. //Icml.Williamstown, MA,2001:3-4.
[33] Zeng D, Sun C, Lin L, Liu B. LSTM-CRF for drug-named entity recognition[J]. Entropy,2017, 19(6): 283-284.
[34] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
[35] Arasu A, Garcia-Molina H. Extracting structured data from web pages[C]. //Proceeding s of the 2003 ACM SIGMOD international conference on Management of data. 2003: 337-348.
[36] Bar-Hillel Y. The present status of automatic translation of languages [J]. Advances in computers, 1960, 1: 91-163.
[37] Egger R, Gokce E. Natural language processing (NLP): An introduction: Making sense of textual data[M]. Applied data science in tourism: Interdisciplinary approaches, methodologies, and applications. Springer. 2022: 307-334.
[38] Ratinov L, Roth D. Design challenges and misconceptions in named entity recognition[C]. //Proceedings of the thirteenth conference on computational natural language learning (CoNLL-2009).2009. 147-155.
[39] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors [J]. nature, 1986, 323(6088): 533-536.
[40] Malhotra P, Vig L, Shroff G, Agarwal P. Long Short Term Memory Networks for Anomaly Detection in Time Series[C]. //Esann.2015. 89-92.
[41] Rizzo G, Troncy R. Nerd: evaluating named entity recognition tools in the web of data[C]. //

中国知网 https://www.cnki.net

Workshop on Web Scale Knowledge Extraction (WEKEX'11). 2011. 1-16.
[42] Tsai R T-H, Sung C-L, Dai H-J, et al. NERBio: using selected word conjunctions, termnormaliz ation, and global patterns to improve biomedical named entity recognition[C]. //BMC bioinfor matic s. Springer, 2006. 1-14.
[43] Augenstein I, Maynard D, Ciravegna F. Distantly supervised web relation extraction for knowle dge base population[J]. Semantic Web, 2016, 7(4): 335-349.
[44] Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on knowledge and data en gineering, 2009, 22(10): 1345-1359.
[45] Guo J, Che W, Wang H, Liu T. Revisiting embedding features for simple semi-supervised learni ng[C]. //Proceedings of the 2014 conference on empirical methods in natural language processing(E MNLP). 2014. 110-120.
[46] Shen W, Wang J, Luo P, Wang M. Linking named entities in tweets with knowledge base via us er interest modeling[C]. //Proceedings of the 19th ACM SIGKDD international conference on Know ledge discovery and data mining. 2013. 68-76.
[47] Nasar Z, Jaffry S W, Malik M K. Named entity recognition and relation extraction: State-of-the -art[J]. ACM Computing Surveys (CSUR), 2021, 54(1): 1-39.
[48] Yang Y, Wu Z, Yang Y, et al. A survey of information extraction based on deep learning[J]. App lied Sciences, 2022, 12(19): 9691.
[49] Bunescu R, Pasca M.Using encyclopedic knowledge for named entity disambiguation[C]. // 11th conference of the European Chapter of the Association for Computational Linguistics. 2006. 9-16.
[50] Ostendorff M, Ruas T, Schubotz M, et al.Pairwise multi-class document classification for sema ntic relations between wikipedia articles[C]. //Proceedings of the ACM/IEEE Joint Conference on Di gital Libraries in 2020. 2020. 127-136.
[51] Shaowei Z, Xin W, Zirui C, et al. Survey of Supervised Joint Entity Relation Extraction Metho ds[J]. Journal of Frontiers of Computer Science & Technology, 2022, 16(4): 713.
[52] Lin Y, Shen S, Liu Z, et al. Neural relation extraction with selective attention over instances[C]. //Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2016. 2124-2133.
[53] Berners-Lee T, Hendler J, Lassila O. The Semantic Web: A new form of Web content that is me aningful to computers will unleash a revolution of new possibilities[M]. Linking the World's Inform ation: Essays on Tim Berners-Lee's Invention of the World Wide Web. 2023: 91-103.
[54] Fung K W, Bodenreider O. Knowledge representation and ontologies[M]. Clinical research info rmatics. Springer. 2023: 367-388.
[55] Qin Z, Zhao P, Zhuang T, et al. A survey of identity recognition via data fusion and feature lear ning[J]. Information Fusion, 2023, 91: 694-712.
[56] Dong X, Gabrilovich E, Heitz G, et al. Knowledge vault: A web-scale approach to probabilistic knowledge fusion[C]. //Proceedings of the 20th ACM SIGKDD international conference on Knowle dge discovery and data mining. 2014. 601-610.
[57] Neo4j, Inc. Neo4j.[EB/OL]. https://neo4j.com/.
[58] Feng H, Huang M. An Approach to Converting Relational Database to Graph Database: from MySQL to Neo4j[C]. //2022 IEEE 2nd International Conference on Power, Electronics and Compute

中国知网 https://www.cnki.net

r Applications (ICPECA).IEEE,2022: 674-680.
[59] Shewalkar A, Nyavanandi D, Ludwig S A. Performance evaluation of deep neural networks applied to speech recognition: RNN, LSTM and GRU[J]. Journal of Artificial Intelligence and Soft Computing Research, 2019, 9(4): 235-245.
[60] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[J]. Advances in neural information processing systems, 2014, 27.
[61] Cui Y, Che W, Liu T, et al. Pre-training with whole word masking for chinese bert[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3504-3514.
[62] Anderson C. The model-view-viewmodel (mvvm) design pattern[M]. Pro Business Applications with Silverlight 5. Springer. 2012: 461-499.
[63] Kentaro N, Satoshi F. Browser-Based manipulation of virtual objects through MVVM architecture with data binding[C]. //2021 ninth international symposium on computing and networking (CANDAR). IEEE, 2021.134-140.
[64] 饶建农. 可依赖软件设计的关注点分离的研究[J]. 电脑知识与技术, 2021, 4: 240-241.
[65] Sussman G J, Steele Jr G L. Scheme: A interpreter for extended lambda calculus [J]. Higher-Order and Symbolic Computation, 1998, 11(4): 405-439.
[66] Vue.js - The Progressive JavaScript Framework [EB/OL]. https://vuejs.org/
[67] React.js - The library for web and native user interfaces [EB/OL]. https://react.dev/
[68] Pathak V, Shrivastava V, Buri R, et al. Current Web Development Technologies: A Comparative Review[C]. //International Conference On Emerging Trends In Expert Applications & Security. Springer, 2023: 13-23.
[69] Yang H. Design Patterns of Vue. js 3[M]. Vue JS Framework: Design and Implementation. Springer. 2023: 33-45.
[70] Rawat P, Mahajan A N. ReactJS: a modern web development framework[J]. International Journal of Innovative Science and Research Technology, 2020, 5(11): 698-702.
[71] Caspers M K. React and redux[J]. Rich Internet Applications w/HTML and Javascript,2017: 11-16.
[72] Kejriwal M. Knowledge graphs: A practical review of the research landscape[J]. Information, 2022, 13(4): 161-162.
[73] Nelli F. The pandas library—an introduction[M]. Python Data Analytics: With Pandas, NumPy, and Matplotlib. Springer. 2023: 73-114.
[74] 刘映. 基于档案数据的地质知识图谱构建研究[J]. Shanghai Land & Resources/Shanghai Guotu Ziyuan, 2023, 44(2): 148-149.
[75] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv: 2303087 74, 2023: 1-100.
[76] Tong B, Chengzhi Z. Extracting Chinese Information with ChatGPT: An Empirical Study by Three Typical Tasks[J]. Data Analysis and Knowledge Discovery, 2023,7(9):1-11.
[77] 侯键, 许茂盛. 医学影像学[M]. 第 3 版. 中国中医药出版社, 2021: 1-368.
[78] 武煜明, 李新华. 系统解剖学[M]. 第 3 版. 中国中医药出版社, 2023: 1-324.
[79] MySQL - The world's most popular open source database. [EB/OL]. https://www.mysql.com/
[80] MongoDB - The Developer Data Platform. [EB/OL]. https://www.mongodb.com/
[81] Mikolov T, Kopecky J, Burget L, Glembek O. Neural network based language models for highl

中国知网 https://www.cnki.net

y inflective languages[C]. //2009 IEEE international conference on acoustics, speech and signal processing. IEEE, 2009: 4725-4728.
[82] Lin T, Chonghui G, Jingfeng C. Review of chinese word segmentation studies[J]. Data Analysis and Knowledge Discovery, 2020, 4(2/3): 1-17.
[83] Hugging Face – The AI community building the future. [EB/OL]. https://huggingface.co/.
[84] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]. //International Conference on Learning Representations. 2018. 1-8.
[85] Ma J, Yarats D. On the adequacy of untuned warmup for adaptive optimization[C]. //Proceedings of the AAAI Conference on Artificial Intelligence. 2021. 8828-8836.

中国知网 https://www.cnki.net

学位论文数据集

表 1.1： 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
医学影像标注；医疗命名实体识别；医学知识图谱；医学影像标注 WEB 系统	公开			
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	电子信息	硕士
论文题名*		并列题名*		论文语种*
基于知识图谱的医学影像辅助标注系统的研究与实现				中文
作者姓名*	杜洋		学号*	22140462
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
专业学位类别（领域）*		研究方向*	学制*	学位授予年*
软件工程		医学人工智能	2	2024
论文提交日期*	2024 年 6 月			
导师姓名*	夏佳楠		职称*	讲师
评阅人	答辩委员会主席*		答辩委员会成员	
	张宝鹏		吴丹 韩文娟	
电子版论文提交格式 文本（√） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword；application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*	62			
共 33 项，其中带*为必填数据，为 21 项。				

中国知网 https://www.cnki.net